

國立雲林科技大學數位媒體設計系

碩士論文

Department of Digital Media Design

National Yunlin University of Science & Technology

Master Thesis

探索 AI 協作與人類創造力差異

:基於抽象與具象尺度問題的創造力評估

Exploring AI Collaboration and Human Creativity:

Assessing Creativity Across Abstract and Concrete Scales

林新凱

Xin-Kai Lin

指導教授：許志維 博士

Advisor: Chih-Wei Shiu, Ph.D.

共同指導教授：白乃遠 博士

Co-advisor: Nai-Yuan Pai, Ph.D.

中華民國 114 年 6 月

June 2025

國立雲林科技大學
碩士班學位論文考試委員會審定書
National Yunlin University of Science and Technology
Thesis Oral Defense Approval Form

本論文係 林新凱 君在本校 數位媒體設計系碩士班 所提論文 探索AI協作與人類創造力差異：基於抽象與具象尺度問題的創造力評估 碩士資格水準，業經本委員會評審認可，特此證明。

The student LIN, XIN-KAI enrolled in the Master's program in Department of Digital Media Design has satisfactorily passed the oral defense of the thesis Exploring AI Collaboration and Human Creativity: Assessing Creativity Across Abstract and Concrete Scales.

口試委員：
Oral defense
committee members

許志維

白乃遠

郝光中

張循鏗




指導教授：
Advisor(s)

許志維

白乃遠



所長：
Dean of Graduate
Institute



中 華 民 國

114 年 7 月 21 日

摘要

本研究旨在探討人類、AI 協作與生成式 AI 三種創意模式於發散性思考中，面對不同抽象程度問題時的創造力差異，並提出基於抽象尺度的模式選擇策略，以協助判斷在何種情境下應採用人類、AI 協作或生成式 AI 模式以獲最佳創造力。實驗招募人類組 21 名、AI 協作組 21 名，生成式 AI 組則以 21 次獨立對話。研究採實驗法，透過 MRC 心理語言學資料庫篩選出涵蓋從高度抽象到高度具象的詞彙，並以此設計基於字詞聯想測驗的問卷。該問卷用以測量人類、AI 協作以及生成式 AI 三種創意模式在發散性思考中的創造力表現。創造力評估指標包括語義距離、專家共識評分與流暢性，其中語義距離透過 SemDis 平台進行量化，專家評分則由 6 位具相關背景的專家採含原創性、變通性、周全性與適切性四個維度的標準評估，流暢性即字詞聯想測驗回答數量。資料分析採線性混合效應及廣義線性混合模型。結果顯示，在抽象問題中，所有創意模式語義距離及專家評分皆顯著高於具象問題，但流暢性則呈相反趨勢；在創意模式比較上，生成式 AI 在語義距離顯著優於其他模式，但在專家評分上三種模式並無顯著差異——這意謂生成式 AI 創造力已達人類水準；AI 協作模式在流暢性上顯著優於人類模式。然而值得注意的是，即便生成式 AI 多數指標領先，仍可見少數人類受試者在某些題目上的語義距離分數與專家評分高於兩種 AI 模式，顯示人類在高原創性構想上仍具不可忽視的潛力。此外，在十種抽象尺度中，各創造力指標均呈非線性的複雜變化模式，顯示創造力表現受抽象程度影響的複雜性。本研究以抽象問題尺度導向的創造力評估為核心。結果揭示生成式 AI 與人類在創造力上的互補性。基於實證發現，本研究建議實務應用導入「生成式 AI 抽象發散→人類價值評鑑→AI 協作精煉」的階段性流程，為教育、設計與創意產業提供具體的 AI 應用策略，推動人機協作創造力的實踐與發展。

關鍵字：創造力評估、抽象與具象、生成式 AI、AI 人機協作、字詞聯想測驗

ABSTRACT

This study investigates how three ideation modes—human creators, human–AI collaboration, and generative AI alone—perform on divergent-thinking tasks that vary in conceptual abstraction, and it proposes an abstraction-based strategy for selecting the most effective mode in a given context. Twenty-one participants formed the human group and another twenty-one formed the collaboration group, while twenty-one independent ChatGPT sessions represented the generative-AI group. Ten cue words ranging from highly abstract to highly concrete were drawn from the MRC Psycholinguistic Database and embedded in a word-association questionnaire. Creativity was evaluated through semantic distance calculated with the SemDis platform, expert consensus ratings provided by six domain specialists on originality, flexibility, elaboration, and appropriateness, and fluency measured by the number of associations. Linear mixed-effects and generalized linear mixed-effects models were used for statistical analysis. Across all three modes, abstract cues elicited significantly greater semantic distance and higher expert ratings but lower fluency than concrete cues. Generative AI achieved the greatest semantic distance, yet expert ratings did not distinguish among the three modes, suggesting that the creative quality of generative AI has reached human levels. The collaboration mode produced significantly higher fluency than the human-only mode. Although generative AI led most metrics, isolated human responses occasionally exceeded both AI modes in semantic distance and expert scores, indicating that individual human ingenuity remains indispensable. Creativity indicators displayed non-linear, complex patterns across the ten abstraction levels, underscoring the multifaceted influence of abstraction on creative output. Building on these findings, the paper advocates a staged workflow in practice: generative-AI ideation at abstract levels, human

evaluation for value alignment, and AI-assisted refinement. This sequence offers actionable guidance for educators, designers, and creative industries seeking to harness complementary human and AI strengths to enhance creative performance.

Keywords: creativity assessment, abstract and concrete, generative AI, human-AI collaboration, Word Association Test



目錄

摘要	i
ABSTRACT	ii
目錄	iv
表目錄	vii
圖目錄	ix
一、 緒論	1
1.1 研究背景與動機	1
1.2 研究問題與目的	2
1.2.1 研究問題	2
1.2.2 研究目的	3
1.3 研究範圍與限制	3
1.3.1 研究範圍	3
1.3.2 研究限制	4
1.4 研究流程	6
二、 文獻探討	7
2.1 創造力與創意思考	8
2.1.1 創造力定義與意涵	8
2.1.2 創意思考方法	10
2.1.3 創造力量化	15
2.1.4 章節小結	22
2.2 生成式 AI 與創造力	24

2.2.1 大型語言模型概述 (LLMs)	24
2.2.2 生成式 AI 的創造力特徵	26
2.2.3 主流大型語言模型的創造力比較與應用	27
2.2.4 章節小結	31
2.3 AI 人機協作與創造力	32
2.3.1 AI 協作模式定義	32
2.3.2 生成式 AI 與人類創造力的異同	34
2.3.3 章節小結	35
2.4 抽象概念與創造力	36
2.4.1 抽象與具象的定義	36
2.4.2 抽象與具象對於創造力影響	37
2.4.3 章節小結	39
2.5 文獻探討總結	39
三、 研究方法與實驗設計	41
3.1 研究架構	41
3.1.1 研究變項	42
3.1.2 研究流程	43
3.2 研究工具	46
3.3 主實驗設計	55
3.3.1 主實驗受測者	55
3.3.2 主實驗流程	56
四、 研究結果與討論	59
4.1 樣本特徵與資料品質檢驗	59
4.1.1 樣本基本資料	59
4.1.2 資料品質檢驗	62

4.2 各項指標表現分析	74
4.2.1 各項指標相關性分析	74
4.2.2 不同創意模式與抽象兩尺度對創造力表現的影響分析	76
4.2.3 不同創意模式與抽象十尺度對創造力表現的影響分析	91
4.3 綜合討論	106
4.3.1 問題抽象程度如何影響三種創意模式的創造力表現與差異	106
4.3.2 人類、AI 協作及生成式 AI 模式的創造力臨界點	113
五、 研究結論與建議	119
5.1 研究結論	119
5.1.1 問題抽象程度顯著影響創造力表現	119
5.1.2 三種創意模式各具獨特優勢	119
5.1.3 抽象問題創造力測量框架之可複製性	120
5.2 未來研究建議	120
5.2.1 擴展任務類型	121
5.2.2 提升 AI 協作流程設計，探索最佳協作模式	121
5.2.3 強化刺激詞篩選機制與測量工具	121
5.2.4 擴大框架適用範圍，驗證跨領域可複製性	122
六、 參考文獻	123

表目錄

表 1 發散型思考與收斂思考方法對照表	11
表 2 傳統腦力激盪四項原則表	12
表 3 創造力評量方式表	15
表 4 專家共識評分標準表	22
表 5 主流模型性能指標對照表	29
表 6 本研究刺激詞彙抽象程度分佈表	46
表 7 主實驗受測者分組資訊表	56
表 8 受測者基本資料統計表	60
表 9 整體描述性統計表	62
表 10 語義距離之描述性統計表	63
表 11 流暢性之描述性統計表	64
表 12 專家評分之描述性統計表	65
表 13 語義距離之信度檢驗表	66
表 14 專家評分四大維度標準表	66
表 15 專家背景與經驗統計表	67
表 16 評分過程品質控制與信度檢驗結果表	68
表 17 語義距離與流暢性在抽象與具象兩組之常態分佈表	70
表 18 語義距離與流暢性在抽象題目之常態分佈檢驗表	70
表 19 語義距離與流暢性之常態分佈檢定表	72
表 20 專家評分在兩種抽象程度常態分佈檢定表	73
表 21 專家評分在十種抽象尺度常態分佈檢驗表	73
表 22 三組專家評分常態分佈表	74
表 23 語義距離與抽象程度、流暢性相關性分析表	75

表 24 專家評分與抽象程度、語義距離相關性分析表	76
表 25 語義距離之模型基本資訊表	77
表 26 語義距離之固定效應分析表	78
表 27 語義距離之隨機效應表	81
表 28 專家評分之模型基本資訊表	82
表 29 專家評分之固定效應分析表	83
表 30 專家評分之隨機效應表	85
表 31 流暢性之模型基本資訊表	86
表 32 流暢性之固定效應分析表	87
表 33 流暢性之隨機效應表	91
表 34 語義距離之模型基本資訊表	92
表 35 語義距離之固定效應分析表	93
表 36 語義距離之隨機效應表	95
表 37 專家評分模型基本資訊表	96
表 38 專家評分之固定效應表	98
表 39 專家評分之隨機效應	101
表 40 流暢性之模型基本資訊表	101
表 41 流暢性之固定效應表	102
表 42 流暢性之隨機效應表	105
表 43 不同創意模式在各創造力指標上的表現差異總結表	114

圖目錄

圖 1 研究流程圖	6
圖 2 各家創造力定義的體用關係	10
圖 3 字詞聯想測驗 (WAT) 操作流程圖	14
圖 4 鏈狀自由聯想 (CFA) 語義距離正相關的大腦區域圖	17
圖 5 語義記憶結構認知模型圖	19
圖 6 主流模型 Artificial Analysis Intelligence Index 長條圖	29
圖 7 研究架構圖	42
圖 8 研究流程圖	45
圖 9 MRC 心理語言學資料庫	47
圖 10 字詞聯想測驗問卷介面截圖 (以 AI 協作組為例)	49
圖 11 SemDis 輸出結果	52
圖 12 專家評分網站評分標準與四大維度說明	53
圖 13 專家評分網站評分操作畫面與進度追蹤	54
圖 14 主實驗研究流程圖	58
圖 15 語義距離模型預測值之散點圖	77
圖 16 各組對語義距離的主效應	79
圖 17 抽象程度對語義距離的主效應	80
圖 18 組別與抽象程度對語義距離的交互作用圖	81
圖 19 專家評分模型預測值之散點圖	82
圖 20 抽象程度對專家評分的主效應折線圖	84
圖 21 各組對專家評分的主效應折線圖	84
圖 22 組別和不同抽象程度對專家評分的交互作用折線圖	85
圖 23 流暢性模型預測值之散點圖	87

圖 24 各組對流暢性的主效應折線圖	88
圖 25 抽象程度對流暢性的主效應折線圖	89
圖 26 分組和不同抽象程度對流暢性的交互作用折線圖	90
圖 27 語義距離模型預測值之散點圖	92
圖 28 組別與抽象程度對語義距離的交互作用圖折線圖	93
圖 29 抽象程度對語義距離之主效應圖折線圖	94
圖 30 組別對語義距離之主效應圖折線圖	95
圖 31 專家評分之模型預測值的散點圖	97
圖 32 組別與抽象程度對專家評分的交互作用圖折線圖	99
圖 33 抽象程度對專家評分的主效應圖折線圖	100
圖 34 各組對專家評分的整體主效應差異折線圖	100
圖 35 流暢性模型預測值之散點圖	102
圖 36 組別與抽象程度對流暢性的交互作用圖折線圖	103
圖 37 不同抽象程度對流暢性的主效應折線圖	104
圖 38 各組對流暢性的主效應折線圖	105
圖 39 不同創意模式語義距離在兩種抽象程度的變化趨勢圖	107
圖 40 不同創意模式專家評分在兩種抽象程度的變化趨勢圖	108
圖 41 不同創意模式流暢性在兩種抽象程度的變化趨勢圖	109
圖 42 不同創意模式語義距離在十種抽象程度的變化趨勢圖	110
圖 43 不同創意模式專家評分在十種抽象程度的變化趨勢圖	112
圖 44 不同創意模式流暢性在十種抽象程度的變化趨勢圖	113
圖 45 不同創意模式語義距離分布箱型圖	115
圖 46 不同創意模式流暢性分布箱型圖	116
圖 47 不同創意模式專家評分分布箱型圖	117

一、緒論

1.1 研究背景與動機

隨著全球科技革命的推進，創意思考能力已成為未來競爭力的核心要素。世界經濟論壇 2025 年未來工作報告指出，創意思考被評為第二重要技能，73.2%的組織認為其重要性正在增加，僅次於分析思考(Future of Jobs Report 2025, 2025)。與此同時，生成式 AI 技術的快速發展正重塑全球勞動力結構。麥肯錫全球研究院預測，到 2030 年美國經濟中高達 30%的工作時間可能被自動化，需要額外 1200 萬個職業轉換(McKinsey, 2025)。然而，國際貨幣基金組織研究顯示，雖然全球 40%的就業機會面臨 AI 影響，但約一半受影響的工作可能從 AI 整合中受益而非被完全取代(Rebalancing AI-Daron Acemoglu Simon Johnson, 2025)。

在這種背景下，生成式 AI 等技術不斷進步，降低人們在各個領域的技術門檻，使得技術不再是決定因素，反之有好的創意才能脫穎而出。高盛研究顯示，藝術、媒體和娛樂領域 26%的任務可能被 AI 自動化，但大多數創意角色預期是「被補充而非被替代」(Goldman Sachs, 2023)。因此，生成式 AI 與創造力相關研究也變得更為重要。

研究指出，人類與生成式 AI 在創意活動中各有優劣；頂尖創作者的創造力較生成式 AI 更具原創性與新穎性，能產生突破框架的創意點子；然而，人類也可能因認知偏差或靈感枯竭而產出低品質的點子。生成式 AI 在創造力活動中則展現穩定性，極少出現低品質點子。這顯示了人類與 AI 在創意活動中具有互補性，且 AI 協作能有效彌補人類創造力的不足，提高點子的多樣性與品質(Koivisto & Grassini, 2023)。哈佛商學院與波士頓諮詢集團的聯合研究更進一步證實，AI 協作可使任務完成率提高 12.2%，完成時間縮短 25.1%，在 AI 能力範圍內的任務結果品質提高 40%(Dell'Acqua et al., 2023)。

儘管已有研究指出 AI 協作能夠提升創造力，但目前尚缺乏對於在不同問題導向的抽象程度下應採用何種創意策略以獲得最佳創造力表現的深入探討。現有研究尚未明確指出生成式 AI 在抽象與具象問題處理上的優劣，而是顯示 AI 與人類在創意活動中的互補性。抽象問題可能需要更高層次的推理與聯想，而 AI 的語義處理能力取決於其訓練數據與語境理解模型。

然而，目前尚無研究系統分析人類、生成式 AI 與 AI 協作模式在抽象問題尺度下的創造力表現，也未針對問題尺度提出最大化創造力的策略。本研究旨在填補這一缺口，通過定量分析不同問題尺度（抽象到具象）對創造力表現的影響，揭示人類與 AI 協作的臨界點，並探索在各種情境下應選擇生成式 AI、人類或 AI 協作模式的最佳策略。

本研究採用實驗法，利用 MRC 心理語言學資料庫（MRC Psycholinguistic Database）這是一個收錄豐富詞彙心理語言特性資料的資源，以篩選出具有不同抽象與具象尺度的詞彙，並結合字詞聯想測驗（WAT）設計實驗以測量創造力表現，並進一步透過語義距離、專家共識評分法與流暢性評估創造力趨勢。最後，本研究運用視覺化圖表，呈現三種創意模式在不同問題尺度下的創造力臨界點，進而為實務中如何有效應用 AI 協作模式以促進創造力提升提供科學依據。

1.2 研究問題與目的

本研究聚焦於人類、AI 協作以及生成式 AI 三種創意模式在不同抽象問題尺度下的創造力表現，旨在深入了解各模式間的差異，並提出實務建議。以下為本研究的研究問題與研究目的：

1.2.1 研究問題

根據上述的研究背景與動機，本研究探討的問題如下：

- (一) 問題抽象程度如何影響人類、AI 協作與生成式 AI 三種創意模式的創造力表現與差異？

(二) 人類、AI 協作及生成式 AI 模式的創造力臨界點為何？

(三) 如何根據問題抽象程度選擇最佳創意模式策略？

(四) 研究結果如何應用於實務領域？

1.2.2 研究目的

根據上述的研究背景與動機，本研究探討的目的如下：

(一) 建立以問題抽象程度為基準的創造力評估框架，系統性分析人類、AI 協作及生成式 AI 模式在不同問題尺度下的表現特徵。

(二) 探討創造力的臨界點，即在何種抽象尺度下各創造力模式的表現最佳。

(三) 根據實驗結果，繪製不同抽象尺度下的創造力表現曲線，找出 AI 協作的最佳應用臨界點，提供創意模式選擇策略。

(四) 基於研究發現，為教育、設計與創意產業提供 AI 協作應用指引，促進 AI 人機協作創造力的實務發展。

1.3 研究範圍與限制

此章節旨在界定本研究適用範圍與可能面臨的限制因素，並說明研究設計過程中所採取的因應措施。研究範圍主要描述本研究所聚焦的對象、題材及方法學邊界；研究限制則針對在抽樣、語言處理以及工具應用上的潛在侷限進行說明，以確保研究結果在詮釋與推廣時能更為謹慎。

1.3.1 研究範圍

本研究的範圍主要聚焦於 18 至 65 歲、具有 TOEIC 500 分以上英語能力的成年受試者，探討不同創意模式下的創造力表現。研究以 MRC 心理語言學資料庫中篩選出抽象與具象詞彙作為題材基礎，並藉由字詞聯想測驗（WAT）設計相應的實驗題目，評估受試者的創造力。實驗在受試者可獲得充足思考時間（每題四分鐘）及安靜環境下進。受測者將以英文作答，但允許在作答過程中使用翻譯工具協助填答；因此，研究端不再進行中英轉譯處理。總體而言，本研究從研究對象、題材選

取、實驗設計至數據處理各面向均加以明確界定。

1.3.2 研究限制

(一) 跨語言處理限制：由於 MRC 心理語言學資料庫主要收錄英文詞彙，且本研究要求受測者以英文作答，仍可能因受測者使用線上翻譯工具協助輸入而產生語義或文化脈絡的微小差異。

解決對策：

- 問卷設計階段直接呈現英文刺激詞，必要時附註簡短中文釋義，以降低誤解。
- 明確告知受測者可使用翻譯工具輔助理解與輸出，但最終答案需以英文提交。
- 在整理數據時，進行詞彙精簡與標準化處理（如移除贅字、停用詞等），確保輸入分析工具時詞形一致性。

(二) 實驗情境與時間限制：本研究主實驗將每題的作答設定為四分鐘，以期為受試者提供更充分的思考空間來應對抽象或複雜問題；然而，真實情境下的創造力表現仍可能受到多方因素的影響。

解決對策：

- 在研究設計中，將各題作答時間明確規範並統一控制為四分鐘，以降低時間限制對實驗結果造成的外部干擾。
- 要求所有受試者在進行實驗時必須選擇一個安靜且無外界噪音的場所，確保實驗環境的穩定性。

(三) 樣本代表性：本研究招募 18 - 65 歲且 TOEIC 500 分以上之成年受試者，並將人類組與 AI 協作組各設定 21 人。AI 協作組與生成式 AI 組所使用之模型皆為 OpenAI o4-mini high，該模型會持續更新，因此未來可透過相同實驗流程，比較不同版本或不同模型的創造力表現。設定 TOEIC 500 分門檻，因 SemDis 語義距離分析平台與 MRC 心理語言學資料庫均以英文語料為基礎，為避免中英語意落差並確保受試者能以英文作答。18 - 65 歲則涵蓋一般就業年齡層，亦為認知功能相對成熟且穩定之階段。由於每位受試者需進行 45 分鐘的英文

字詞聯想實驗，樣本收集相對困難；雖已放寬教育背景限制，樣本仍可能在英語能力與生成式 AI 使用經驗上集中，影響結果推論至其他族群之外部效度。

解決對策：

- 本研究僅招募 TOEIC 500 分以上、或就讀或畢業於應用外語相關科系的受試者，確保其能以英文充分理解題意並作答。
- 未來研究可採用相同方法驗證不同模型，強化結果的穩健性。
- 未來研究可進一步擴大樣本範圍，納入不同年齡層、不同生成式 AI 使用經驗以及多元教育背景的受試者，以驗證結果的普遍性與外部效度。

(四) 專家評分樣本限制：為控制專家評分的認知負荷與疲勞，本研究採用分層抽樣法，每位專家僅評估 300 個樣本，總計 1,800 個樣本進行專家評分。相較於語義距離分析涵蓋全部樣本，專家評分的樣本數量相對較少。

解決對策：

- 採用分層抽樣確保各組別與抽象程度的樣本比例均衡，維持樣本代表性。
- 透過 6 位專家的獨立評分降低個別專家主觀偏誤的影響。
- 未來研究可考慮增加專家人數或採用輪替評分機制，在控制疲勞效應的前提下擴大評分樣本。

(五) 刺激詞詞性控制限制：本研究僅依據 MRC 心理語言學資料庫的具象度指標篩選刺激詞，未能充分控制詞性變項（如名詞、動詞、形容詞等）對字詞聯想任務的潛在影響。不同詞性可能激發不同的聯想模式與創造力表現，此變項的未控制可能對研究結果造成混淆效應。

解決對策：

- 未來研究應在刺激詞篩選階段同時考量抽象度與詞性的平衡配置。
- 建議後續研究可專門探討詞性與抽象程度的交互作用對創造力表現的影響。

1.4 研究流程

首先界定研究目的、動機與研究問題，並透過文獻探討奠定研究基礎。接著，在研究方法與實驗設計階段，設計並檢核實驗流程與問卷，隨後進行實驗以蒐集正式數據。數據分析與研究結果章節中，運用統計方法整合與探討實驗資料，檢驗研究假設並解釋重要發現。最後於結論與建議部分，綜合研究成果，討論可能的限制與應用價值，並提出對後續研究及實務應用之建議，詳細流程圖如圖 1 所示。

圖 1
研究流程圖



註：本研究製作

二、文獻探討

本章聚焦於「創造力與創意思考」、「生成式 AI 與創造力」、「AI 協作與創造力」、「抽象概念與創造力」四個核心構面，系統性地分析相關文獻，為本研究奠定理論基礎與設計框架。

首先探討創造力的定義與創意思考的理論基礎，深入剖析發散性思考與收斂性思考的特性，並介紹字詞聯想測驗（WAT）與替代用途測驗（AUT）等創意發散方法。同時，本章節也詳細探討創造力量化方法，包括語義距離分析工具、專家共識評分法、流暢性計數。

接下來為生成式 AI 與創造力的關係，從大型語言模型（LLMs）的基礎架構出發，比較幾個主流模型 OpenAI o4mini-high、Gemini2.5 Pro、Grok 3 mini Reasoning high 在模型能力測驗分數上的表現差異，探討這些模型在創意任務中的表現，並比較生成式 AI 與人類在創造力表現上的差異與互補性。

再者，將深入探討 AI 協作的形式與機制，並分析其基本流程，以降低實驗中的變數。本部分特別聚焦於人機協作的互動模式，探討 AI 如何補足人類認知上的局限，並針對協作過程中可能遇到的挑戰提出相應的解決策略，從而為理解人機協作在創造力活動中的角色與價值提供理論支持。

最後，探討將著重於抽象概念對創造力表現的影響。此部分將闡述抽象與具象概念的定義及其差異，並進一步探討抽象概念如何影響人類與生成式 AI 在創造力任務中的表現，詳細介紹 MRC 心理語言學資料庫在量化問題抽象度中的應用。文獻探討透過這些面向的系統分析，建立以問題抽象度為基準的創造力評估理論基礎，為實驗設計提供明確的方向與理論支持，構成本研究的核心架構。

2.1 創造力與創意思考

本節將探討創造力與創意思考的基本概念及其評估方法，探討創造力的定義、主要影響構面（如原創性、變通性、流暢性、周全性等）以及促使創意產生的內外部因素，同時介紹發散性與收斂性思考的理論區分與應用。

最後，將說明如何透過語義距離分析、專家共識評分法與流暢性對創意表現進行量化，以建立一套客觀的創造力評估框架。

2.1.1 創造力定義與意涵

創造力(Creativity)通常指創造或產生新穎且有價值的思想、解決方案或產品。這一詞彙源自拉丁語 *creare*，意為「創造」或「製造」，與我們對創新和新思維的普遍理解相符。然而，創造力是一個多元的概念，其範疇非常廣泛，定義受多種因素影響，涵蓋多個層面。不同領域的研究者基於各自的背景與角度進行探討，導致對創造力的定義存在諸多不同詮釋(Runco & Charles, 1993) (Amabile, 1983)認為，創造力是一種能力，指個體在特定領域中創造新穎且有價值思想與解決方案的能力。此研究強調創造力的產生不僅依賴於智力，還與內在動機和情感因素密切相關。創造力是由動機、知識、技能以及工作環境等多種因素共同影響的結果。

與此相比，(Runco & Charles, 1993)將創造力視為一種「過程」，強調在解決問題時，通過獨特的思考方式產生新穎且有價值的結果。他認為，創造力不僅關乎新穎性，還包括有效性，即創造出的解決方案必須在特定情境中具備實用價值。

此外，(Guilford, 1950)提出，創造力是由心理特質和認知能力組成的。他將創造力分為多個構面，包括「流暢性」、「變通性」、「原創性」和「周全性」。

「流暢性」是指在單位時間內生成大量點子的能力；「變通性」是改變思考方向並從多角度解決問題的能力；「原創性」強調罕見或獨特但合乎邏輯的想法；「周全性」則是指能夠豐富完善想法補充細節並發展出完整方案的能力。他認為，創造力是多面向的，這些能力在不同創造性活動中可能以不同的模式組合呈現。

(Rhodes, 1961) 提出了創造力的「四個構面」(4P)，包括個人(Person)、過程(Process)、壓力或環境(Press/Place)和產品(Product)。個人指與創造力相關的屬性，如人格特質、智力和價值觀；過程則涵蓋創造力的心理活動，例如動機、學習和溝通；壓力描述個體與環境的交互作用，強調支持性或壓力性環境對創造力的影響。


Sternberg 和 Lubart (1998) 定義創造力為產生原創且適切的想法、解決方案或產品的能力。原創性是創造力的核心，代表著新穎性與獨特性，而「適切性」則確保這些成果在特定情境中具有實用性、價值或相關性。儘管原創性可能導致不合常規甚至怪異的結果，但結合適切性後，便能構成真正創造力的基礎，因為這樣的創造力既能解決問題，也符合特定情境的需求。

Mednick (1962) 認為，創造力是一種將聯想元素重新組合成新穎且實用的過程。這一過程依賴於將不同甚至遙遠領域的想法或元素結合在一起，並通過整合它們來創造出全新的事物。他提出「遠距離聯想」的概念，認為當結合的元素之間距離越遠，產生的解決方案便越具創造力。因此，創造力強調對現有知識和經驗進行重新組織與重組，以生成創新且有意義的結果。

創造力並非「無中生有」，而是一種「推陳出新」與「賦予存在」的過程。通過潛意識的釋放、深度思考的運作以及經驗的重組與整合，將現有事物進行「創新改良」與「組合」，最終形成新事物並提升其價值。(何佳勳, 2012) 同時，創造力的本質是多元且複雜的，隨著研究領域的不同而展現多樣性。儘管定義有所差異，研究者一致認為，創造力包含原創性、實用性、解決問題的能力，以及認知與情感層面的綜合表現，這些因素共同構成了創造力的完整面貌(蒲怡靜, 2003)。總之，各家創造力的定義雖然不同，但加以分析，可發現定義間的體用關係如圖 2 所示。

圖 2

各家創造力定義的體用關係



註：引自毛連塏、陳龍安（1989）。《創造力研究》。心理出版社。

2.1.2 創意思考方法

創意思考反映了個體的創造性潛能（Creative potential），即產生新穎且實用的事物的認知能力（Jauk 等, 2014; Runco & Jaeger, 2012）。在心理學領域，創造性認知研究主要從兩個方向展開：一是建立心理學理論框架來解析創造性思考，二是通過實驗觀察法考察人類推理過程中的認知機制（Sternberg & Lubart, 1996）。

（Guilford, 1950）作為創造性認知理論的先驅，在其智力結構論（Structure of Intellect Theory, SOI）中提出了六種思維運作方法，其中最具影響力的是發散性思考（divergent thinking）與收斂性思考（convergent thinking）。發散性思考強調基於已有信息產生多樣化的解答，允許多種可能的解決方案；而收斂性思考則偏重邏輯性的集中思考，針對特定問題尋求最優解。這兩種思考方式在創造過程中相互補充。特別值得注意的是，「發散性思考」與創造力的概念高度相關，以至於一度被視為創造力的同義詞（Francis Galton, 1879）（Acar 與 Runco - 2014 - Assessing

Associative Distance Among Ideas Elicited, 2014)。

(Wakefield,1992) 進一步指出，發散性思考蘊含了開放性答案與封閉性問題的特質，強調流暢力的重要性。與傾向依循既有經驗的收斂性思考相比，發散性思考的開放性特徵使其更容易形成可操作的定義，因此成為當前創造力研究的主要理論基礎。

自 1953 年 Osborn 提出腦力激盪法以來，創意思考方法已發展出超過 300 種不同的技術與方法。此因創意的概念，定義太廣，只要將一些不同的稍做組合就另成一種方法。以下為發散性、收斂性思考為主要分類方式與較知名創意方法做分類：

表 1

發散型思考與收斂思考方法對照表

	發散型思考	收斂型思考
特點	發散型思考強調創意生成可能解決問題的構想。	收斂型思考注重創意的篩選、歸納與最佳解決方案的形成。
常見方法	腦力激盪法 (BS) 替代性用途測驗 (AUT) 字詞聯想測驗 (WAT) 六頂思考帽 心智圖法 奔馳法	KJ 法 (親和圖法) 六 W 檢討法 分合法

註：本研究製作

以下內容以發散性思考方法為研究核心，因發散性思考與創造力高度相關(Acar 與 Runco - 2014 - *Assessing Associative Distance Among Ideas Elicited*.pdf, 2014)。以下將介紹三種主要的發散性思考方法：腦力激盪法 (BS)、替代用途測驗 (AUT) 以及字詞聯想測驗 (WAT)。

(一) 腦力激盪法 (BS)：

腦力激盪法 (Brainstorming)，亦稱為頭腦風暴法，是一種促進集體創意的技巧。其核心理念在於受測者運用自身腦力，圍繞特定議題展開創新思考並提出解決方案。過程中鼓勵在有限時間內集結眾智，激盪出大量的構想，旨在尋求新的想 (Valacich 等, 1994)。腦力激盪法被視為一種有效的創意思考手段，因它強調從潛意識中跳出想法，跳出原有的思考框架來進行發想，進而產生創新的想法。

根據過去的研究，最佳的群體規模為 5-7 人(Valacich 等, 1994)，在會議前，應將主題提前告知受測者，並使他們熟悉腦力激盪的流程。由引導者帶領團隊成員展開構思發展，將所有想法記錄下來，並確保所有構想對受測者可見，以激發團隊的創造力（陳天亮等, 2000）。在構思過程中，不對想法的可行性進行評估，腦力激盪法以團隊形式運作。以下為傳統腦力激盪四項原則，請參照表 2 所示。

表 2

傳統腦力激盪四項原則表

原則	解釋
延後批評	在討論的過程中，不對他人想法做出評價。
自由奔放	自由發想，不局限於框架，減少無用的對話。
點子越多越好	點子越多，得到好的點子可能性越高。
歸納與改進	鼓勵相互交流想法，且可以利用他人的構想來產生新點子。

註：引自何佳勳（2012）。建構-以 KJ 法為基礎之創意思考平台。國立台中科技大學，台中市。

(二) 替代用途測驗 (AUT)

替代用途測驗 (Alternative Uses Test, AUT) 最初由(Guilford, 1967)開發，是一種評估發散性思考能力的常用工具。在測驗中，受測者需要為日常物品（如鉛筆、磚塊或迴紋針等）產生盡可能多的替代用途。例如，磚塊可以用作書擋、門擋或園藝裝飾。這種測驗方法廣泛應用於創造力研究、認知評估、教育評量等多個領域（Acar & Runco , 2014）。

AUT 在不同領域有著廣泛的應用。在心理學研究中，它被用來評估個體的創造性思考能力和認知彈性。在教育領域，教師使用 AUT 評估學生的創造力發展並設計相應的教學策略。特別是在創造力研究領域，AUT 被用來測量發散性思維的四個關鍵維度：流暢性（產生想法的數量）、變通性（想法類別的多樣性）、原創性（想法的新穎程度）以及周全性（想法的詳細程度）(Guilford, 1967)。

替代用途測驗 (AUT) 的實施分為測試前準備、說明階段以及測試階段三個主要階段 (Koivisto & Grassini, 2023)。各階段的具象實施步驟如下：

- A. **測試前準備**：主試者需準備四個測試物品，包括繩子、盒子、鉛筆和蠟燭等日常物品，並架設測試介面，在物品名稱下方設置文字輸入框，供受試者填寫回答。
- B. **說明階段**：向受試者說明測驗重點在於創意的品質而非數量。測驗標準著重於想法是否具備聰明、不尋常、有趣、罕見、幽默、創新或與眾不同等特質。同時說明受試者可以提出不尋常或創新的想法，可以天馬行空，但應避免列舉物品的常見用途。
- C. **測試階段**：每個測試物品通常給予 3-5 分鐘的作答時間，受試者需在規定時間內提出盡可能多的替代用途。主試者應在測試過程中提醒剩餘時間。所有物品的測驗應在同一個測試階段中完成，以確保測驗的連續性和完整性。

(三) 字詞聯想測驗 (WAT)

字詞聯想測驗 (Word Association Test, WAT) 最初由 (Francis Galton, 1879) 提出，是心理學中歷史最悠久的測試方法之一。其目的是研究聯想能力，特別是受試者對「刺激詞」的即時反應過程，藉此探究創造性思考的運作機制(Gough, 1976)。WAT 的基本形式是由主試者給予受試者一個刺激字詞，要求受試者立即說出或寫下所聯想到的字詞 (林建諭, 2018)。Galton 在實驗中使用字詞聯想的方法進行心理測量，記錄自己看到 75 個詞彙的立即反應與反應時間 (林姿君, 2011)。WAT 通過測量受試者在聽到刺激詞後的聯想反應，揭示了聯想的流暢性、變通性與原創性，進而評估創造力。該方法特別適合研究創造性思維中關於聯想距離 (semantic distance) 與非典型聯想 (remote associations) 的關係，已被廣泛應用於心理診斷、人格特質評估、創造力研究、教育評量等多個領域。

字詞聯想測驗 (Word Association Test WAT) 在不同領域的應用相當廣泛。在心理診斷領域，(Rothenberg, 1973, Jung 1919) 將其用於診斷精神病患的病因，探索人的潛意識中的情結。在教育領域，Kostov (2008) 應用於研究學習者的概念結構，通過自由聯想測試調查教師和學生的概念連結。在創造力研究領域，研究發

現高創造力者傾向於產生更多獨特且迅速的對立性反應（opposites），這種能力被稱為"Janusian thinking"，反映了同時掌握對立概念的創造性思考特徵（Rothenberg, 1973）。值得注意的是，非典型的聯想反應本身並不足以代表創造力，創造力更多地體現在聯想的適切性與靈活性上。


字詞聯想測驗（Word Association Test, WAT）的操作流程主要分為「刺激輸入」、「分類處理」與「反應產生」三個階段。在測驗前，施測者需先準備刺激詞清單及計時工具，並向受試者說明測驗目的與回答方式。

在實施階段，過程可分為三個主要步驟（林建諭,2018）：

- A. **刺激輸入**：施測者呈現刺激詞，受試者在短時間內接收該刺激。
- B. **分類處理**：受試者將接收到的刺激詞暫存於短期記憶中，並根據個人的記憶模組進行分類。
- C. **反應產生**：受試者根據個人特質、社會期許及當下心理狀態等因素，從眾多可能的反應中進行篩選，最後產生聯想詞。

圖 3

字詞聯想測驗（WAT）操作流程圖



註：本研究製作

2.1.3 創造力量化

創造力量化評估長期以來是研究者關注核心議題，其特性為量化帶來重大挑戰。創造力不僅需要展現新穎性與變通性，還須具備適切性與價值。研究者們發展出多種評估方法，本研究將聚焦於語義距離分析、專家共識評分法與流暢性分析這些量化方法，並透過整合三種評分方式的結果，建立更客觀的創造力評估指標（Hocevar & Bachelor, 1989）。創造力評量的方式繁多，將其歸納成以下幾個主要類別：

表 3

創造力評量方式表

評分方法	說明
(一) 發散性思考測驗	根據 Guilford 的智力結構論中發散性思考理念編製，如陶倫斯創造思考測驗，可測量流暢性、變通性、原創性和周全性。
(二) 態度與興趣量表	評量個人興趣傾向和態度中的創造力，如 Williams 創造性傾向量表，評量冒險、好奇、想像、挑戰等特質程度。
(三) 人格特質量表	評量與創造力相關的人格特質，如接受新經驗程度、對模糊情境的容忍度。
(四) 傳記量表	透過了解個人過去經歷、家庭和學校環境來衡量創造力。
(五) 教師、同儕和指導者的評定	透過教師、同儕或指導者的觀察資料評定個體的創造傾向或創造力，如 Williams 的「創造性評定量表」，評估八種創造行為（流暢性、變通性、原創性、周全性、冒險性、好奇心、想像力、挑戰性）。
(六) 以傑出人士為楷模	以研究傑出人士特質作為創造力量測指標，但因僅針對少數傑出人士，與創造力普遍性觀點相悖，應用上需審慎考量。（林幸台，2000）。
(七) 自陳式創造性活動與成就	依據個人陳述曾經從事的活動與成就加以評斷其創造力，例如曾獲得專利權、公開展出個人作品等。
(八) 專家共識評分	透過專家或相關領域人士對個人作品或表現進行評分，依據預設的評分標準（如原創性、適切性、變通性等）進行評估。

(九) 語義距離分析

運用自然語言處理技術，分析創意產出與概念的語義差異程度。通過計算詞彙或概念間的語義距離，量化詞彙的遠近程度，為創造力提供客觀指標。語義距離越大，通常代表思維越能跳脫常規，創造力表現越高。

註：本研究製作

本研究將聚焦於語義距離分析、專家共識評分法與流暢性分析這三種量化方法，並整合其結果進行分析，下文將針對這三種方法進行重點說明。

(一) 語義距離分析 (Semantic Distance Analysis)


語義距離分析是一種基於自然語言處理的創造力量化方法。語義距離的概念源自(Collins & Loftus, 1975)提出的語義記憶擴散啟動理論 (Spreading Activation Theory)。根據此理論，概念在記憶中以網絡結構儲存，概念之間的連結強度取決於其語義特徵的重疊程度。當一個概念被啟動時，啟動會擴散至相鄰的概念節點，而這種啟動會隨著概念間距離的增加而衰減。語義距離即反映了概念之間在此語義網絡中的路徑長度，較短的路徑代表概念關係較密切，較長的路徑則表示概念關係較遠。

計算語義距離的早期方法使用潛在語義分析(Landauer, 1999)，通過計算詞彙在大型文本語料庫中的共現頻率來量化語義相關性。近年來發展的方法包括全域向量表示 GloVe(Pennington 等, 2014)以及連續詞袋模型 CBOW(Mikolov 等, 2013)等神經網絡架構，這些方法在預測人類語義相似性判斷方面表現更佳。在處理多詞回答時，(Mitchell & Lapata, 2010)發現乘法組合模型相較於加法模型能更準確地反映人類對語義相關性的判斷，這一發現對改善創造力評估的精確度具有重要意義。

在神經科學研究中，(Liu 等, 2021)發現語義聯想能力與左後側顳下回(LpITG)的灰質體積呈現顯著正相關。這個區域不僅涉及視覺詞彙處理、語義整合和語義記憶，還與發散性思考和創造力特質相關。研究表明，LpITG 區域的灰質體積較大的個體往往展現出更強的語義聯想能力，這反映在他們能夠更有效地連結遠距離的概念並產生新穎創意。

圖 4

鏈狀自由聯想 (CFA) 語義距離正相關的大腦區域圖



註：引自 Liu, C., Ren, Z., Zhuang, K., He, L., Yan, T., Zeng, R., & Qiu, J. (2021).

Semantic association ability mediates the relationship between brain structure and human creativity. *Neuropsychologia*, 151, 107722.

語義距離的數值範圍依比較對象而定，在 SemDis 自動創造力評估系統中比較兩個詞彙時，數值範圍為 0 到 1；當比較詞彙與片語或片語之間時，數值範圍為 0 到 2。其中 0 表示概念完全相同或最密切相關，數值越高則代表概念間關係越遠。在實際應用中，較高的語義距離值表示兩個概念的關係越遠，創造力越高。(Kenett, 2019) 的研究進一步指出，量化的語義距離測量不僅能提供創造力表現的客觀指標，還能更直接地檢驗語義記憶結構在創造思考中的作用。

在創造力測量面向上，語義距離分析主要針對創造力的特定維度進行評估。根據研究證實，語義距離最適合測量原創性和變通性，這是因為語義距離的核心概念即是測量想法與常見概念之間的距離，距離越遠代表越原創與跳遠(Heinen & Johnson, 2018; Prabhakaran 等, 2014)。此外，語義距離在測量適切性方面也展現一定效度，(Heinen & Johnson, 2018)發現語義距離與人類對創意回答的適切性評分呈現正相關。在變通性的測量上，Johnson 等人 (2021)證實語義距離可通過評估想法多樣性來間接反映變通性。然而，語義距離並不適合測量流暢，因為其關注的是想法品質而非數量。

基於這個理論基礎，(Beaty & Johnson, 2021) 開發了 SemDis 自動創造力評估系統，該系統整合了五種語義模型 (GloVe、TASA-LSA、三種 CBOW 模型)，使用潛在變數建模來提取多個語義距離指標的共同變異數，以減少任何單一文本語料庫的偏差影響。該研究通過五項研究證明，潛在語義距離因子能可靠且強力地預測人類在替代用途測驗和字詞聯想任務上的創造力評分。此方法的優勢在於其客觀性與可複製性。為了更清楚地理解語義距離的概念，我們可以參考(Collins & Loftus, 1975)提出的經典語義記憶結構認知模型示意圖（如圖 5 所示）此圖展示了三個重要部分：


(a) 以"紅色"為核心概念的理論示例，周圍的概念基於語意特徵的重疊程度進行組織連結，形成一個完整的概念網絡。

(b) "紅色"概念及其直接相關概念的連結關係。

(c) 基於潛在語義分析 (Latent Semantic Analysis, LSA) 計算的語意距離分數，顯示了"紅色"與其部分直接相連概念之間的語意距離值。例如，紅色與火的語意距離為 0.85（關係較遠），與黃色的語意距離為 0.26（關係較近），這些數值具象反映了不同概念之間關聯程度的差異。

圖 5

語義記憶結構認知模型圖



註：引自 Collins, A. M., & Loftus, E. F. (1975). A spreading-activation theory of semantic processing. *Psychological Review*, 82 (6), 407–428.

在創造力研究中，語義距離分析已被廣泛應用於多種評估場景。研究指出，當受試者被要求「具有創意地思考」時，其產生的語義距離顯著高於未接受此指示的控制組（Prabhakaran 等, 2014）。這種差異不僅反映了指令對創造力表現的影響，也驗證了語義距離作為創造力指標的有效性。更重要的是，個人在創意任務中的語義距離表現，與其他創造力任務（例如字詞聯想測驗、創意寫作任務表現、自我回報的藝術與科學創造成就）呈現顯著相關性。（Hass, 2017）的開創性研究通過語義距離追蹤發散性思考的動態過程，證明了語義距離在檢驗發散性思考方面的可行性，為該方法的理論應用提供了重要支持。（Heinen & Johnson, 2018）進一步驗證了語義距離分析於詞語聯想任務中的效度，發現語義距離反映創造力中的原創性與

變通性，且與人類主觀創造力評分呈現正相關，驗證其作為創造力客觀測量指標的有效性。

然而，語義距離分析也面臨一些技術性挑戰。(Forthmann 等, 2019) 指出，在替代用途測驗 (Alternative Uses Test) 中，使用加法組合模型時，詞彙的細節程度會對語義距離計算產生負面影響，較長的回答會導致較低的語義距離分數，這與人類評分者給予較長回答更高創造力分數的模式相矛盾。然而，使用乘法組合模型能夠逆轉這種關係，使得更精細的回答獲得更高的語義距離分數，與人類評分模式一致。此外，研究建議在計算前移除停用詞 (例如 the、an、but) 以改善效度。這項發現反映出，在應用語義距離分析時，需要謹慎考量多種影響因素，並採取適當的資料前處理策略。特別是在評估較長句子或段落的創造力時，這些技術細節的處理變得更為重要。

儘管面臨挑戰，語義距離分析為創造力研究提供了重要的客觀量化工具。此方法不僅能自動化評估創意力的原創性、變通性，在適切性和變通性的測量上也具備一定效度，但並不適用於流暢性和周全性的評估。語義距離分析能夠揭示創造性思考過程，有效輔助傳統的創造力評估方法。

(二) 專家共識評分法

專家共識評分法 (Consensual Assessment Technique, CAT) 由 Amabile(1982) 提出，是一種基於領域專家判斷的評估方法。這種評估技術建立在一個基本前提上：某個產品或反應的創造力程度，取決於相關領域的適當觀察者是否一致認為它具有創造力 (Hennessey & Amabile, 2010)。在實施過程中，通常邀請 3-6 位相關領域的專家，使用預設的評分標準 (通常是 1-5 分量表) 對創意成果進行獨立評分。評分維度可能包括原創性、變通性、周全性、適切性等面向。為確保評分的客觀，評分者需獨立完成評分，不得相互討論或受實驗者訓練。這種方法的優勢在於能結合專業判斷，評估創意成果的價值。

在專家選擇方面，(Silvia 等, 2008) 建議創造力評分的專家應具備相關領域知識

與實務經驗，並強調專家背景的多元化對評分品質的重要性，專家的專業領域分布應能涵蓋創造力評估的不同面向，以確保評分的全面性與客觀性。一般而言，專家人數建議在 3-10 人之間，既能確保評分的可靠性，又能避免過多評分者造成的協調困難(Hennessey & Amabile, 2010)。

在評分流程設計上，標準化培訓是確保評分品質的關鍵步驟。(Cseh & Jeffries, 2019)的研究指出，有效的專家培訓應包含：評分目的說明、評分標準詳細解釋、範例示範與練習、以及評分一致性的重要性強調。培訓時間通常控制在 30-60 分鐘，既能確保專家充分理解評分標準，又能避免過度培訓可能造成的評分僵化(Hennessey & Amabile, 2010)。

(Koivisto & Grassini, 2023) 在探討人工智慧與人類創造力差異時，提出了一種改良的主觀評分方法。他們邀請 6 位經過簡單訓練的評分者，採用 5 分量表(1=完全不具創造力，5=非常具創造力)對回答進行評分。為避免偏見，評分者並不知道部分回答來自 AI。評分標準特別強調新穎性而非實用性，並明確指示對常見回答(如針對剪刀回答"切割")應給予低分，對不合邏輯的回答同樣給予 1 分。為確保評分的可靠性，每位評分者以不同的隨機順序評估作品，最終分數取 6 位評分者的平均值。

本研究在上述方法的基礎上，延伸適用於字詞聯想測驗(WAT)的專家共識評分。研究邀請 6 位專家評分者，採用 5 點量表評估目標詞與聯想詞之間連結的創造性。評分標準強調聯想的原創性、變通性、周全性、適切性(實用且有價值)，評分標準如下表 4 所示：

表 4

專家共識評分標準表

分數	評分標準
1 分	缺乏原創性、變通性與周全性，且可能不具適切性的聯想
2 分	具有基本原創性但缺乏變通性，僅有簡單描述且適切性有限
3 分	稍具新意，中等程度的跨域思考，基本描述合理且適切
4 分	罕見且富有意義，具有跨域，描述豐富且適切
5 分	極為罕見且高度跨域與多角度思考，故事化描述豐富並高度適切

註：本研究製作

(三) 流暢性分析 (Fluency Analysis)

流暢性指的是個體在受限時間內產出大量「相關且有效」想法的能力，屬於發散性思考最直接的量化指標(Guilford, 1967)。本研究採用字詞聯想測驗(WAT)作為施測工具，依循 Torrance 等人 (1974)與(Silvia 等, 2008)的操作化方式，統計每題在固定時限內去除重複與無關回應後的有效反應總數；為排除書寫速度差異的混淆，並同步計算「每分鐘平均反應數」作為修正分數。過往研究顯示，流暢性具有良好的重測信度 ($r \approx .80$) 及評分者一致性 ($ICC > .85$) ((Silvia 等, 2008)，本研究著重於創造力各構面的獨立效應，特別將流暢性與語義距離、專家評分並列為核心結果變項，分別以線性混合模型檢視其在不同問題條件下的效應與交互作用。此獨立分析策略使流暢性能充分呈現受試者「點子生成速度」的個體差異，同時保留語義距離與專家評分的解釋力。

2.1.4 章節小結

在眾多創造力評估方式中，本研究將語義距離、專家共識評分法與流暢性分析列為三大評估指標；其中，語義距離與流暢性分析提供客觀量化基準，專家共識評分則補充主觀專業判斷。專家共識評分法涵蓋原創性、變通性、周全性與適切性四個維度，能夠全面評估創意的綜合品質，強調領域知識與實際脈絡的判斷力，深入洞察創意在其應用環境中的價值與適切性。

語義距離分析則專門聚焦於原創性與變通性兩個面向，運用自然語言處理技術客觀量化概念之間的遠近程度，凸顯想法跳脫常規的程度。雖然語義距離分析無法涵蓋創造力的所有維度，但其提供可重複檢驗的量化指標，能夠補強專家評分在原創性與變通性測量上的客觀性。

流暢性分析則著眼於「點子生成速度與數量」，透過統計固定時限內的有效反應數與平均反應數，直接呈現受試者在發散思考階段的產出能力。大量研究指出，流暢性具備高重測信度與跨任務一致性，是衡量創造潛能不可或缺的一環。

三項指標相互補充，流暢性捕捉「量」、語義距離揭示「跳躍幅度」、專家評分評定「價值與適切性」。透過此兼具客觀與主觀的整合架構，本研究得以多角度描繪創造力表現，並為後續統計分析與實務應用奠定堅實基礎。



2.2 生成式 AI 與創造力

生成式 AI 涵蓋文字、圖像、音樂等多模態形式，本研究將專注於文本生成領域，特別是大型語言模型的創造力潛能。首先介紹大型語言模型的基礎架構與核心原理，建立對這類 AI 系統的基礎認知；其次分析大型語言模型在創造力方面的獨特特徵，包括其在組合性、探索性及轉型性創造力等面向的表現。接著深入比較大型語言模型與人類在創造力方面的異同，探討兩者創意發想上的優勢與限制，為後續 AI 協作模式的討論奠定基礎。最後，本章對目前主流的大型語言模型（如 OpenAI-o4mini high、Gemini 2.5 PRO、Grok 3mini Reasoning high 等）進行效能表現的系統性比較，以了解不同模型在文本創意任務中的特點與應用潛力。

2.2.1 大型語言模型概述（LLMs）

大型語言模型（Large Language Models, LLMs）是一種基於深度學習的人工智慧系統，透過大量文本數據的訓練，能夠理解、生成和處理人類語言。這類模型在近年來取得重大突破，不僅在自然語言處理任務上展現出優異表現，更在創造力相關任務中顯示出驚人潛力（Xue, 2024）。本節將從模型架構、發展歷程、運作原理三個面向，介紹大型語言模型的基本概念。

在模型架構方面，現代大型語言模型主要採用 Transformer 架構，這是一種基於自注意力機制（Self-attention）的神經網絡結構（Xu 等, 2023）。與早期的循環神經網絡（RNN）相比，Transformer 能更有效地處理長序列文本，捕捉文本中的長距離依賴關係。這種架構使模型能夠更好地理解上下文語境，產生連貫且符合語境的文本內容。

從發展歷程來看，大型語言模型的演進可追溯至 2017 年 Google 提出的 Transformer 架構。隨後，OpenAI 於 2018 年提出 GPT（Generative Pre-trained Transformer）系列模型，開創了大規模預訓練語言模型的新紀元（Carolan 等, 2024）。2022 年 ChatGPT 的發布更是掀起了生成式 AI 的革命，展現出前所未有的自然語

言理解與生成能力。目前，OpenAI、Grok、Gemini 等模型進一步擴展了大型語言模型的應用範疇，特別是在創造性任務方面取得顯著進展(Zhou 等, 2024)。

在運作原理上，大型語言模型主要通過兩個階段實現其功能為預訓練（Pre-training）和微調（Fine-tuning）。在預訓練階段，模型通過處理大量的文本數據，學習語言的基本規則和知識(Lu 等,2024)。這個過程使模型能夠理解詞彙關係、語法結構和上下文語境。在微調階段，模型針對特定任務進行最佳化，提升在特定領域的表現（Christophe 等, 2024）。

大型語言模型在處理不同語言時展現出明顯的差異性。相較於英文，中文的語言特性（如字形結構複雜、詞義模糊、語境依賴性強等）為模型帶來獨特的挑戰。研究顯示，在英文提問中，大型語言模型通常能產生更精確和連貫的回應，這可能是由於訓練數據中英文資料的比例較高，且英文的語法結構相對規律所致（Li 等, 2023）。相較之下，在處理中文提問時，模型可能需要更多上下文資訊來準確理解提問意圖，且在專業術語翻譯和文化特定表達方面存在一定局限。然而，隨著中文訓練數據的增加和模型架構的改進，這種差距正逐漸縮小，特別是在近期發布的模型中，中文生成能力已有顯著提升。大型語言模型的核心優勢在於其強大的模式識別和知識綜合能力。通過在大量數據中學習，這些模型能夠識別複雜的語言模式，理解深層語義關係，並運用這些知識生成新的內容。這種能力不僅體現在基本的語言理解和生成任務上，更延伸至創造性寫作、概念聯想等需要創造力的領域。然而，值得注意的是，大型語言模型也存在一些固有限制，如可能產生偏見、難以理解因果關係、缺乏真實世界經驗等。

在創造力應用方面，大型語言模型展現出獨特的優勢。它們能夠快速產生多樣化的想法，結合不同領域的知識進行創新，並協助人類進行創意發想(Choudhary, 2024)。這種能力使其成為潛在的創意協作工具，能夠輔助人類在創造性任務中取得更好的表現。然而，如何最大化這些模型的創造力潛能，同時避免其局限性，是當前研究的重要課題。

2.2.2 生成式 AI 的創造力特徵

根據 (Boden,1998)的理論，創造力可被區分為三種類型：組合性創造力 (Combinational Creativity)、探索性創造力 (Exploratory Creativity) 與轉型性創造力 (Transformational Creativity)。在生成式人工智慧 (Generative AI) 領域，這三種類型也有明顯的體現。近年的研究將此分類框架應用於生成式人工智慧領域，指出 AI 的創造力可依其生成過程與輸出特徵對應到這三種類型。(Boden, 2009; Franceschelli & Musolesi, 2025)

(一) 組合性創造力 (Combinational Creativity)

組合性創造力是指 AI 結合現有的概念生成新內容。例如語言方面的類比式或幽默式生成，抑或是經常應用於詩歌創作、故事結構建議的文字創造。生成式 AI 的此類創造過程雖能呈現多元面向，但因其主要基於數據驅動與模式學習，對情感深度與文化意義的詮釋仍需進一步探討 (Boden, 2009; Franceschelli & Musolesi, 2025) 指出，大型語言模型 (LLMs) 主要依賴給定的數據分佈進行訓練，因此最能表達組合性與探索性創造力。

(二) 探索性創造力 (Exploratory Creativity)

探索性創造力是 AI 在既定的「概念空間」中進行探索或嘗試，利用既有規則或框架的不斷組合、變化，來找出未曾嘗試過的可能性 (Boden, 1998)，例如模仿莫札特風格或古典樂風格進行音樂生成，或透過 GPT、DALL-E 等模型在文字與圖像生成中展現多重風格與變化。此種方式讓 AI 在探索性創造方面顯現出高速且多樣的生成優勢。然而，其內容品質仍仰賴系統對大規模資料的演算與優化，有時也會出現風格混雜或不符合語境的狀況。

(三) 轉型性創造力 (Transformational Creativity)

轉型性創造力指 AI 能夠「改變概念空間的結構」，創造出全新的框架。這類創造力需要 AI 重新定義概念的邏輯關係，是所有創造力類型中最具挑戰性的部分 (Boden, 2009; Franceschelli & Musolesi, 2025)。目前，多數生成式 AI 依賴於既有數

據空間的「探索」與「組合」，要真正實現其轉型潛力仍在早期階段。

然而，目前大多數生成式 AI 的運作仍主要依賴訓練數據與既定規則，真正能夠「轉型」概念結構的模型相對有限，仍處於初步嘗試階段。

雖然生成式 AI 是否真能「擁有」創造力在哲學與心理學層面尚存爭議，但其輸出已部分符合多數研究者對創造力的 operational definition——如原創性 (novelty)、適切性 (appropriateness) 或價值性 (value) (Sternberg & Lubart, 1998)。例如，在文字領域，大型語言模型能快速生成具有邏輯連貫度且多樣化的內容，展現一定程度的「新穎性」；在圖像與音樂方面，Diffusion Models 或 GANs 也能運用大量資料產出罕見或獨特的圖形 (Haase & Hanel, 2023)。然而，必須強調的是，這些新穎性往往是透過對既有資訊的重組與模擬而來，缺乏人類創造力中常見的情感動機與自我覺知 (Giannuzzo, 2023)。也就是說，AI 雖能在外顯產出上與人類創作相似，卻不一定真正擁有能動的「意圖」或「情感」來引導創新，但其快速產生多元想法的能力，仍使其在「組合性」與「探索性」創造力兩面向展現巨大優勢。

2.2.3 主流大型語言模型的創造力比較與應用

當前的人工智慧性能指標常依據品質、速度與價格等面向來評估大型語言模型，本研究同樣參考 Artificial Analysis 網站所提供的相關指標 (Artificial Analysis, 2025)。然而，由於本研究聚焦於創造力的探討，因此特別關注該網站的 Artificial Analysis Intelligence Index。該指標由 MMLU-PRO、GPQA DIAMOND、HUMANITY'S LAST EXAM、LIVECODEBENCH、SCICODE、HUMANEVAL、MATH-500 以及 AIME 2024 八大測試構成 (Artificial Analysis, 2025)。這些測試分別從不同維度評估模型的核心能力：MMLU-PRO 透過高難度多選題，評估模型跨學科的知識深度 (Wang 等, 2024)；GPQA DIAMOND 藉由研究生級的科學難題，測試其深度推理能力，該測試包含 198 道經過專家驗證的生物、物理與化學問題，設計為「防谷歌」型題目，即使具備博士學位的專家也僅能達到 65-74% 的正確率

(Epoch AI, 2024; Rein 等, 2023)；HUMANITY'S LAST EXAM 則透過廣泛且艱深的多模態問題，探索模型知識的邊界，該測試由 Center for AI Safety 與 Scale AI 共同開發，包含 2,500 道涵蓋數學、人文與自然科學的專家級問題(Phan 等, 2025; Scale AI & CAIS, 2025)。在程式設計方面，LIVECODEBENCH 全面地檢視程式碼生成、修復與執行的綜合能力，該平台持續收集來自 LeetCode、AtCoder 與 CodeForces 的最新競程問題，以防止數據污染(Jain 等, 2024)；SCICODE 著重於生成程式碼以解決真實科學研究問題，包含 338 個源自實際研究工作流程的科學計算子問題，涵蓋物理、數學、材料科學、生物與化學等 6 大領域(Tian 等, 2024)；而 HUMANEVAL 專注於評估生成程式碼的功能是否正確，採用 Pass@1 指標測量模型在首次嘗試中的程式碼正確性(Chen 等, 2021)。數學能力則由 MATH-500 的高中多步驟推理題與 AIME 2024 的高階競賽題來衡量，其中 MATH-500 為 OpenAI 從 Hendrycks 2021 年 MATH 數據集中隨機抽取的 500 道題目子集，而 AIME 2024 則來自美國數學邀請賽，專門測試高中數學頂尖學生的能力(Artificial Analysis, 2025; OpenAI, 2024)。這些測試共同提供了模型在知識廣度、推理深度與專業應用（特別是程式設計與數學）層面上的客觀評估。本研究基於實驗應用需求與模型的市場代表性，選擇了 OpenAI o4mini high、Gemini 2.5 Pro 與 Grok 3 mini Reasoning(high)四種大型語言模型作為比較對象，並藉由參考上述 Artificial Analysis Intelligence Index 指標，篩選出最能呼應本研主題需求的模型，為後續的實驗設計與分析奠定基礎。儘管這些指標未能直接衡量創造力，Artificial Analysis Intelligence Index 在評估模型基礎知識理解與推理能力方面仍具相當參考價值，能為本研究提供篩選依據。

表 5


主流模型性能指標對照表

排名	1	2	3
模型名稱	OpenAI o4-mini(high)	Gemini 2.5 Pro	Grok 3 mini Reasoning (high)
Artificial Analysis Intelligence Index	70	69	67
MMLU-PRO	83	86	83
GPQA DIAMOND	78	84	79
HUMANITY’S LAST EXAM	18	17	11
LIVECODEBENCH	80	78	70
SCICODE	47	40	41
HUMANEVAL	99	99	98
MATH-500	99	98	99
AIME 2024	94	87	93

註：引自 Artificial Analysis 網址: <https://artificialanalysis.ai/>

圖 6

主流模型 Artificial Analysis Intelligence Index 長條圖



註：引自 Artificial Analysis 網址: <https://artificialanalysis.ai/>

(一) OpenAI-o4 mini high

根據 Artificial Analysis 基準測試結果，OpenAI o4-mini high 在綜合指標 Artificial Analysis Intelligence Index 獲得 70 分，並於 MMLU-Pro、GPQA Diamond 與 MATH-500 分別獲得 83%、78%與 99%的高分，在 Humanity's Last Exam 亦達 18%，顯示其在廣域知識覆蓋、精確邏輯推理及數學推理等面向均位居同級模型前列，且在常識推理題型維持穩定水準。雖然上述量化指標並非直接衡量「創造力」，高品質的知識推理與準確的問題解決能力正是創意應用的關鍵，能促使模型生成多元且語境貼切的聯想詞彙。o4-mini high 為 GPT-4 架構的輕量化版本，兼具高速推論與低資源需求，在保留 GPT-4 級推理與程式生成優勢的同時，可降低實驗成本並提升重複測量一致性。(DataCamp, 2025)此外，ChatGPT 目前擁有全球逾四億活躍用戶，為最廣為人知的語言模型服務，受測者對其介面與回應風格高度熟悉，有助於減少操作偏差並增進外部效度。綜合性能、可用性與研究控制需求，本研究選擇 o4-mini high 作為主要測試模型，以確保實驗結果的可比性與信效度。(Aitechtonic, 2025)

(二) Gemini 2.5 Pro

Gemini 2.5 Pro 在本次評測中獲得 Artificial Analysis Intelligence Index 為 69 分，在 MMLU-Pro 達 (86%)，GPQA Diamond (84%)，MATH-500 (98%)，Humanity's Last Exam (17%)，綜合反映其在知識廣度、科學推理與構思上的領先地位(Gemini 2.5 Pro, 2025; Artificial Analysis, 2025)。Gemini 2.5 Pro 在多項基準測試中展現出色的深度推理與結構化問題解決能力，這些特質對於技術型創意生成（如複雜程式設計）尤為關鍵。整體而言，Gemini 2.5 Pro 與 OpenAI o4mini high 在推理與生成效能上旗鼓相當：前者於 GPQA 與 MMLU-Pro 的領先，顯示其專業知識深度與跨域整合能力；後者則在 LiveCodeBench 與 AIME 等程式與數學評測小幅優勝，顯示其結構化推理與演繹穩定度更高。鑑於字詞聯想任務需兼顧廣域知識與一致邏輯推理，且研究受測者對 ChatGPT 介面更為熟悉，本研究最終選用 OpenAI o4mini

high 作為單一測驗模型。

(三) Grok 3 mini Reasoning high

Artificial Analysis 基準測試，Grok 3 mini Reasoning high 的 Intelligence Index 為 67 分，在 MMLU-Pro (83%)、GPQA Diamond (79%) 與 MATH-500 (99%) 均展現與 OpenAI o4-mini (high) 旗鼓相當的推理計算實力 (Artificial Analysis, 2025)，但於 Humanity's Last Exam 僅得 11%，顯示其在開放式常識推理仍有進步空間。作為 xAI 將 Grok-3 架構精簡後的推理優化版本，該模型採「先思考後作答」流程以強化演繹穩定度，並因參數量縮減而在成本與速度上具備優勢。GPQA 與 MMLU 的成績意味它能調用跨領域知識作為聯想素材，而數學與程式測試的頂尖表現則為技術導向創意任務提供可靠邏輯支撐。然而，相較於使用者已高度熟悉的 ChatGPT，Grok 平台仍屬新興，其介面與回應風格的學習曲線較陡，加之常識推理能力較弱，可能為本研究帶來額外變因。綜合推理穩定性、使用便利性與外部效度等考量，本研究仍選擇性能略占優勢且受測者熟練度更高的 OpenAI o4-mini high 為測驗模型。

2.2.4 章節小結

綜合三款候選模型之比較結果，OpenAI o4mini high 以 Artificial Analysis Intelligence Index 70 分為三款中綜合最高分，並在 MATH-500 與 LiveCodeBench 等結構化推理評測保持領先，且於常識推理與跨領域問答亦維持穩定水準；Gemini 2.5 Pro 雖在 GPQA 與 MMLU-Pro 略勝一籌，展現深厚專業知識與概念整合潛力，但於程式與競賽數學評測稍遜；Grok 3 mini Reasoning high 則因常識推理表現較弱，且使用者對其介面尚不熟悉，仍存在外部效度與操作負荷的疑慮。考量本研究既需廣域知識涵蓋，又受提問次數與實驗成本限制，o4-mini high 在效能、可用性與成本控制之間展現最佳平衡，故被選為字詞聯想創造力測驗的核心模型。

2.3 AI 人機協作與創造力

本節將深入探討 AI 人機協作的理論基礎與實務應用，首先釐清 AI 協作模式的定義與核心原則，並說明「以人為本的人工智慧」理念如何指導有效的協作設計；接著分析標準化協作流程，包括提示工程與「需求→生成→回饋→再生成」的動態循環機制。其次，比較生成式 AI 與人類創造力在動機來源、情感投入與原創突破等面向的差異與互補性，透過實證研究驗證雙方的相對優勢。最後，本研究基於上述理論基礎，提出分階段協作模式的設計，將獨立思考與 AI 協作階段結合，使 AI 在提供多元素材的同時，保留並強化人類在創意與倫理決策上的主導地位。

2.3.1 AI 協作模式定義

AI 協作模式 (AI Collaboration Mode) 是指人類與人工智慧系統在特定任務情境下，透過互補的角色分工與資訊交換，共同完成從問題定義、想法產出到成果驗證的一系列流程。根據(Kolbjørnsrud, 2023)的組織智慧理論，有效的人機協作需要遵循六個核心原則：互補性 (addition)、相關性 (relevance)、替代性 (substitution)、多樣性 (diversity)、協作性 (collaboration) 以及可解釋性 (explanation)。

近期研究表明，人機協作已超越傳統的任務分配模式，演進為動態且互適性的協作關係。(Berretta 等, 2023)將人機協作團隊定義為：「一個或多個人類與一個或多個（部分）自主 AI 系統作為團隊成員，具有獨特且互補的能力，朝向共同目標協同工作的過程。團隊成員的角色在協作過程中動態調整，需要協調和相互溝通以滿足彼此和任務的需求。」

(一) 以人為本的 AI 協作理念

從 HCAI (Human-Centered AI，以人為本的人工智慧) 觀點來看，AI 的最佳應用應聚焦於輔助人類創意過程，而非取而代之(Shneiderman, 2022)。這種協作模式強調人類作為主導者，設定方向與目標，AI 則充當「助手角色」，負責生成大量可能的選項，最後由人類進行篩選與評估。此設計確保人類在創意過程中保持主

體性與獨特性，同時充分發揮 AI 的快速運算與內容生成能力，從而提升創意產出的效率與品質。Shneiderman 進一步強調，人類應保持對創意過程的主導權，避免過度依賴 AI 而削弱自主思考能力。(Dell'Acqua 等, 2023)的研究也發現，當任務超出 AI 能力邊界時，過度依賴 AI 反而會導致 13-24 個百分點的性能下降。

在大型語言模型 (LLMs) 日趨成熟的背景下，協作模式的核心並非單純「讓 AI 自動化處理」，而是強調「人機並行討論與動態調整」。哈佛商學院與波士頓諮詢集團的聯合研究(Dell'Acqua 等, 2023)識別出兩種成功的協作模式：「人馬座模式」(Centaur) 將任務在人類和 AI 之間明確分工；「賽博格模式」(Cyborgs) 實現人類-AI 工作流程的完全整合。這項涉及 758 名顧問的實驗顯示，AI 協作可提高任務完成率 12.2%，縮短完成時間 25.1%。

(二) 標準化協作流程

以大型語言模型為基礎的協作流程，通常包含以下標準化階段：首先，使用者需明確定義目標或問題範圍，並向 LLM 提供清晰的敘述或提示；接著，LLM 根據訓練資料與內部運算機制產生初步回應；隨後，使用者對此回應進行檢視與反饋，例如調整參數、補充關鍵字或要求模型解釋特定結果(Kong, 2024)。

在協作過程中，提示工程(prompt engineering)扮演關鍵角色。Steyvers 與 Kong (2024)指出，有效的提示工程需要遵循「C.R.E.A.T.E.」框架：Character(角色設定)、Request(明確請求)、Additions(任務細化)、Type of Output(輸出格式)和 Extras(補充資訊)。這種迭代式的改進過程使使用者能精準掌握關鍵詞設定、上下文控制與回饋方式，引導 LLM 產生更適切的内容。

Kabir(2024)提出的六階段 co-creation 框架為人機協作提供了系統性的理論基礎：(1)準備階段(Preparation)：明確定義專案目標、範圍與期望成果，並選擇適合的 AI 工具與平台；(2)探索階段(Exploration)：收集相關資料與靈感來源，運用生成式 AI 產生初始概念與創意提示；(3)協作階段(Collaboration)：進行人機互動的迭代循環，人類提供反饋與方向指導，AI 處理輸入並生成精煉的想法與解決方案；

(4)發展階段(Development)：基於 co-creation 洞察開發原型，結合 AI 生成內容與人類創意專業知識；(5)實施階段(Implementation)：根據測試與反饋精煉並最終確定共創產品或解決方案；(6)評估階段(Evaluation)：評估共創產品的績效與影響，並識別未來改進領域以迭代 co-creation 流程。

基於此理論框架 AI 協作的核心可歸納為「需求→生成→回饋→再生成」的動態循環流程。對於本研究而言，這種協作模式體現為使用者與模型的持續對話過程：使用者首先提出問題或設計目標，LLM 根據語料生成初步回應，接著使用者根據情境需求進行評估與修訂，再將修改後的指令回饋給 LLM 進行進一步調整。這種人機互動的迭代過程能持續累積上下文知識，提升模型回應的深度與準確度。

然而，LLM 的輸出品質高度依賴使用者的引導技巧。(How to Support Human-AI Collaboration in the Intelligent Age, 2025)強調，成功的人機協作需要明確定義人類與 AI 的角色邊界，識別各自的能力盲點，並建立持續的技能評估機制。當提示設定不夠明確或上下文限制模糊時，生成式 AI 可能產生偏差回答或無關內容，影響協作效果。因此，藉由「以人為本」的分階段協作模式，AI 不僅成為強力的輔助工具，也進一步擴展了人類創意的可能性，既避免了純 AI 生成可能缺乏情感深度與個人特色的問題，也克服了純人類思考可能受限於知識廣度與聯想速度的限制，實現了真正的互補協作。

2.3.2 生成式 AI 與人類創造力的異同

若將生成式 AI 與人類的創造力進行比較，可以發現雙方在「動機來源」、「情感投入」以及「原創突破」上有所差異 (Giannuzzo, 2023; Haase & Hanel, 2023)。人類創造力常帶有強烈的個體化色彩，包含獨特的人生經驗、價值觀與情感驅動，能在不確定或模糊情境中產生「突破性」的創意(Boden, 1998) (Smith & Kosslyn, 2020)。相較之下，生成式 AI 雖可憑藉龐大資料庫與強大運算能力，在短時間內提出大量「可能解」，但其產出主要來自對訓練數據的模擬與預測，較少反映「自主動機」或「情感深度」(Boden, 1998)。

實證研究進一步驗證了這些差異。(Koivisto & Grassini, 2023b)在替代用途測試(AUT)的研究中比較了 256 名人類受測者與三個 AI 聊天機器人的表現，發現 AI 在流暢性(fluency)方面表現亮眼，能產生多元且豐富的想法，平均創造力得分甚至超越人類受測者。然而，在人類評審格外重視的原創性(originality)與情感深度上，最佳人類回應仍然超越了 AI 表現。研究同時發現，AI 極少產出低品質點子，展現了穩定的創意產出能力，而人類則呈現較大的變異性，既有突破性的頂尖創意，也可能因認知偏差或靈感枯竭而產出品質較低的想法。

更近期的研究提供了進一步的證據。(Hubert 等, 2024)在《Scientific Reports》發表的研究中發現，GPT-4 在標準化發散思維任務上的創意潛力顯著超過人類受試者，特別是在原創性評估中表現突。然而，該研究也強調，AI 的創造力主要體現在組合既有概念的能力上，缺乏人類特有的深層情感體驗與價值判斷(Doshi & Hauser, 2024)。

在此基礎上，AI 與人類的差異也轉化為一種互補關係，AI 為人類提供高效且多樣化的素材，人類則利用經驗、審美與道德判斷進行修飾與整合，使最終產物不僅兼具新穎與適切性，也彰顯了人類在「意圖性」與「價值連結」上的獨到見解(Doshi & Hauser, 2024; Giannuzzo, 2023; Sternberg & Lubart, 1998b)

2.3.3 章節小結

綜合前述探討，AI 協作模式透過人類與人工智慧在任務執行時的互補分工，展現了迭代式的特性：人類設定問題與提供回饋，AI 則憑藉巨量資料與運算能力快速生成內容。此外，生成式 AI 與人類創造力在動機、情感與原創突破上存在明顯差異，但也由此產生互補作用。人類能利用經驗與價值判斷審視 AI 所輸出的多元想法，並融入個人化的創造元素與倫理觀點，最終形成更具深度與適切性的成果。

為了在實際應用中實現這種互補優勢，本研究設計了「分階段協作模式」，將每題字詞聯想測驗的 4 分鐘作答時間分為兩個階段：1 分鐘獨立思考階段與 3 分鐘 AI 協作階段。

2.4 抽象概念與創造力

問題的抽象度對於人類與生成式 AI 在進行創意思考時，往往具有關鍵性的影響。一般而言，抽象問題傾向於引導更廣泛的聯想與思維空間，而具象問題則因具有明確的細節與情境脈絡，使思考能在更緊密的框架中進行。本研究將從哲學與心理學觀點切入，首先探討抽象與具象兩種概念的定義，並進一步說明 MRC 心理語言學資料庫（MRC Psycholinguistic Database）在篩選抽象與具象詞彙時的應用流程；接著將針對抽象與具象問題在創造力活動中的影響進行探討，分別說明對人類與生成式 AI（大型語言模型，LLMs）的潛在作用機制，進而為本研究後續的實驗設計奠定理論基礎。

2.4.1 抽象與具象的定義

自哲學層面而論，「抽象」與「具象」的區分長期以來便是該領域的核心議題之一。亞里斯多德（Aristotle）曾強調，抽象概念通常源自人類對外在事物本質的提煉與概括，而具象概念則著重於具象事物所呈現的形象或經驗（De Anima, 350 B.C.E）。在心理學領域，(Paivio, 1978)的雙碼理論（Dual Coding Theory）也進一步指出，人類在處理抽象概念時，更多地依賴語言性系統（verbal system），而面對具象概念時則可以同時運用語言性與表象性系統（imagery system），從而在理解與記憶上產生差異。

基於上述理論，本研究採用「抽象」一詞指涉較難以直接感知、具有高度概念化或無明確時空脈絡的問題，如「希望」、「自由」等詞彙；而「具象」則指人們較易於感官層面辨識或觀察到的事物，例如「桌子」、「蘋果」等。這種區分對於創意思考尤為重要，因為抽象問題往往需要較高層次的概念操作和延伸聯想，具象問題則更傾向於在現實脈絡下的直覺與經驗式聯想。

在實際應用上，本研究運用 MRC 心理語言學資料庫（MRC Psycholinguistic Database）來篩選並量化詞彙的抽象度。MRC 資料庫由(Coltheart, 1981)建立，整合

了多項英語詞彙的心理語言學指標，包含 98,538 個詞彙的語義、句法、音韻和拼字資訊(Coltheart, 1981)。該資料庫提供多達 26 種不同的語言學和心理語言學屬性，包括字頻（Word Frequency）、具象度（Concreteness）、形象性（Imagery）、語意熟悉度（Familiarity）等(Wilson, 1988)。

在抽象度測量方面，MRC 資料庫的具象度（Concreteness）分數是核心指標，數值範圍為 100-700 分。該分數整合了(Paivio, 1978)、(Toglia, 1978)以及(Gilhooly & Logie, 1980)三套規範的評分結果，透過調整平均數和標準差後進行平均計算(Coltheart, 1981; Wilson, 1988)。數值越高代表詞彙越具象（易於感官化想像），數值越低則表示越抽象（較難聯想到具象影像）。

研究者可依據具象度分數的高低，準確判定一個詞彙更趨近於抽象或具象，並進一步應用於創造力相關的實驗設計或測量中(Friendly 等, 1982)。藉由 MRC 心理語言學資料庫的支援，本研究在篩選抽象與具象詞彙時能更具客觀性與系統化，有助於後續檢驗問題抽象度與創造力表現之間的關聯。

2.4.2 抽象與具象對於創造力影響

(一) 對人類創造力的影響

抽象性較高的問題常被認為能引導更深層次的概念思維，並催化更廣泛的聯想空間。(Guilford, 1950) 在其創造力理論中指出，當個體面臨需高度概念化與非直接關聯的問題時，往往需要動用更高階的認知歷程，包括將既有知識加以重新組合與再概念化，以生成新穎且具獨特性的想法。因此，在抽象問題情境下，人類較容易激發「遠距離聯想」(Mednick, 1962)，使想法跳脫慣性思考框架。然而，過於抽象的問題也可能導致思考方向過度發散，增加理解或執行上的困難度，甚至因缺乏具象脈絡而降低解決問題的可行性(Runco & Jaeger, 2012)。

相比之下，具象問題具有明確的情境與細節，往往可使創意思考聚焦於實際的操作層面。研究顯示，當問題足夠「具象」時，受試者在產生解決方案時較易從現有經驗中找到可行的組合路徑，並輔以感官想像來增強思考效率(Palmarini &

Mitchell, 2023)(Ward, 2007)。因此，具象問題有利於提高「收斂性思考」(convergent thinking)的精準度，並能使個體更快地提出可行方案。然而，若問題過於具象，受測者可能侷限於狹窄的解決思維，降低了思考的發散程度(Smith & Kosslyn, 2013)。

除了傳統心理學的觀點外(Palmarini & Mitchell, 2023)在針對 ConceptARC 等抽象概念測試時，也發現人類在僅有少量範例的情境下，仍能藉由歸納或比喻等抽象推理方式去快速形成概念，展現了高度的靈活度與通用性。雖然該研究主要關注的是概念形成與抽象推理能力，但此特性在理論上有助於人類在面對抽象與多樣化情境時維持穩定的創造力表現。

(二) 對生成式 AI (LLMs) 創造力的影響

在生成式 AI 處理抽象問題時，模型須依賴內部龐大的語料庫與統計關係來理解高階概念。一方面，抽象問題可以使大型語言模型展現「組合性創造力」和「探索性創造力」(Boden, 1998)，例如將多領域的概念融合在一起，生成多樣且天馬行空的回應。另一方面，若抽象問題過於廣泛或缺少上下文，模型可能傾向產生無關或冗長的敘述，導致回答的有效性與方向性降低(Koivisto & Grassini, 2023)。

對於具象問題，因其具有明顯的情境脈絡，生成式 AI 能透過預訓練時所學到的具象經驗、常用情景或範例來快速產生較為貼切的解決方案。例如，在需要具象物品用途或情境設定的問題時，AI 能基於多樣化知識庫提供相對「現實可行」的建議。然而，也有學者指出，對 AI 而言，具象問題雖然可降低模型理解與生成時的模糊性，但同時也可能限制 AI 在「探索性創造力」中的表現，因為 AI 容易沿大量訓練數據中既定的類型化範本(Miller, 2019)。

綜言之，抽象與具象問題皆能影響人類與 AI 在創造力活動中的表現方向與結果。人類在面對抽象問題時，更容易激發深度聯想與突破式思考；AI 則可藉由龐大語言庫展現多元而高速的生成能力。在具象問題方面，雖然人類較能聚焦在實用性解決方案上，AI 也能即時運用多樣資料庫得出具象建議，然而可能因此減少了「跳脫框架」的發散空間。本研究即將在後續實驗中，針對問題抽象度如何影響人

類、生成式 AI 與 AI 協作模式三者的創造力表現進行更細緻的探討。

2.4.3 章節小結

綜合以上討論，抽象與具象的差異在哲學與心理學領域具有深刻的理論意涵，既牽涉到人類高階認知與感官聯想的運作方式，也關係到生成式 AI 在語言理解與內容生成時能否提供充足且有意義的回應。MRC 心理語言學資料庫提供了一套客觀而系統的指標，用以篩選並量化詞彙的抽象程度，有助於在實驗與實務應用中準確分類問題類型。面對抽象問題，人類與生成式 AI 皆可能激發更廣闊的創意空間，但也同時面臨判斷與執行難度的提升；相對地，具象問題雖在解題可行性與效率上較具優勢，但可能在創意的突破上受到侷限。這些理論基礎與文獻回顧，正是本研究後續實驗設計與分析的關鍵所在，為探討問題抽象度與三種創造力模式（人類、生成式 AI、AI 協作）之間的互動提供明確方向。

2.5 文獻探討總結

綜合以上文獻可知，本研究所探討的四大面向「創造力與創意思考」、「生成式 AI 與創造力」、「AI 人機協作與創造力」、「抽象概念與創造力」彼此之間具有密切的交互關係，並共同構成了本研究的理論基礎與實驗設計脈絡。透過整理這些文獻可歸納出幾項發現：第一，創造力評估複雜且測量方式也相當多種，因此本研究採取語義距離分析、流暢性分析與專家共識評分，這種方式結合了主觀與客觀的測量，以更全面呈現創意表現的多樣面向。；第二，人類與生成式 AI 在創意活動中各具優勢（例如人類的情感動機與 AI 的大量快速生成），但針對不同抽象層次的問題，其表現差異尚未有系統化之量化研究；第三，AI 人機協作雖被視為可以互補彼此的不足，然而對於其在哪種抽象程度的問題情境下能發揮最大價值，相關文獻仍缺乏明確的實徵依據。

有鑑於此，本研究提出「以問題抽象度為核心的人類、生成式 AI 與 AI 協作三種創意模式創造力評估」之框架。研究將利用 MRC 心理語言學資料庫篩選出

10 個代表不同抽象程度的刺激詞，並以此設計字詞聯想測驗（WAT），以比較生成式 AI、人類及 AI 協作三模式在創造力表現上的差異。隨後，透過語義距離分析、專家共識評分與流暢性進行評估，並利用視覺化圖表與統計檢定分析不同抽象度對創造力的影響。研究結果預期能為教育、設計與創意產業提供具象的 AI 應用策略，進一步豐富人機協作在創造力領域的實踐與發展。



三、研究方法與實驗設計

本研究旨在探討生成式 AI、人類及 AI 協作三種創意模式在不同問題抽象尺度下的創造力表現差異。研究採用實驗法作為主要研究方法，透過 MRC 心理語言學資料庫篩選定義抽象到具象的問題尺度，以字詞聯想測驗（WAT）作為核心測試工具，並結合語義距離分析與專家評分，評估不同模式在各類問題中的創造力表現。研究目的在於測量不同模式於不同問題抽象程度的創造力表現差異與趨勢，進一步識別各模式的創造力臨界點，並推導出在特定問題情境下應採用 AI、人類或 AI 協作模式，以實現最佳創造力的建議。


3.1 研究架構

本研究旨在探討「實驗模式」與「問題抽象程度」兩項核心自變項對創造力表現的影響。實驗模式分為人類組、生成式 AI 組與 AI 協作組，問題抽象程度則以 1～10 題涵蓋從高度抽象到高度具象的連續尺度。為確保內部效度，研究同時納入多項控制變項，包括作答時間（每題 4 分鐘）、英語程度（TOEIC 500 分以上）、年齡(18-65 歲)、AI 使用熟練度以及 AI 協作流程的標準化設定。

在此基礎上，受測者針對不同抽象程度的問題進行字詞聯想測驗（WAT），以衡量其創造力表現。最終則將「創造力表現趨勢」及「模式臨界點」視為依變項，分析各模式於不同抽象尺度下的表現差異與臨界值，從而找出最佳創造力策略。由此，整體研究架構形成了自變項（實驗模式、問題抽象程度）、控制變項與依變項（創造力表現趨勢、模式臨界點）三大部份，並共同組成本研究的核心設計。本研究架構兩個變項如下圖 7 所示。

圖 7

研究架構圖



註：本研究製作

3.1.1 研究變項

本節將依序介紹「自變項」、「依變項」與「控制變項」三大構面，並說明各變項之內涵與操作方式。

(一) 自變項

本研究採混合設計，將「實驗模式」與「題目抽象程度」設定為兩項自變項。首先，實驗模式包含人類組、生成式 AI 組以及 AI 協作組三種。實驗模式為組間變項，包含人類組、生成式 AI 組與 AI 協作組，每組各招募 21 名受試者；人類組受試者在每題 4 分鐘獨立完成 10 題字詞聯想測驗（WAT），生成式 AI 組則完全由 ChatGPT 作答，而 AI 協作組受試者先用 1 分鐘獨立思考，再於剩餘 3 分鐘依「需求→生成→回饋→再生成」流程與 AI 互動，以產出最終答案。題目抽象程度為組內變項，研究者參考 MRC 心理語言學資料庫之形象度指標，挑選高抽象與高具象詞彙，並依 1-10 尺度由高度抽象遞增至高度具象編排 10 題，同時允許後續

分析按連續（1-10）或二分（抽象 1-5 與具象 6-10）方式處理。此種設計使研究者能同時檢驗「不同實驗模式」與「不同抽象程度」在創造力表現上是否有交互作用。

（二）依變項

在依變項中，本研究以三項量化指標語義距離、專家主觀評分與流暢性衡量創造力表現。語義距離透過 SemDis 計算受試者回應與刺激詞數值；專家評分採 5 點式量表，由經訓練的領域專家對每題產出進行整體創意性判斷並取平均；流暢性則記錄每題有效回答數。這些指標先後納入線性混合模型（LMM）與廣義線性混合模型（GLMM）檢驗，以描繪三種實驗模式在不同抽象程度下的表現走勢，並擷取「模式臨界點」，藉此界定各模式於創造力任務中的最佳應用情境。

（三）控制變項

為降低無關變因干擾，本研究訂定以下控制原則。所有題目均以英文作答並限時 4 分鐘；其中，AI 協作組的 4 分鐘進一步拆分為 1 分鐘獨立思考與 3 分鐘 AI 協作，並依「需求→生成→回饋→再生成」之流程完成作答，以確保操作一致性。僅招募 18 - 65 歲且 TOEIC 500 分以上之成年受試者，以減少年齡與英文能力差異造成的影響；其教育背景與生成式 AI 使用頻率、頻率等資料於前測問卷中詳實記錄，後續可作共變量或分組比較。實驗要求受試者於安靜、無干擾環境下，透過同一線上答題介面與設備完成測驗，確保環境與情境一致。

3.1.2 研究流程

本研究採用實驗法作為主要研究方法，流程分為四個階段：研究準備階段、實驗設計與工具開發階段、主實驗執行與受測者招募階段，以及數據分析與結果詮釋階段。各階段環環相扣，確保研究的系統性與嚴謹性。

在研究準備階段，首先透過文獻探討建立理論基礎，確立以問題抽象程度為核心的創造力評估框架。接著運用 MRC 心理語言學資料庫篩選出 10 個具有不同抽象程度的刺激詞彙，範圍涵蓋從高度抽象到高度具象的尺度。。

在實驗設計與工具開發階段，以字詞聯想測驗（WAT）作為核心創造力聯想工具，採用 LimeSurvey 平台設計具備倒數計時功能的線上問卷，每題設定 4 分鐘作答時間。針對 AI 協作組的特殊需求，問卷介面額外設計標準化的協作流程提示與操作指引，確保受測者能依循「需求→生成→回饋→再生成」的協作模式進行作答。同時建立專家評分網站，基於 Torrance 創造力理論設計包含原創性、變通性、周全性與適切性四個維度的評分標準，採用 5 點式量表並提供詳細的評分指引與操作介面。

在主實驗執行與受測者招募階段，研究共招募 42 名符合條件的受測者（TOEIC 500 分以上、18-65 歲），隨機分配至人類組與 AI 協作組各 21 人，另設置生成式 AI 組進行 21 次獨立對話作為基準比較。所有受測者均需簽署研究參與同意書並完成基本資料調查。正式實驗中，人類組受測者獨立完成所有題目，AI 協作組則採用分階段模式（1 分鐘獨立思考 3 分鐘 AI 協作），生成式 AI 組由研究者操作 OpenAI o4mini high 模型完成 21 次獨立對話，每題結束後重置對話視窗以確保獨立性。

在數據收集與抽樣階段，語義距離分析涵蓋所有 13,549 個有效回答，透過 SemDis 平台進行客觀量化；專家評分採用分層抽樣法從總體回答中抽取 1,800 個樣本，由 6 位專家進行獨立評分。抽樣採用雙層分層設計，先依實驗組別等比例分配，再依 10 個抽象程度刺激詞進行等比例分配，確保樣本代表性與統計檢定力。

在統計分析與結果詮釋階段，研究採用線性混合模型(LMM)或廣義線性混合模型(GLMM)進行推論統計，分別從二分抽象尺度（抽象 1-5 vs. 具象 6-10）與十種抽象尺度兩個層次分析三種創意模式的表現差異。語義距離與專家評分結果分別進行獨立分析與詮釋，語義距離側重於評估原創性與變通性，專家評分則提供適切性、原創性、變通性與周全性的綜合評估。最後透過視覺化圖表呈現不同創意模式在各抽象程度下的表現趨勢與臨界點，並結合文獻探討進行深度詮釋，提出實務應用建議與未來研究方向。研究流程圖如下圖 8 所示。

圖 8

研究流程圖



註：本研究製作

3.2 研究工具

本研究使用了多項工具與平台，涵蓋詞彙篩選、創造力測驗、生成式 AI 應用、語義距離計算以及專家評分等面向。以下將逐一介紹各工具的功能與操作方式，並說明其在本研究中所扮演的角色與應用流程。

(一) MRC 心理語言學資料庫 (MRC Psycholinguistic Databas)

MRC Psycholinguistic Database (MRC) 是英語心理語言學研究中相當知名的詞彙屬性資料庫，由 Coltheart 等人 (1981) 於 1981 年代建立，整合了多種關於英語詞彙的心理語言學指標，如可想像度 (Imagability)、具象度 (Concreteness)、語義熟悉度 (Familiarity)、語義意義 (Meaningfulness) 等。在本研究中，特別關注資料庫所提供的具象度 (Concreteness) 分數，範圍介於 100 至 700，數值越低代表詞彙越偏向抽象，越高則表示越具象。

本研究聚焦於具象度分數 (100 - 700)；數值愈低愈抽象、愈高愈具象，先將該區間等分為十段 (每段約 60 分)，再於各段各篩選一個代表詞，形成連續十階的刺激詞序列；此外，為便利進一步比較，也將這十階再對映為二分尺度：抽象 (1 - 5) 與具象 (6 - 10)。由於 MRC 收錄的均為英文詞彙，問卷呈現時同時提供英文原詞與中文翻譯，受試者可借助翻譯工具理解，但最終仍須以英文作答，以維持語料的一致性並避免跨語言偏移。根據上述原則，本研究最終選定十個從高度抽象至高度具象的刺激詞。以下為本研究篩選之刺激詞彙及其抽象程度，請參照表 6 所示。

表 6

本研究刺激詞彙抽象程度分佈表

編號	抽象程度(CNC)	英文詞彙	中文解釋
1	144	As	像...
2	204	Infinity	無限
3	261	Hope	希望

4	320	Help	幫忙
5	380	Scare	驚嚇
6	440	Art	藝術
7	501	Red	紅色
8	559	King	國王
9	620	Apple	蘋果
10	670	Milk	牛奶

註：本研究製作

上述刺激詞彙均透過 MRC 心理語言學資料庫進行查詢與篩選，確保具象度分數的準確性與可信度，為本研究的詞彙選擇提供科學依據。以下為 MRC 心理語言學資料庫具象度指標的詞庫，但未經篩選，請參照圖 9 所示。

圖 9

MRC 心理語言學資料庫

MRC Psycholinguistic Database Output

UNIX : dict -r +\$S -o +N -h +N -c 100 700 -C -H -R -W

WORD CNC CPOS STAT

ABANDONMENT	272 N	S
ABASEMENT	275 N	S
ABATEMENT	250 N	S
ABBESS	401 N	S
ABDICATION	275 N	S
ABDUCTION	337 N	S
ABERRATION	330 N	S
ABILITY	273 N	S
ABODE	498 N	S

註：引自 MRC Psycholinguistic Database. (n.d.). *UWA psycholinguistic database*.

University of Western Australia. Retrieved February 15, 2025, from
https://websites.psychology.uwa.edu.au/school/mrcdatabase/uwa_mrc.htm

(二) 字詞聯想測驗 (WAT)

本研究採用字詞聯想測驗 (Word Association Test, WAT) 作為核心發散性思考的創造力評估工具，針對人類組與 AI 協作組受測者進行測試。首先，研究者參考 MRC 心理語言學資料庫相關指標，篩選出 10 個分佈於不同抽象程度的字詞作為刺激詞彙，並編制成 10 題開放式問卷。每題設定 4 分鐘限時作答，受試者需針對「刺激詞」寫下聯想反應，可提出多個想法。開放式作答形式使受試者不受既定選項限制，充分展現自由聯想與創造性思維。

為滿足問卷格式的特殊需求，研究採用 LimeSurvey 平台設計線上問卷，藉其高度彈性實現倒數計時與自動跳題：每題均設定 4 分鐘時限，時間一到即自動切換至下一題，以確保人類組與 AI 協作組的作答時程一致。系統同時記錄受試者於限時內輸入的「有效答案數」，作為流暢性 (fluency) 指標後續可直接從匯出資料表中擷取計數值。作業流程方面，人類組受試者獨立完成 10 題字詞聯想測驗；AI 協作組則使用研究方提供的 ChatGPT 帳號，在每題先獨立思考後再依「需求→生成→回饋→再生成」與 AI 互動，以生成最終答案。由於 MRC 心理語言學資料庫與 SemDis 語義距離模型均以英文語料為基礎，本研究規定所有受試者最終須以英文提交答案；作答過程可輔以翻譯工具理解詞義，以確保語義的一致性與準確。

本研究設計的字詞聯想測驗問卷介面具備以下特色：頂部設有紫色倒數計時條，顯示剩餘作答時間；中央清楚呈現刺激詞及其中文翻譯，降低詞彙理解障礙；針對 AI 協作組，黃色區塊標示作答階段，刺激詞下方提供標準化 Prompts 供受測者複製使用，減少與 AI 互動時間並確保協作流程一致性。介面分為兩個區塊：左側填寫聯想詞 (英文作答)，右側為補充說明區 (中文作答)。此設計兼顧實驗需求與使用便利性，透過編號輸入框引導受測者有序完成聯想任務。

人類組問卷介面僅保留基本的刺激詞、計時功能與回答區域，不會顯示「獨立

思考階段」提示與 Prompts 區塊，確保兩組實驗條件的差異性。以下為字詞聯想測驗問卷介面截圖（以 AI 協作組為例），請參照圖 10 所示。

圖 10

字詞聯想測驗問卷介面截圖（以 AI 協作組為例）

第一題

作答時間剩餘 00:03:59

獨立思考階段

Infinity

無限

Prompts:

針對詞彙『infinity』提供30個聯想詞，並依以下規則執行：回答內容請包含單詞與短句混合呈現但是盡量給我單詞，提升語義多樣性 避免過度無意義聯想或創作、仍要思想跳躍 發揮你的創造力 創意程度略高於一般人類的水準，不偏離常識需具合理性。 避免詞性或語意過度相似的詞彙（例如全是顏色、物品、或動詞） 請使用繁體中文回答 且回答口語化!!

請在下方填寫您的聯想詞 (英文作答)

1.	11.	21.
2.	12.	22.
3.	13.	23.
4.	14.	24.
5.	15.	25.
6.	16.	26.
7.	17.	27.
8.	18.	28.
9.	19.	29.
10.	20.	30.

若回答出乎意料或獨創，請補充說明 (中文作答)

1.	11.	21.
2.	12.	22.
3.	13.	23.
4.	14.	24.
5.	15.	25.
6.	16.	26.
7.	17.	27.
8.	18.	28.
9.	19.	29.
10.	20.	30.

(三) 生成式 AI 工具

A. 生成式 AI 組

本研究在生成式 AI 組別中，採用 OpenAI 所提供之 o4mini high 模型進行獨立創意生成測試。為確保樣本數量與人類組、AI 協作組（各 21 位受試者）相互對應，研究者進行 21 次獨立對話實驗。

具體操作流程如下，研究者將 MRC 心理語言學資料庫篩選之 10 個刺激詞輸入 ChatGPT，使用標準化提示詞(Prompt)一次性要求對所有刺激詞進行聯想。完整提示詞為：「針對詞彙 As、Infinity、Hope、Help、Scare、Art、Red、King、Apple、Milk，每個詞彙提供 30 個聯想詞，並依以下規則執行：回答內容請包含單詞與短句混合呈現但是盡量給我單詞，提升語義多樣性，避免過度無意義聯想或創作、仍要思想跳躍發揮你的創造力，創意程度高於一般人類的水準，不偏離常識需具合理性，避免詞性或語意過度相似的詞彙（例如全是顏色、物品、或動詞），請使用英語回答且回答口語化」。此標準化提示詞確保每次測試的一致性與可比較性。

數據處理方面，每次對話設定產出 300 個聯想回應（10 個刺激詞各 30 個回答），並對文字長度進行適度約束，確保整體作答規模與其他兩組相當。操作流程上，每次測試完畢後，研究者立即關閉當前對話視窗，重新開啟新的對話環境，清除 ChatGPT 的上下文記憶，以確保各次實驗間的獨立性，避免前次回答影響後續生成結果。透過 21 次獨立實驗，總計獲得 6,300 個聯想回應，經數據清理後納入後續分析。

B. AI 協作組

AI 協作組同樣採用 OpenAI o4mini high 模型，操作流程遵循人本導向人工智慧 (Human-Centered AI, HCAI) 的理念，保留「以人為本的協作」以避免完全依賴機器。具體操作流程如下，每題 4 分鐘的作答時間明確分為兩個階段。第一階段為 1 分鐘獨立思考時間，受測者需獨立構想初步聯想答案；第二階段為 3 分鐘 AI 協作時間，受測者依循「需求→生成→回饋→再生成」的標準協作流程，使用研究方

提供的 ChatGPT 帳號進行人機互動。

為降低受測者的認知負荷並確保協作流程的一致性，問卷介面提供標準化提示詞供受測者直接使用。以刺激詞「Infinity」為例，標準提示詞為：「針對詞彙『Infinity』提供 30 個聯想詞，並依以下規則執行：回答內容請包含單詞與短句混合呈現但是盡量給我單詞，提升語義多樣性，避免過度無意義聯想或創作、仍要思想跳躍發揮你的創造力，創意程度高於一般人類的水準，不偏離常識需具合理性，避免詞性或語意過度相似的詞彙（例如全是顏色、物品、或動詞），請使用英語回答且回答口語化」。此一固定提示可降低個體差異並確保協作起點一致。受測者可在 3 分鐘協作時間內不限次數地下達追加提示、要求修改或追問細節，讓 ChatGPT 在持續性對話中參考先前上下文進行內容擴充與修正，無需重置對話視窗。協作過程中，ChatGPT 保留完整的對話記憶，能根據受測者的回饋進行調整與強化。受測者需將 AI 提供的內容進行統整、篩選或再創造，形成最終的英文聯想答案。此流程確保人類主導的創意與 AI 生成的發散能力，體現 HCAI 所強調的人機互補。

(四) 語義距離分析工具(SemDis)

本研究採用 SemDis 語義距離分析平台，此平台由 Washington and Lee University 的 Dan Johnson 教授與 Penn State University 的 Roger Beaty 教授共同研發，運用先進的自然語言處理技術，自動計算文本間的語義關聯程度。該工具可依據輸入文本之間的語意相似性，生成介於 0 至 2 之間的數值，其中 0 表示兩個概念完全相同或極為密切，2 則代表概念間完全無關。由於 SemDis 已廣泛應用於創造力評估等相關研究，其提供的量化指標為本研究提供了堅實的學術依據（Beaty & Johnson, 2021）。

在實驗操作方面，所有組別作答均直接以英文輸出，因此研究者僅進行必要的文字清理與格式統整（如去除停用詞），再以 .csv 格式上傳至 SemDis 平台。操作流程主要包括：首先，準備包含「id」、「item」與「response」三個欄位的資料檔，其中「id」為受測者編號、「item」為刺激詞，而「response」則為受試者的回

答；接著，根據平台提供的選項，選擇合適的資料整理方式（例如移除特殊字符與停用詞）、語義空間及組合模型（使用 Multiplicative 模型，以提高與人類評分的一致性）；上傳資料後，平台將自動計算各組實驗結果的語義距離，並以表格形式呈現最終結果，供後續分析與下載。詳細操作步驟可參考平台中「Instructions for SemDis」的相關說明。以下為 SemDis 輸出結果，請參照圖 11 所示。

圖 11

SemDis 輸出結果

	A	B	C	D	E	F	G
1	group	participant_id	item	item_clean	response	response_clean	SemDis
2	human	23	Infinity	infinity	universe	universe	0.64028
3	human	23	Infinity	infinity	feeling	feeling	0.93045
4	human	23	Infinity	infinity	math	math	0.86809
5	human	23	Infinity	infinity	knowledge	knowledge	0.91914
6	human	23	Infinity	infinity	ocean	ocean	0.89044
7	human	23	Infinity	infinity	vocabularies	vocabularies	0.9501
8	human	23	Infinity	infinity	sky	sky	0.75072
9	human	23	Infinity	infinity	history	history	0.97228
10	human	23	Infinity	infinity	buddhism	buddhism	0.92095
11	human	23	Infinity	infinity	mazu	mazu	0.93047
12	human	23	Infinity	infinity	creature	creature	0.81715
13	human	23	Infinity	infinity	minibeast	minibeast	0.96526
14	human	23	Infinity	infinity	century	century	0.99344
15	human	23	Infinity	infinity	time	time	0.84113
16	human	23	Hope	hope	dream	dream	0.74304
17	human	23	Hope	hope	success	success	0.84597
18	human	23	Hope	hope	sky	sky	0.94722
19	human	23	Hope	hope	future	future	0.67033
20	human	23	Hope	hope	reputation	reputation	0.87763

註：引自 SemDis. (n.d.). *Semantic distance measurement tool*. Pennsylvania State

University. Retrieved February 15, 2025, from <http://semdis.wlu.psu.edu/>

(五) 專家共識評分標準與網站：

專家共識評分法（Consensual Assessment Technique, CAT），在本研究中由 6 名具備相關領域專業背景或評分經驗之研究人員，共同對三組於字詞聯想測驗（WAT）中所提出的點子進行創造力判斷。評分流程採單盲程序（blind procedure），使評分者無法得知各回答出自哪一組別。

本研究製作專家評分網站，基於 Torrance 創造力理論與 Guilford 的發散性思考理論，建立評分標準包含原創性（Originality）、變通性（Flexibility）、周全性（Elaboration）與適切性（Appropriateness）四個維度。評分標準採用「少見、跳遠、說透、合理」的口訣，使用李克特式 5 分量表進行評估：原創性評估答案的罕見程度與獨創性；變通性著重概念跨域程度與多角度思考；周全性檢視回答的故事性、情境描述與細節豐富程度；適切性評估聯想是否符合刺激詞意涵且具實際意義。以下為專家評分網站評分標準與四大維度說明截圖，請參照圖 12 所示。

圖 12

專家評分網站評分標準與四大維度說明

字詞聯想創造力評分系統

評審專用評分平台

創造力評分標準（基於Torrance理論）

評分口訣：「少見、跳遠、說透、合理」

稀 + 遠 + 透 + 切 = 高分

請綜合考量四個面向，給予1-5分整體評分

1 原創性 (Originality)

少見：答案是不是罕見或意料之外？

- 低分：常見、老梗
- 中分：稍具新意
- 高分：罕見且出其不意

2 變通性 (Flexibility)

跳遠：概念跨多遠、角度變化多大？

- 低分：侷限單一途徑
- 中分：小幅換類別
- 高分：跨域或多角度切換

3 周全性 (Elaboration)

說透：敘述有沒有補充故事、隱喻、細節？

- 低分：幾乎無補充
- 中分：基本描述
- 高分：故事化、隱喻、細節豐富

4 適切性 (Appropriateness)

合理：聯想是否符合刺激詞意涵且具實際意義？

- 低分：與刺激詞無關或不合邏輯
- 中分：基本相關且合理
- 高分：高度相關且富有深層意義

綜合評分標準

1-2分（低） 常見、單一途徑、沒細節、不合理	3分（中） 有創意意圖，但跨域/細節/適切性仍有限	4-5分（高） 罕見+大跨域+故事豐富+深層意義
-----------------------------------	-------------------------------------	------------------------------------

註：本研究製作。網址: <https://kenkkoko.github.io/>

評分網站操作流程簡述如下：專家首先下載分配的評分檔案，進入評分網站上傳檔案後，系統自動載入待評項目；專家依序檢視回答內容，根據三大維度綜合給予 1 到 5 分；系統以紅框提醒未評分項目並即時顯示進度；確認所有項目評分完畢後，匯出結果檔案並上傳至指定雲端資料夾。以下為專家評分網站評分操作畫面與進度追蹤截圖，請參照圖 13 所示。

圖 13

專家評分網站評分操作畫面與進度追蹤

The screenshot displays the '資料輸入與評分' (Data Input and Rating) interface. It features a section for uploading Excel/CSV files, a manual input section, and a list of items to be rated. The first item, 'Apple', is already rated with a score of 5. The second item, 'newton(牛頓)', is highlighted in red, indicating it is yet to be rated. A progress bar at the bottom shows '已評分: 1 / 總數: 2' (Rated: 1 / Total: 2).

資料輸入與評分
 上傳Excel/CSV檔案

點擊選擇檔案
 支援格式: CSV, Excel (.xlsx, .xls)
 檔案格式: group, participant_id, item, response

已上傳檔案: test.xlsx
 資料筆數: 4

手動輸入 (可選)

刺激詞: 例如: Milk
 參與者回答: 例如: Milk tea

新增回答

1/2 ID: 147
 刺激詞: Apple 回答: fruit(水果)
 1-2分 (低) 單一、常見 3分 (中) 有創意但有限 4-5分 (高) 遠+新+透
 1 2 3 4 5

2/2 ID: 132 未評分
 刺激詞: Apple 回答: newton(牛頓)
 1-2分 (低) 單一、常見 3分 (中) 有創意但有限 4-5分 (高) 遠+新+透
 1 2 3 4 5

已評分: 1 / 總數: 2

清除所有資料 匯出Excel檔案

註：本研究製作。網址: <https://kenkkoko.github.io/>

3.3 主實驗設計

本研究採用三組比較實驗設計，透過系統性的實驗流程探討生成式 AI、人類及 AI 協作三種創意模式在不同問題抽象程度下的創造力表現差異。整體規劃分為實驗前準備、正式實驗執行與數據評分與分析三大環節。研究共招募 42 名受測者，分為人類組、AI 協作組各 21 人，另設置生成式 AI 組進行相同次數的對話共 21 次作為基準比較。本研究同時採用語義距離、專家共識評分與流暢性三項指標，前兩者分別以 SemDis 平台進行評分，專家評分將邀請具相關經驗或專業背景之評審進行評估，並於評分前進行簡短培訓，以確保評分結果的可靠性與有效性。為確保各組間的公平比較，本研究將每題作答時間統一設定為四分鐘，使研究能在相同時間限制下比較各組的回答數量（流暢性）與創造力表現。

3.3.1 主實驗受測者

主實驗共招募 42 名受測者。考慮到創造力是人類的普遍特質，本研究不限制受測者的教育程度與專業背景，但要求所有受測者英語能力達 TOEIC 500 分以上，以確保能以英文進行作答。AI 協作組的受測者需具備基本的 AI 工具使用經驗（至少使用過 ChatGPT 等生成式 AI 工具 3 個月以上）。研究採用分組實驗設計，將受測者隨機分配至人類組與 AI 協作組，每組各 21 人。此外，設置生成式 AI 組（使用 OpenAI o4mini high）進行 21 次獨立對話作為基準比較。人類組的受測者需獨立完成所有實驗問題；AI 協作組則採用人機協作模式完成作答。為控制實驗變項，所有受測者均接受標準化的實驗前訓練，確保充分理解實驗流程與任務要求。實驗對象的詳細分組資訊如下表 7 所示：

表 7

主實驗受測者分組資訊表

實驗組別	人數	實驗模式說明	受測者背景
人類組	21 人	獨立完成實驗問題，無 AI 輔助	TOEIC 500 分以上
AI 協作組	21 人	採用人機協作模式完成作答(OpenAI o4mini high)	TOEIC 500 分以上，具 3 個月以上 AI 使用經驗
生成式 AI 組	21 次對話	由研究者以生成式 AI 獨立作答	OpenAI o4mini high

註：本研究製作

3.3.2 主實驗流程

主實驗流程分為實驗前準備、正式實驗執行與數據評分與分析三個主要階段。

(一) 實驗前準備階段：

研究團隊首先透過 MRC 心理語言學資料庫篩選 10 個不同抽象程度的詞彙(具象度指數介於 100-700 之間)，設計成字詞聯想測驗(WAT)題目。為避免順序效應，題目順序進行隨機化處理。實驗前，所有受測者需簽署研究參與同意書，並完成基本資料調查，確認英語能力達 TOEIC 500 分以上。AI 協作組的受試者還需接受針對實驗流程的簡短培訓，詳細說明實驗流程與操作方式。

(二) 正式實驗執行階段：

人類組受測者獨立完成字詞聯想測驗(WAT)測驗，每題作答時間為 4 分鐘，全程以英文作答；AI 協作組則採用人機協作模式，每題 4 分鐘內分為 1 分鐘獨立思考與 3 分鐘 AI 協作階段，協作階段需要參照「需求→生成→回饋→再生成」之協作流程，並須使用實驗方提供之 ChatGPT 帳號進行問答，最終以英文提交答案；生成式 AI 組則完全由 OpenAI o4mini high 獨立完成 21 次對話回答。人類組與 AI 協作組受測者可以使用翻譯工具對不確定的詞彙進行確認。實驗過程全程由研究者進行監督與記錄，確保實驗程序的標準化與數據的完整性。


(三) 數據評分與分析階段：

研究團隊運用 SemDis 平台計算答案的語義距離分數，並邀請 6 位專家進行創造力評分。本研究為專家評分架設網站，基於 Torrance 創造力理論與 Guilford 的發散性思考理論，建立評分標準包含變通性 (Flexibility)、原創性 (Originality)、周全性 (Elaboration) 與適切性 (Appropriateness) 四個維度。專家使用 1-5 分量表對回答進行評估，其中變通性評估回答類別的多樣性，原創性評估回答的新穎程度，周全性評估回答的詳細完整程度。所有評分過程採取單盲設計，評分者不知道回答來自何種實驗組別。最後，將語義距離分析、專家評分與流暢性的結果先獨立解釋最後將結果綜合分析。本研究使用 SPSS 與 RStudio 進行統計分析。以下為主實驗流程圖 14。



圖 14

主實驗研究流程圖



註：本研究製作

四、研究結果與討論

本章節深入討論本研究的主要發現，旨在回應先前章節提出的研究問題。內容涵蓋各項數據分析結果，並結合文獻探討進行多面向的詮釋與比較，以釐清生成式 AI、人類及 AI 協作三種創意模式在不同問題抽象程度下的創造力表現差異、各模式的創造力臨界點，以及研究成果在實務領域的應用價值。

4.1 樣本特徵與資料品質檢驗

本節將詳述本研究實驗參與者的基本資料，並對所蒐集之數據進行嚴謹的品質檢驗，為後續的數據分析提供紮實的依據。

4.1.1 樣本基本資料

首先呈現本研究中三組實驗參與者的基本人口統計學資料，包括年齡、性別、教育程度及專業領域分佈，以提供對研究樣本特徵的初步認識。

(一) 三組受測者基本資料統計

本研究共招募 42 名受測者，分為人類組與 AI 協作組各 21 人，另設置生成式 AI 組進行 21 次獨立對話作為基準比較。由於生成式 AI 組為 21 個獨立對話，故無受測者基本資料。以下針對人類組與 AI 協作組的受測者基本資料進行統計分析。

在年齡分佈方面，人類組受測者年齡介於 20 至 56 歲之間，平均年齡為 24.05 歲 ($SD=8.12$)；AI 協作組受測者年齡介於 20 至 28 歲之間，平均年齡為 22.90 歲 ($SD=2.33$)；在性別分佈上，人類組包含男性 7 名 (33.3%)、女性 14 名 (66.7%)；AI 協作組包含男性 9 名 (42.9%)、女性 12 名 (57.1%)，兩組均呈現女性略多於男性的分佈型態。在教育程度方面，人類組中大學程度者 12 名 (57.1%)，研究所程度者 9 名 (42.9%)；AI 協作組中大學程度者 10 名 (47.6%)，研究所程度者 11 名 (52.4%)；專業領域分布顯示，兩組受測者主要集中於人文藝術領域，人類組 19 名 (90.5%)、AI 協作組 18 名 (85.7%)；其他領域包括工程製造領域、社會

科學商業法律領域等，詳細結果如表 8 所示。

表 8

受測者基本資料統計表

變項	類別	人類組 (n=21)	AI 協作組 (n=21)
年齡	平均值±標準差	24.05±8.12	22.90±2.33
	範圍	20-56 歲	20-28 歲
性別	男性	7 (33.3%)	9 (42.9%)
	女性	14 (66.7%)	12 (57.1%)
教育程度	大學(含大專)	12 (57.1%)	10 (47.6%)
	研究所(碩、博士班)	9 (42.9%)	11 (52.4%)
專業領域	人文藝術領域	19 (90.5%)	18 (85.7%)
	工程、製造及營造領域	2 (9.5%)	0 (0%)
	社會科學、商業及法律領域	0 (0%)	1 (4.8%)
	其他領域	0 (0%)	2 (9.5%)

(二) 資料收集概況說明

本研究在正式實驗執行階段共收集三個核心構面的資料：語義距離分析、專家評分與流暢性測量，各構面樣本數量與抽樣方式說明如下。

A. 各構面樣本分布

本研究針對語義距離、流暢性及專家評分等不同指標，採用了相應的樣本數據集。語義距離分析涵蓋了所有受測者的完整回答，總計達 13,549 個有效回答。其中，人類組貢獻了 2,946 個回答，AI 協作組貢獻了 4,484 個回答，而生成式 AI 組則貢獻了 6,118 個回答，所有回答均透過 SemDis 平台進行語義距離計算。

至於流暢性測量，其數據以受測者為單位進行計算，共產生 630 個觀測值。包括 21 位人類組受測者在 10 道題目下的表現，21 位 AI 協作組受測者在 10 道題目

下的表現，以及 21 次生成式 AI 對話在 10 道題目下的產出。每個觀測值皆代表該受測者在特定題目下的回答數量，作為衡量其發散性思考流暢性的指標。

最後，考量到專家評分的認知負荷與評分品質，本研究採取了分層抽樣法，從總計 13,549 個回答中抽取了 1,800 個樣本進行專家評估。

B. 專家評分分層抽樣設計

鑒於完整評分所有回答將對專家造成過度認知負荷，影響評分精確度，本研究採用分層抽樣策略以確保樣本代表性。抽樣設計遵循比例分配原則，每位專家被分配 300 個評分單位，該工作量為可接受範圍內。考量 6 位專家同時進行評分，本研究總計評估 1,800 個樣本。

樣本分層結構採用雙層分層設計，首先依實驗組別進行第一層分層，將 1,800 個樣本等比例分配於人類組、AI 協作組與生成式 AI 組，各組 600 個樣本；其次進行第二層分層，依 10 個不同抽象程度的刺激詞進行等比例分配，每個刺激詞在各組中均分配 60 個樣本。此雙層分層設計確保了後續進行組間比較分析時具備充分的統計檢定力，同時保證了不同抽象程度刺激詞的效應檢驗具有等權重，避免了因抽樣偏誤導致的統計推論偏差。

C. 抽象尺度分析層次說明

為兼顧抽象度分析可解釋性，本研究將十種抽象尺度概括成二種抽象尺度。十種抽象尺度分析保留 MRC 心理語言學資料庫篩選出的完整抽象程度光譜（抽象程度 1 至 10），能夠捕捉創造力表現的細緻變化與非線性趨勢；二種抽象尺度分析則將十個刺激詞依抽象程度劃分為抽象組（題目 1-5）與具象組（題目 6-10），便於建立清晰的理論對比與實務應用指引。

此設計的優勢在於：十種尺度分析提供精細的創造力臨界點識別，有助於發現各創意模式在特定抽象程度下的表現峰值；二分尺度分析則簡化複雜的統計結果，將發現轉化為易於理解且具實務價值的應用策略。透過比較兩種分析層次的結果一致性，研究亦能驗證分類方式的穩健性，確保研究結論在不同抽象程度劃分下均

具說服力。

4.1.2 資料品質檢驗

本節將針對本研究蒐集之資料進行嚴謹的品質檢驗，以驗證數據的可靠性與適用性，為後續的統計分析奠定分析基礎。

(一) 描述性統計

本節針對三個核心指標：語義距離、流暢性與專家評分進行描述性統計分析。內容涵蓋整體資料概況，以及分別針對語義距離、流暢性與專家評分的詳細統計。分析同時考量三個實驗組別（人類組、AI 協作組與生成式 AI 組）、兩種抽象層次分組（抽象程度 1-5 與具象程度 6-10），並深入至十個抽象程度刺激詞的層級。在這些不同條件之下，均報告平均數、標準差、最小值與最大值，以描繪各指標的集中趨勢與離散程度。

A. 整總體描述性統計

本研究首先針對語義距離、流暢性與專家評分三項指標進行描述性統計分析。語義距離整體平均值為 0.873917 ($SD=0.0648218$)，數值範圍介於 0.6944 至 1.0332 之間；流暢性表現的整體平均值為 21.76 個回答 ($SD=8.479$)，範圍介於 2 至 48 個回答，反映受測者間在字詞聯想測驗中的產出數量存在明顯的差異；專家評分採 1-5 分量表，整體平均值為 3.14 分 ($SD=1.317$)，整體資料品質良好，標準差顯示各指標均具有適當的變異程度，結果彙整於表 9。

表 9

整體描述性統計表

變數/分類方式	個數	平均數	標準差	最小值	最大值
語義距離	630	.873917	.0648218	.6944	1.0332
整體描述					
流暢性	630	21.76	8.479	2	48
專家評分	1800	3.14	1.317	1	5

B. 語義距離描述性統計

語義距離的整體分布可從三個層次加以觀察，可為後續推論性比較提供基礎。

首先，就實驗組別而言，生成式 AI 組的語義距離最高，平均值為 0.904884 ($SD = 0.0347091$) 範圍介於 0.8608–0.9626；AI 協作組次之，平均為 0.860898 ($SD = 0.0453602$) 範圍介於 0.7972–0.9692；人類組平均為 0.854596 ($SD = 0.0479752$) 範圍介於 0.7786–0.9387。

其次，若將十個刺激詞依抽象層次二分，抽象程度 1–5（較抽象）之平均語義距離為 0.885528 ($SD = 0.0599715$)，範圍介於 0.7207–1.0332；具象程度 6–10（較具象）之平均 0.862306 ($SD = 0.0674541$) 範圍介於 0.6944–1.0254。

最後，以十個單一抽象程度的指標劃分，平均值分布於 0.833671 至 0.898282 之間；其中，抽象程度 1 的語義距離最大 ($M = 0.898282$)，抽象程度 8 最小 ($M = 0.833671$)，各層次的標準差介於 0.0415480 與 0.0754890 間，詳細列於表 10。

表 10

語義距離之描述性統計表

	分類方式	個數	平均數	標準差	最小值	最大值
語義距離	人類組	21	.854596	.0479752	.7786	.9387
	AI 協作組	21	.860898	.0453602	.7972	.9692
	生成式 AI 組	21	.904884	.0347091	.8608	.9626
	抽象 1~5	315	.885528	.0599715	.7207	1.0332
	具象 6~10	315	.862306	.0674541	.6944	1.0254
	抽象度_1	63	.898282	.0525976	.7231	1.0332
	抽象度_2	63	.896550	.0563960	.7839	1.0068
	抽象度_3	63	.869136	.0663765	.7291	.9912
	抽象度_4	63	.874197	.0593507	.7448	1.0057
	抽象度_5	63	.889477	.0602619	.7207	1.0007
	抽象度_6	63	.846303	.0754890	.6944	1.0136
	抽象度_7	63	.892472	.0415480	.7453	.9906

抽象度_8	63	.833671	.0686892	.6987	.9834
抽象度_9	63	.888852	.0552668	.7225	.9996
抽象度_10	63	.850232	.0704567	.6954	1.0254

C. 流暢性描述性統計

流暢性描述性統計分析分為三個層面呈現。首先，就實驗組別而言，生成式 AI 組的流暢性平均值為 291.33 個回答 ($SD=3.692$)，範圍介於 281 至 296 個；AI 協作組平均值為 213.52 個回答 ($SD=54.030$)，範圍介於 139 至 308 個；人類組平均值為 148.00 個回答 ($SD=67.691$)，範圍介於 54 至 341 個。

按抽象度高低二分，抽象程度 1-5 組(抽象)的平均流暢性為 20.58 個回答($SD=8.816$)，範圍介於 2 至 38 個；抽象程度 6-10 組(具象)的平均流暢性為 22.94 個回答 ($SD=7.970$)，範圍介於 3 至 48 個。

進一步從 10 個不同抽象程度的詳細分析來看，流暢性平均值介於 18.60 至 24.11 之間，其中抽象程度 7 表現最高(24.11 個回答)，抽象程度 2 表現最低(18.60 個回答)，標準差範圍介於 6.368 至 9.375 間，完整數據載於表 11。

表 11

流暢性之描述性統計表

	分類方式	個數	平均數	標準差	最小值	最大值
流暢性	人類組	21	148.00	67.691	54	341
	AI 協作組	21	213.52	54.030	139	308
	生成式 AI 組	21	291.33	3.692	281	296
	抽象 1~5	315	20.58	8.816	2	38
	具象 6~10	315	22.94	7.970	3	48
	抽象程度_1	63	19.33	8.576	2	32
	抽象程度_2	63	18.60	9.375	3	30
	抽象程度_3	63	21.10	8.862	3	30
	抽象程度_4	63	21.41	8.573	4	30
	抽象程度_5	63	22.48	8.362	4	38
	抽象程度_6	63	23.17	8.045	6	48

抽象程度_7	63	24.11	6.368	9	32
抽象程度_8	63	22.46	8.256	4	42
抽象程度_9	63	22.87	8.818	3	48
抽象程度_10	63	22.08	8.249	4	36

D. 專家評分描述性統計

專家評分描述性統計分析分為三個層面呈現。首先，於三個實驗組別中，生成式 AI 組的專家評分平均值為 3.19 分（SD = 1.272）；AI 協作組平均值為 3.13 分（SD = 1.397）；人類組平均值為 3.09 分（SD = 1.278），專家評分採 1-5 分量表，因此範圍皆介於 1 至 5 分。

依抽象程度分組，抽象程度 1-5 組（抽象）的平均專家評分為 3.25 分（SD = 1.275）；抽象程度 6-10 組（具象）的平均專家評分為 3.03 分（SD = 1.348）。

從 6 位專家的評分分佈來看，專家評分平均值介於 2.62 至 3.56 分之間，其中專家 2 的評分最高（3.56 分），專家 5 的評分最低（2.62 分）。標準差範圍介於 1.149 至 1.351 之間，完整數據載於表 12。

表 12

專家評分之描述性統計表

	分類方式	個數	平均數	標準差	最小值	最大值
專家評分	人類組	600	3.09	1.278	1	5
	AI 協作組	600	3.13	1.397	1	5
	生成式 AI 組	600	3.19	1.272	1	5
	抽象 1~5	900	3.25	1.275	1	5
	抽象 6~10	900	3.03	1.348	1	5
	專家 1	300	3.06	1.301	1	5
	專家 2	300	3.56	1.351	1	5
	專家 3	300	3.06	1.301	1	5
	專家 4	300	3.46	1.330	1	5
	專家 5	300	2.62	1.252	1	5
	專家 6	300	3.06	1.149	1	5

(二) 信度檢驗

A. 語義距離信度檢驗

在進行語義距離量表的內部一致性評估時，本研究以十個具不同抽象程度的刺激詞為試題單元，計算 Cronbach's α 係數以檢驗量表信度。結果顯示 α 值為 0.932，明顯高於 0.70 的通用可接受門檻，也超過 0.90 的優秀一致性標準。此結果表示各刺激詞對語義距離的衡量方向一致，量表內部誤差變異極低；因此，在後續比較不同實驗條件（組別與抽象程度）時，語義距離差異可歸因於真實效應，而非測量不穩定所致，完整數據載於表 13。

表 13

語義距離之信度檢驗表

變數	題數	Cronbach's Alpha 係數
語義距離	10	.932

B. 專家評分描述性信度檢驗

為確保專家評分的可靠性與一致性，本研究採用多項措施提升評分品質，包括明確的評分標準與範例、評分前簡短培訓、單盲評分程序等。在評分標準方面，本研究基於 Torrance 創造力理論與 Guilford 的發散性思考理論，建立包含原創性 (Originality)、變通性 (Flexibility)、周全性 (Elaboration) 與適切性 (Appropriateness) 四個維度的評分標準。評分標準採用「少見、跳遠、說透、合理」的記憶口訣，使用 5 分李克特量表進行評估，詳細說明如表 14 所示。

表 14

專家評分四大維度標準表

評分標準	重點	具體說明
原創性	少見	評估答案的罕見程度與獨創性，衡量受測者能否產生不尋常、新穎且具有突破性的聯想

變通性	跳遠	著重概念跨域程度與多角度思考能力，檢視回答是否能從不同觀點或領域進行聯想
周全性	說透	檢視回答的故事性、情境描述與細節豐富程度，評估受測者是否能將聯想發展成完整且具體的概念
適切性	合理	評估聯想是否符合刺激詞意涵且具實際意義，確保創意回答在邏輯上與刺激詞相關且具實用價值

在專家背景與培訓方面，所有專家在正式評分前均接受簡短培訓，內容包括評分目的與重要性說明、四個評分維度的詳細解釋與範例示範、評分網站操作流程指導，以及評分一致性的重要性強調。專家的背景資料顯示所有 6 位專家均具備創意相關科系背景與豐富的實務經驗。其中 67% 具備碩士學歷，主修領域均為創意相關科系，包括動畫與影片創作、視覺設計、多媒體設計等。在創造力研究經驗方面，100% 的專家具有創造力相關研究或專案經驗，其中 50% 具有 5 年以上的資深經驗，50% 具有 1-3 年的實務經驗；在評分經驗方面，33% 曾參與過創造力評分或類似主觀評分研究，參與次數從 1-2 次至 10 次以上不等，提供了豐富的評分經驗基礎。詳細說明如表 15 所示。

表 15

專家背景與經驗統計表

編號	學歷	主修領域	創造力研究 專案經驗	經驗年數	評分經驗	參與次數
專家 1	碩士	多媒體設計	是	5 年以上	是	3-5 次
專家 2	碩士	多媒體設計	是	1-3 年	否	無
專家 3	碩士	多媒體設計	是	5 年以上	是	10 次以上
專家 4	學士	多媒體設計	是	1-3 年	否	1-2 次

專家 5	學士	多媒體設計	是	1-3 年	否	無
專家 6	碩士	視覺設計	是	5 年以上	是	1-2 次

在評分程序控制方面，評分過程品質控制的專家回饋結果，顯示在評分困難程度上，50%的專家表示「很少」遇到困難，33%表示「偶爾」遇到困難，17%表示「經常」遇到困難；評分環境品質良好，100%的專家確認評分環境安靜且無干擾，確保評分過程的專注度；在評分一致性方面，100%的專家認為自己的評分標準在整個過程中「大致一致」，詳細說明如表 16 所示。

表 16

評分過程品質控制與信度檢驗結果表

信度檢驗項目	具體指標	結果	比例
專家資格審查	創意相關科系	6 人	100%
	碩士學歷	4 人	67%
	大學學歷	2 人	33%
	創造力研究經驗	6 人	100%
	5 年以上資深經驗	3 人	50%
	1-3 年資深經驗	3 人	50%
評分過程控制	安靜無干擾環境	6 人	100%
	很少遇到困難	3 人	50%
	偶爾遇到困難	2 人	33%
	經常遇到困難	1 人	17%
評分一致性	大致一致	6 人	100%

綜合信度檢驗結果顯示，透過四個維度的綜合評分標準、充分的培訓程序與單盲設計，專家間評分的一致性得到有效保障。專家 100%具備創意相關科系背景與創造力實務經驗，評分環境 100%符合標準，評分一致性維持 100%。儘管有 17%的

專家表示「經常」遇到困難，但所有專家均能維持評分標準的一致性，顯示評分培訓與標準設定的有效性。專家回饋顯示整體評分過程順暢，對評分標準的理解程度高，且評分一致性維持良好，為後續統計分析提供可靠且具代表性的評分數據基礎。

(三) 常態分佈檢驗

本研究使用 Shapiro-Wilk 檢定評估語義距離、流暢性與專家評分在各資料層級上的分布形態，以決定後續統計方法的適切性。檢定範圍涵蓋六個面向：A.語義距離與流暢性在兩種抽象尺度的分布、B.語義距離與流暢性在十種抽象尺度的分布、C.三種創意模式與語義距離與流暢性常態分佈檢驗分布，D.專家評分在兩種抽象尺度常態分佈檢驗，E.專家評分在十種抽象尺度的分布，以及 F. 三種創意模式的專家評分分布。

檢驗結果將指導後續統計分析方法的選擇。對於未符合常態分佈假設的資料，若其數據特性與模型假設相符，將採用適合的廣義線性混合模型或考慮其穩健性進行參數分析；若資料特性嚴重偏離且無法透過模型調整涵蓋，則採用無母數統計方法。

A. 語義距離與流暢性在兩種抽象尺度的分布

以 Shapiro-Wilk 檢定檢視抽象與具象兩組資料是否符合常態分佈。首先，語義距離部分，抽象組的檢定結果為 $p=.103$ ，符合常態分佈假設，具象組為 $p=.009$ ，未符合常態分佈假設；其次，在流暢性部分，抽象組的檢定結果為 $p<.001$ ，具象組亦為 $p<.001$ ，兩組的流暢性均未符合常態分佈假設。完整檢定數據列於表 [X]

此結果顯示在抽象與具象分組的比較中，流暢性資料均偏離常態分佈，而語義距離僅在具象組未符合常態分佈假設。因此，在後續的統計分析中，對於部分未符合常態分佈的資料，本研究將依循其數據類型（連續或計數）選用適合的廣義線性混合模型，並於模型說明中進一步闡釋其合理性，詳細說明如表 17 所示。

表 17

語義距離與流暢性在抽象與具象兩組之常態分佈表

構面	抽象/具象	Shapiro-Wilk		
		統計量	自由度	顯著性
語義距離	抽象(1-5)	.992	315	.103
	具象(6-10)	.988	315	.009
流暢性	抽象(1-5)	.889	315	.000
	具象(6-10)	.899	315	.000

B. 語義距離與流暢性在十種抽象尺度常態分佈檢驗

前述針對抽象程度兩組進行常態分佈檢定後，接著針對十種抽象尺度題目語義距離與流暢性進行常態分佈檢驗，同樣採用 Shapiro-Wilk 檢驗進行檢測。

語義距離檢驗結果顯示，抽象程度 1 ($p = .034$) 和抽象程度 7 ($p = .001$) 兩題 p 值均小於 0.05，未符合常態分佈；其餘八題的 p 值介於.157 至.951 間，未檢出偏離常態的證據。在流暢性方面，所有十種抽象尺度题目的檢驗均呈現顯著性($p < .001$)，顯示流暢性資料未符合常態分佈假設，因此在後續統計分析中，將採用適合計數資料的廣義線性混合模型 (Poisson 分佈)，以穩健性地處理其非常態分佈特性，詳細說明如表 18 所示。

表 18

語義距離與流暢性在抽象題目之常態分佈檢驗表

構面	抽象程度	Shapiro-Wilk		
		統計量	自由度	顯著性
語義距離	抽象度_1	.959	63	.034
	抽象度_2	.974	63	.191
	抽象度_3	.972	63	.157

	抽象度_4	.992	63	.951
	抽象度_5	.982	63	.498
	抽象度_6	.980	63	.413
	抽象度_7	.930	63	.001
	抽象度_8	.978	63	.320
	抽象度_9	.982	63	.500
	抽象度_10	.990	63	.894
流暢性	抽象度_1	.912	63	.000
	抽象度_2	.846	63	.000
	抽象度_3	.849	63	.000
	抽象度_4	.859	63	.000
	抽象度_5	.876	63	.000
	抽象度_6	.897	63	.000
	抽象度_7	.867	63	.000
	抽象度_8	.896	63	.000
	抽象度_9	.914	63	.000
	抽象度_10	.877	63	.000

C. 三種創意模式與語義距離與流暢性常態分佈檢驗

檢驗三種創意模式（AI 協作組、生成式 AI 組、人類組）的語義距離與流暢性是否符合常態分佈，採用 Shapiro-Wilk 檢驗進行分析，詳細結果如表[X]所示。

在語義距離方面，人類組（ $p = .459$ ）、AI 協作組（ $p = .067$ ）與生成式 AI 組（ $p = .061$ ）的檢驗結果均未達顯著水準（ $p > .05$ ），顯示三種創意模式語義距離皆符合常態分佈假設。從語義距離常態分佈圖可觀察到，AI 協作組與人類組呈現相對集中的分佈型態。在流暢性方面，AI 協作組（ $p = .108$ ）、生成式 AI 組（ $p = .077$ ）

與人類組 ($p = .087$) 的檢驗結果同樣未達顯著水準，表示三種創意模式流暢性亦符合常態分佈假設。從流暢性常態分佈圖可見，三種模式間皆呈現接近常態的分佈型態。此結果顯示在組別層次的分析中，語義距離與流暢性資料均符合常態分佈假設，支持後續採用參數統計方法進行組間差異分析的適當性，詳細說明如表 19 所示。

表 19

語義距離與流暢性之常態分佈檢定表

構面	組別	Shapiro-Wilk		
		統計量	自由度	顯著性
語義距離	人類組	.957	21	.459
	AI 協作組	.914	21	.067
	生成式 AI 組	.912	21	.061
流暢性	人類組	.920	21	.087
	AI 協作組	.925	21	.108
	生成式 AI 組	.918	21	.077

D. 專家評分在兩種抽象尺度常態分佈檢驗

檢驗專家評分在兩種抽象尺度中是否符合常態分佈，本研究採用 Shapiro-Wilk 檢驗進行分析。檢驗結果顯示，抽象組的專家評分在 Shapiro-Wilk 檢驗中呈現顯著性 ($p < .001$)，具象組同樣呈現顯著性 ($p < .001$)，表示兩組的專家評分資料均未符合常態分佈假設。抽象組的統計量為.889，具象組的統計量為.893，雖然數值相近，但兩組的顯著性水準均達到 $p < .001$ ，明確顯示專家評分資料在兩種抽象尺度分組中均偏離常態分佈。由於專家評分資料顯著偏離常態分佈，但考慮到其為近似連續的區間尺度，且為處理其偏態性，本研究選擇採用廣義線性混合模型搭配常態分佈與對數連結函數，並將在後續模型說明中闡釋此選擇的合理性，詳細結果如

表 20 所示。

表 20

專家評分在兩種抽象程度常態分佈檢定表

構面	抽象/具象	Shapiro-Wilk		
		統計量	自由度	顯著性
專家評分	抽象(1-5)	.889	900	.000
	具象(6-10)	.893	900	.000

E. 專家評分在十種抽象尺度常態分佈檢驗

針對十種抽象尺度題目的專家評分，採用 Shapiro-Wilk 檢定檢視常態性。檢定結果顯示，各題目 W 值介於 0.823 至 0.903，且 p 值均小於 .001，全部顯著偏離常態。鑒於常態假設不成立，但考慮到其為近似連續的區間尺度，且為處理其偏態性，本研究選擇採用廣義線性混合模型搭配常態分佈與對數連結函數，並將在後續模型說明中闡釋此選擇的合理性，詳細說明如表 21 所示。

表 21

專家評分在十種抽象尺度常態分佈檢驗表

構面	抽象程度	Shapiro-Wilk		
		統計量	自由度	顯著性
專家評分	抽象度_1	.903	180	.000
	抽象度_2	.876	180	.000
	抽象度_3	.823	180	.000
	抽象度_4	.875	180	.000
	抽象度_5	.887	180	.000
	抽象度_6	.862	180	.000
	抽象度_7	.886	180	.000

抽象度_8	.871	180	.000
抽象度_9	.897	180	.000
抽象度_10	.889	180	.000

F. 三種創意模式在專家評分常態分佈

三種創意模式在專家評分的常態性以 Shapiro-Wilk 檢定驗證，檢定統計量分別為 $W=0.896$ （人類組）、 0.880 （AI 協作組）、 0.894 （生成式 AI 組），且 p 值皆 $<.00$ 。結果顯示每一組的評分分佈都顯著偏離常態，由於專家評分資料顯著偏離常態分佈，但考慮到其為近似連續的區間尺度，且為處理其偏態性，本研究選擇採用廣義線性混合模型搭配常態分佈與對數連結函數，並將在後續模型說明中闡釋此選擇的合理性，詳細說明如表 22 所示。

表 22

三組專家評分常態分佈表

構面	組別	Shapiro-Wilk		
		統計量	自由度	顯著性
專家評分	人類組	.896	600	.000
	AI 協作組	.880	600	.000
	生成式 AI 組	.894	600	.000

4.2 各項指標表現分析

本節將著重分析語義距離、流暢性及專家評分核心指標間的關聯性，以釐清這些創造力衡量維度彼此間的相互作用，並為後續的影響分析奠定基礎。

4.2.1 各項指標相關性分析

(一) 語義距離與抽象程度、流暢性相關性

本研究採用斯皮爾曼相關性分析(Spearman Correlation)探討語義距離與流暢性、

抽象程度之間的關聯性。分析結果顯示，語義距離與流暢性之間存在顯著正相關（ $r_s = .229, p < .01$ ），表示受測者產生的聯想回答數量越多，其語義距離也傾向於越遠。

語義距離與抽象程度之間則呈現顯著負相關（ $r_s = -.166, p < .01$ ），此結果顯示隨著刺激詞題號的增加（數值越小代表越抽象），語義距離傾向於增加，亦即越抽象的題目能引發受測者產生與刺激詞語義關聯更遠的聯想。此發現符合抽象概念促進發散性思考的理論預期，驗證了抽象問題在激發創造性聯想方面的有效性。

這些相關性分析結果為本研究的核心假設提供了初步支持，顯示語義距離作為創造力指標與流暢性及抽象程度均存在理論上預期的關聯方向，詳細結果如表 23 所示。

表 23

語義距離與抽象程度、流暢性相關性分析表

	個數 N	相關係數	顯著性(雙尾)
語義距離×抽象程度	630	-.166	.000
語義距離×流暢性	630	.229	.000

(二) 專家評分與語義距離、抽象程度相關性

本研究採用斯皮爾曼相關性分析(Spearman Correlation)探討專家評分與抽象程度、語義距離之間的關聯性。分析結果顯示，專家評分與抽象程度之間存在顯著負相關（ $r_s = -.106, p < .01$ ），此結果顯示越抽象的題目能獲得專家更高的創造力評分，反映出抽象題目在激發創造性表現方面的優勢。

專家評分與語義距離之間的相關性分析結果顯示，兩者之間的相關係數為 $r_s = .046$ ，但未達統計顯著水準（ $p = .053$ ），表示專家評分與語義距離之間僅存在微弱且不顯著的正向關聯。此結果顯示專家對創造力的主觀評判與語義距離的客觀測量指標之間並非完全一致，可能反映出兩種評估方法在創造力測量上的不同面向與特性。

這些相關性分析結果顯示，抽象程度對專家評分具有顯著影響，而專家評分與語義距離之間的關聯性相對較弱，提示兩種創造力評估方法可能各自捕捉到創造力的不同層面，詳細結果如表 24 所示。

表 24

專家評分與抽象程度、語義距離相關性分析表

	個數 N	相關係數	顯著性(雙尾)
專家評分×抽象程度	1800	-.106	.000
專家評分×語義距離	1800	.046	.053

4.2.2 不同創意模式與抽象兩尺度對創造力表現的影響分析

本節旨在探討三種創意模式（人類、AI 協作與生成式 AI）在抽象與具象兩種問題尺度下，語義距離、流暢性與專家評分三項創造力指標的表現差異。本研究採用線性混合模型 (LMM) 或廣義線性混合模型 (GLMM) 進行推論，這些方法能夠同時考量組別、抽象程度（二分尺度：抽象 1-5 vs. 具象 6-10）及其交互作用的固定效應，並控制個體間的隨機變異。語義距離採用線性混合模型 (LMM)；流暢性採用廣義線性混合模型 (GLMM) 並使用 Poisson 分佈；專家評分則採用廣義線性模型 (GLMM) 並使用常態分佈。

（一）語義距離表現差異分析（兩種尺度）

本節首先探討不同創意模式在抽象與具象兩種問題尺度下，其語義距離表現的差異。儘管語義距離部分數據在 Shapiro-Wilk 檢定中未達顯著常態性，但考慮到混合模型的穩健性，以及在殘差圖未呈現明顯的模式或極端偏離，模型的資訊準則亦顯示良好擬合度，故仍採用參數模型線性混合效應模型 (LMM)。模型將語義距離視為連續依變項，創意模式、抽象尺度（抽象與具象）及其交互作用設定為固定效應，同時以受試者之截距作為隨機效應以控制層級結構造成的誤差。

模型假設語義距離服從常態分佈，連結函數採恆等式，適配度指標顯示，校正後的 Akaike 資訊量 (AICc = -1777.829) 與 Bayesian 資訊量 (BIC = -1764.560)

皆低，代表目前模型在複雜度與解釋力之間取得良好平衡。進一步檢視觀察值與模型預測值之散點圖 15，可見資料多落在對角帶附近，殘差分佈亦未呈現系統化偏離，顯示模型對資料具足夠擬合度，常態與恆等式設定亦為合理，詳細結果如表 25 所示。


表 25

語義距離之模型基本資訊表

目標		語義距離
機率分佈		常態
連結函數		恆等式
資訊準則	已修正 Akaike	-1777.829
	Bayesian	-1764.560

圖 15

語義距離模型預測值之散點圖



根據固定效應分析，語義距離模型整體達顯著水準， $F(5, 624) = 12.021$ ， $p < .001$ ，顯示將組別、抽象尺度及其交互作用納入後，模型能夠有效解釋語義距離的總變異。進一步檢視單一固定因子，組別主效應顯著， $F(2, 624) = 8.137$ ， $p < .001$ ；亦即在控制受試者與題項隨機變異後，生成式 AI、純人類與 AI 協作三種創意模式於語

義距離上的表現存在整體差異；抽象程度的主效應 $F(1, 624) = 42.936$ ， $p < .001$ ，證實抽象題與具象題在語義距離表現上存在顯著差異。相較之下，組別與抽象程度的交互作用不具顯著性， $F(2, 624) = 0.749$ ， $p = .473$ ，表示不同創意模式雖在語義距離上存在主效應差異，但此差異在抽象題與具象題之間的變化幅度趨於一致，抽象度對語義發散的促進效果並未因創意模式而顯著改變，詳細結果如表 26 所示。

表 26

語義距離之固定效應分析表


固定效應	F	Df1	Df2	顯著性
修正的模型	12.021	5	624	<.001*
組別	8.137	2	624	<.001*
抽象程度	42.936	1	624	<.001*
組別 × 抽象程度	.749	2	624	.473

在各組對語義距離的主效應圖 16 中，三張圖分別對應組別主效應、抽象程度主效應與組別 × 抽象程度交互作用。以下依序敘述各圖所揭示的趨勢與其在統計檢定中的意涵。

首先，組別主效應的圖像走勢與先前 $F(2, 624)=8.137$ 、 $p<.001$ 的組別主效應結果相符，在控制受試者與題項隨機變異後，三種創意模式的語義距離確實存在整體差異，生成式 AI 組的平均語義距離位於最高點，AI 協作組與人類組的平均值則大致相近，詳細結果如圖 16 所示。

圖 16


各組對語義距離的主效應



其次，圖 17 呈現抽象程度主效應僅考量題目抽象度差異，抽象組(1~5 題)所對應的點略高於具象題(6~10 題)，整體趨勢反映抽象題誘發較大語義距離的方向。此視覺結果與統計檢定 $F(1, 624)=42.936$ 、 $p<.001$ 之主效應一致，證實抽象題與具象題在語義跳躍幅度上具有顯著差異。

圖 17


抽象程度對語義距離的主效應



最後，交互作用以藍線代表抽象題、紅線代表具象題，同時描繪三組的平均值與信賴區間。可見兩條線在各組別上維持大致平行，不論是 AI 協作組、生成式 AI 組或人類組，抽象題皆位於具象題之上，顯示抽象度對語義距離的提升幅度在三種創意模式間相當一致。此視覺印象與交互作用 $F(2, 624)=0.749$ 、 $p=.473$ 的不顯著結果相呼應，雖然抽象題普遍拉高語義距離，且生成式 AI 組整體平均最高，但抽象程度對各組別的增幅並無統計上可辨識的差異，也就是說題目抽象度的效果並不因創意模式而改變，詳細結果如圖 18 所示。

圖 18

組別與抽象程度對語義距離的交互作用圖



就隨機效應而言，本研究模型保留了兩個來源的變異，一是截距殘差，代表題項與受測者交互後仍未被固定效應解釋的誤差；另一是「受測者」隨機截距，對應個體間在語義距離上的固有差異。結果顯示，截距殘差的變異量為 .002，這是 LMM 中不可再拆解的單位誤差；而受測者層級亦估得 .002 的變異量，其標準誤為 .000，Z 值 4.910，顯著性 $p < .001$ ，95% 信賴區間介於 .001 與 .003 之間，說明即使已控制組別與抽象程度等固定效應，受試者之間仍存在穩定且統計上顯著的差異，詳細結果如表 27 所示。

表 27

語義距離之隨機效應表

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.002	.000	4.910	<.001	.001	.003

(二) 專家評分表現差異分析（兩種尺度）

本節檢視生成式 AI 組、AI 協作組與人類組在兩種抽象尺度下的專家評分差異。分析同樣採階層結構的線性混合效應模型，但因評分屬近似連續資料且分佈趨於常態，故以常態性分佈結合對數連結函數建模。模型資訊準則（ $AIC = 2001.439$ ； $BIC = 2017.902$ ）顯示，在同類候選模型中，其配適度與複雜度之權衡仍屬可接受。預測值與觀察值散點圖 19 亦呈現收束於對角帶的趨勢，未見明顯系統性偏差，佐證模型對資料具基本解釋力，詳細結果如表 28 所示。


表 28

專家評分之模型基本資訊表

目標		專家評分
機率分佈		常態
連結函數		對數
資訊準則	已修正 Akaike	2001.439
	Bayesian	2017.902

圖 19

專家評分模型預測值之散點圖



然而，固定效應檢定結如表 29 所示，此模型雖整體 ($F = 3.120, df_1 = 5, df_2 = 1794, p = .008$) 達顯著水準，但差異來源與先前兩項指標截然不同。首先，組別主效應不具顯著性 ($F = 0.839, p = .432$)，在控制抽象程度與個體差異後，生成式 AI、AI 協作與純人類三組於專家評分上並無系統性高低之，表示無論答案產自何種創意模式，專家對其品質的主觀評估趨於一致；其次，「組別 $\times$ 抽象程度」交互作用亦不顯著 ($F = 0.253, p = .776$)，抽象題組或具象題組對三組的評分影響幅度並無顯著差異；唯一達顯著的固定因子為抽象程度本身 ($F = 13.748, p < .001$)。如圖 20 所示，抽象題平均評分約略高於具象題。此結果顯示就專家而言，抽象題的回答在可讀性、概念深度或語用適切性等維度上或許稍具優勢，儘管幅度有限。

表 29


專家評分之固定效應分析表

固定效應	F	Df1	Df2	顯著性
修正的模型	3.120	5	1794	.008*
組別	.839	2	1794	.432
抽象程度	13.748	1	1794	<.001*
組別 $\times$ 抽象程度	.253	2	1794	.776

在圖 20 抽象程度對專家評分的主效應中，清楚展現了抽象問題與具象問題在專家評分上的顯著差異，抽象組（標示為 1）的平均評分達到 3.25 分，且明顯高於具象組（標示為 2）的 3.03 分，兩組間約 0.2 分的差距在統計上達到顯著水準 ($F(1, 1794) = 13.748, p < .001$)。

圖 20


抽象程度對專家評分的主效應折線圖



各組對專家評分的主效應圖 21 顯示，三種創意模式在專家評分上呈現相當接近的表現水準，生成式 AI 組略居首位，AI 協作組居，人類組最，但三者差距微小且信賴區間重疊，反映出組別主效應的不顯著性 ($F(2, 1794) = 0.839, p = .432$)。

圖 21

各組對專家評分的主效應折線圖




從組別與抽象程度的交互作用圖 22 可觀察到，三種創意模式在抽象與具象兩種問題尺度下的專家評分呈現相對穩定的模式，與統計分析中交互作用不顯著的

結果相符，可見兩條線在三個組別間基本保持平行走勢，不同創意模式受到抽象程度影響的幅度相當一致。

圖 22

組別和不同抽象程度對專家評分的交互作用折線圖



隨機效應方面，受測者截距變異僅 0.002，且 $Z=1.463$ 、 $p=.143$ 未達顯著；殘差變異則為 0.070。表示在專家評分上，個體間穩定差異遠小於題項或隨機誤差。此結果與語義距離、流暢性兩指標形成鮮明對比，專家對作品優劣的判斷標準相對一致，且不易受創作者背景或使用工具影響，詳細結果如表 30 所示。

表 30

專家評分之隨機效應表

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.002	.001	1.463	.143	.001	.008

(三) 流暢性表現差異分析（兩種尺度）

本節針對生成式 AI 組、AI 協作組與人類組在抽象題與具象題兩種條件下的流暢性進行比較。由於反應數量屬計數資料，分析採 Poisson 連線的線性混合效應模，以受試者為隨機截距，並將組別、抽象程度及其交互項納入固定效應。

首先，從模型摘要顯示，以對數連結函數建構的 Poisson 在資訊準則上表現良好，經小樣本修正之 AIC 為 -50.575，BIC 為 -41.722，均遠低於零基準，表示模型在解釋力與複雜度之間取得適當平衡。觀察值與預測值之散點圖 23 呈現近似 45° 斜帶分佈，顯示模型對資料的擬合度足以信賴，未見系統性偏差，詳細結果如表 31 所示。


表 31

流暢性之模型基本資訊表

目標		流暢性
機率分佈		Poisson
連結函數		對數
資訊準則	已修正 Akaike	-50.575
	Bayesian	-41.722

圖 23

流暢性模型預測值之散點圖



固定效應檢定結果詳見表 32，整體模型顯著（ $F = 26.652$, $df_1 = 5$, $df_2 = 624$, $p < .001$ ），且三項固定因子皆達顯著水準：組別主效應 $F = 35.380$, $p < .001$ 抽象程度主效應 $F = 54.035$, $p < .001$ ；組別 $\times$ 抽象程度交互作用 $F = 12.364$, $p < .001$ 。

表 32


流暢性之固定效應分析表

固定效應	F	Df1	Df2	顯著性
修正的模型	26.652	5	624	.000*
組別	35.380	2	624	<.001*
抽象程度	54.035	1	624	<.001*
組別 $\times$ 抽象程度	12.364	2	624	<.001*

組別主效應的走勢如圖 24 所示，生成式 AI 組在兩種抽象尺度下皆產出最多有效回應，AI 協作組次之，人類組最少。

圖 24


各組對流暢性的主效應折線圖



抽象程度主效應如圖 25 所示，具象題比抽象題略能提高回答數；然此提升效應並非在三組間均一致，正是交互作用顯著的來源。

圖 25


抽象程度對流暢性的主效應折線圖



交互作用圖 26 進一步揭示，各組對抽象度變動的敏感性並不相同，對生成式 AI 組而言，抽象與具象題的流暢性幾乎等同；AI 協作組在具象題略優於抽象題；而人類組的差距最為顯著，遇到抽象題時平均回答數明顯下降。由上述可以表示具象尺度的題目，可在一定程度上彌補人類創作者的產生量不足，但對已能快速產生多元構想的生成式 AI，其助益相對有限。

圖 26

分組和不同抽象程度對流暢性的交互作用折線圖



最後，從隨機效應表顯示，受試者截距變異為 0.081 ($SE = 0.016, Z = 4.988, p < .001, 95\% CI [0.055, 0.120]$)，殘差變異為 0.076。以此估算的類內相關係數約為 0.52，代表超過一半的總變異源自個體特質，凸顯受試者間的潛在語言能力或創作習慣對流暢性具有關鍵影響，若分析中忽略這層結構，極可能低估標準誤並高估固定效應的顯著性，詳細結果如表 33 所示。

表 33

流暢性之隨機效應表

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.081	.016	4.988	<.001*	.055	.120

4.2.3 不同創意模式與抽象十尺度對創造力表現的影響分析

前述章節探討了抽象與具象二分尺度下，不同創意模式對創造力指標的影響。為進一步洞悉創意模式與抽象層次的複雜關係，本節將抽象尺度細分為十個層級，重新檢視三種創意模式在連續十級抽象度下的語義距離、流暢性與專家評分表現，藉此捕捉潛在的漸進趨勢與臨界效應，並驗證先前二分尺度下所得結論在更精密刻度上是否仍具穩健性。本階段同樣採用線性混合模型 (LMM) 或廣義線性混合模型 (GLMM) 比較不同抽象程度對三個組別在各構面中的影響，同時考慮個體間的隨機變異。

(一) 語義距離表現差異分析（十種尺度）

本階段採用線性混合模型 (LMM) 比較不同抽象程度（十級）對三個組別在語義距離中的影響，同時考慮個體間的隨機變異。由於語義距離為連續型資料，故選用常態分佈，並使用恆等式作為連結函數。

模型的整體擬合度與資訊準則(Information Criteria)顯示模型具有良好的解釋能力，調整後的 Akaike 資訊準則(AICc)值為-1924.790，而 Bayesian 資訊準則(BIC)值則為-1916.016，詳細結果如表 34 所示。圖 27 觀測值與模型預測值的散點圖顯示，數據點分佈在近似 45 度線上，表明模型預測值與實際觀測值吻合良好。


表 34

語義距離之模型基本資訊表

目標		語義距離
機率分佈		常態
連結函數		恆等式
資訊準則	已修正 Akaike	-1924.790
	Bayesian	-1916.016

圖 27

語義距離模型預測值之散點圖



固定效應的分析結果顯示，修正後的模型($F(29, 600) = 8.134, p < .001$)、組別($F(2, 600) = 9.083, p < .001$)和抽象程度($F(9, 600) = 21.702, p < .001$)對於語義距離均有顯著影響，詳細結果如表 35 所示。然而，組別與抽象程度的交互作用不顯著($F(18,$

600) = 1.355, $p = .148$)，表示三組在不同抽象程度下的語義距離變化模式相似，不存在顯著的交互效應。

表 35


語義距離之固定效應分析表

固定效應	F	Df1	Df2	顯著性
修正的模型	8.134	29	600	.000*
組別	9.083	2	600	<.000*
抽象程度	21.702	9	600	.000*
組別 × 抽象程度	1.355	18	600	.148

從組別與抽象程度的交互作用圖可觀察到，雖然三種創意模式在不同抽象程度下的語義距離呈現複雜的波動模式，但各組別的變化趨勢大致保持一致，生成式 AI 組在所有抽象程度上均維持最高的語義距離水準，AI 協作與人類組的表現則較為接近且相互交錯，這種一致的模式反映出抽象程度雖會影響整體語義距離的高低，但並不會改變各模式間的根本差異，如圖 28 所示。

圖 28


組別與抽象程度對語義距離的交互作用圖折線圖



從不同抽象程度對語義距離的主效應圖 29 可觀察到，語義距離隨著抽象程度的變化呈現明顯的非線性波動模式。抽象程度 1、2、5、7、9 維持相對較高的語義距離水準（約 0.85-0.95），而抽象程度 6、8、10 則顯示較低的語義距離表現（約 0.80-0.90）。這種波動性變化與抽象程度在固定效應分析中表現出顯著影響（ $p < .001$ ）相符，表示抽象程度確實會影響語義距離，但其影響模式是複雜的，而非單一方向的線性關係，詳細結果如圖 29 所示。

圖 29


抽象程度對語義距離之主效應圖折線圖



從各組對語義距離的主效應圖 30 可觀察到明確的組間差異模式。生成式 AI 組具有最高的語義距離平均值，顯示生成式 AI 獨立產出的內容其語義距離相對於刺激詞而言是最大的。人類組具有最低的語義距離平均值，表示由人類獨立產出的內容語義距離相對最小，即語義上與刺激詞最為接近。AI 協作組的語義距離平均值介於生成式 AI 組和人類組之間，表示在 AI 協作模式下，語義距離比純 AI 產出要小，但比純人類產出要大，呈現出協作模式的中介效應。

圖 30

組別對語義距離之主效應圖折線圖



接著，在隨機效應的結果顯示，受測者作為隨機效果的變異量估計為 0.002，且在統計上達到顯著水平($Z = 5.021, p < .001$)，95%信賴區間介於[0.001, 0.003]，詳細結果如表 36 所示。儘管變異量看起來相對較小，但其統計顯著性表明，在控制了組別和抽象程度等固定效應的影響後，不同受測者之間在語義距離上仍然存在顯著的個體差異。

表 36

語義距離之隨機效應表

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.002	.000	5.021	<.000	.001	.003

(二) 專家評分表現差異分析（十種尺度）

在完成前述的語義距離分析後，本節將持續以廣義線性混合模型(GLMM)評估不同組別和抽象程度對於專家評分的影響，並將受試者納入隨機效應以控制個體間變異，鑒於專家評分視為連續變項，本模型選用常態分佈並使用對數作為連結函數。

整體擬合指標顯示模型具有良好的解釋力，詳情見表 37，校正後 Akaike 資訊準則 (AICc) = 5934.271、Bayesia 資訊準則 (BIC) = 5945.222，顯示在兼顧模型複雜度與擬合度的情況下，本模型能有效描述資料結構。


表 37

專家評分模型基本資訊表

目標		專家評分
機率分佈		常態
連結函數		對數
資訊準則	已修正 Akaike	5934.271
	Bayesian	5945.222

圖 31

專家評分之模型預測值的散點圖



固定效應的分析結果顯示，組別對專家評分沒有顯著的主效應($F(2, 1770) = 0.871, p = .419$)，但抽象程度($F(9, 1770) = 20.549, p < .001$)以及組別與抽象程度的交互作用($F(18, 1770) = 2.362, p = .001$)對於專家評分有顯著影響，詳細結果如表 38 所示。修正後的模型整體達到顯著水準($F(29, 1770) = 7.911, p < .001$)。雖然三組在專家評分上的整體平均表現無顯著差異，但專家評分會因抽象程度的不同而有所變化，且這種變化模式在不同組別間存在差異。換言之，專家評分在不同組別上的表現會因抽象程度的不同而呈現出不同的模式，強調任務抽象程度在評估不同創意模式時的重要調節作用。

表 38

專家評分之固定效應表


固定效應	F	Df1	Df2	顯著性
修正的模型	7.911	29	1770	.000*
組別	.871	2	1770	.419
抽象程度	20.549	9	1770	.000*
組別 × 抽象程度	2,362	18	1770	.001*

為深入理解固定效應的結果，以下將透過三個主要圖表進行分析，首先檢視分組和不同抽象程度對專家評分的交互作用模式，接著分析不同抽象程度對專家評分的主效應趨勢，最後探討各組對專家評分的整體主效應差異。

首先，組別與抽象程度的交互作用圖 32 顯示，不同抽象程度下各組別的專家評分呈現複雜且顯著的交互模式 ($p = .001$)。圖中各條彩色線條代表不同抽象程度，三組的曲線相互交錯且明顯非平行，說明沒有任何單一組別能在所有抽象層次上始終取得最高評分。

圖 32


組別與抽象程度對專家評分的主效應圖折線圖



從抽象程度對專家評分的主效應圖 33 可見，專家評分從最抽象的 1 到最具象的 10 變化的複雜模式，專家評分隨抽象程度呈現顯著的非線性波動（固定效應： $p < .001$ ）。在抽象度 2、3、4（較為抽象的範圍），專家評分的中位數達到最高點，表示在此中高抽象範圍內，專家傾向給予較高的創造力評分；評分在抽象度 5、7、8、9、10 時中位數較低，尤其在抽象度 8 時，中位數降至約 2.0 分，表示部分具象程度的內容其評分相對較低。

圖 33


抽象程度對專家評分的主效應圖折線圖



從組別主效應圖 34 可見，三種創意模式在專家評分上呈現近乎一致的表現水準，與統計檢定結果組別主效應不顯著相符，各組的評分皆緊密分布於同一範圍內，顯示專家對不同創意模式產出的整體創造力品質評估趨於一致。

圖 34

各組對專家評分的整體主效應差異折線圖



隨機效應的結果顯示，將受測者視為隨機效應時，其變異量為 0.015 ($SD = 0.013$, $Z = 1.225$, $p = .221$; 95 % $CI = [0.003, 0.077]$), 詳細結果如表 39 所示。與語

義距離和流暢性的隨機效應不同，專家評分的隨機效應在統計上並未達到顯著水平，意味在控制組別和抽象程度等固定效應的影響後，各受測者間在專家評分上並無顯著的個體差異。此結果顯示專家評分的變異主要源於組別與抽象程度這些系統性因素，而非個體隨機差異，彰顯本評分系統在創造力評估上的穩定與一致。’

表 39

專家評分之隨機效應

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.015	.013	1.225	.221	.003	.077

流暢性表現差異分析（十種尺度）

為探三組在不同抽象程度下的流暢性表現差異，本研究採用廣義線性混合模型(GLMM)探討不同組別和抽象程度對於流暢性的影響，同時考慮個體間的隨機變異。由於流暢性為計數資料，故選用 Poisson 分佈，並使用對數(log)作為連結函數。

首先，在模型的整體擬合度與資訊準則(Information Criteria)顯示模型具有良好的解釋能力，詳細結果如表 40 所示。調整後的 Akaike 資訊準則(AICc)值為-22.040，而 Bayesian 資訊準則(BIC)值則為-17.650。觀測值與模型預測值的散點圖 35 顯示，點分佈在近似 45 度線上，表明模型預測值與實際觀測值吻合良好。


表 40

流暢性之模型基本資訊表

目標		流暢性
機率分佈		Poisson
連結函數		對數
資訊準則	已修正 Akaike	-22.040
	Bayesian	-17.650

圖 35

流暢性模型預測值之散點圖



在固定效應的分析結果顯示，組別、抽象程度以及組別與抽象程度的交互作用對於流暢性均有顯著影響($p < .001$)，詳細結果如表 41 所示。修正後的模型($F(29, 600) = 6.884, p < .001$)、組別($F(2, 600) = 35.781, p < .001$)、抽象程度($F(9, 600) = 11.289, p < .001$)，以及組別與抽象程度的交互作用($F(18, 600) = 3.330, p < .001$)均達到顯著水準。

表 41

流暢性之固定效應表

固定效應	F	Df1	Df2	顯著性
修正的模型	6.884	29	600	.000
組別	35.781	2	600	<.001
抽象程度	11.289	9	600	<.001
組別 × 抽象程度	3.330	18	600	<.001

由於生成式 AI 組在實驗設計中被設定為提供固定數量的回答，因此其流暢性表現並非自然產生的變異，而是預設的固定值。儘管如此，本研究仍將生成式 AI 組納入整體統計分析中，作為對照組在固定產出條件下，為其他組別提供重要的對


照基準，能夠比較在非自由產出量的限制下，不同組別在流暢性上的表現差異。

為深入理解固定效應的結果，以下將透過三個主要圖表進行分析，首先檢視分組和不同抽象程度對流暢性的交互作用模式，接著分析不同抽象程度對流暢性的主效應趨勢，最後探討各組對流暢性的整體主效應差異。

首先，從分組和不同抽象程度對流暢性的交互作用圖 36 可觀察到，三組在不同抽象程度下呈現不同的流暢性變化模式，驗證統計分析中顯著交互作用的發現($p < .001$)。圖中各條線的非平行走勢和交叉點顯示，沒有任何單一組別在所有抽象程度上都能持續維持最高或最低的流暢性表現。生成式 AI 組的趨勢線作為固定產出量的參照點，而人類組和 AI 協作組的流暢性隨著抽象程度的變化呈現不同的波動模式，反映出 AI 協作模式與純人類模式在面對不同抽象程度問題時的差異化。

圖 36

組別與抽象程度對流暢性的交互作用圖折線圖




從不同抽象程度對流暢性的主效應圖 37 可觀察到，流暢性總體上隨著抽象程

度的變化呈現先上升後略有下降的趨勢，在抽象度 1 至 3 時，流暢性相對較低，但自抽象度 4 開始逐步提升，並在抽象程度 7-8 時達到峰值，此結果表明抽象程度是影響流暢性表現的重要因素，如圖 37 所示。

圖 37


不同抽象程度對流暢性的主效應折線圖



從各組對流暢性的主效應圖 38 可清楚觀察到三組間的整體差異。生成式 AI 組的流暢性平均值最高，這主要歸因於其固定產出量的設定；AI 協作組的流暢性平均值明顯高於人類組在不考慮抽象程度細節的情況下，AI 協作模式顯著提升流暢性，優於單純人類的表現，如圖 38 所示。

圖 38

各組對流暢性的主效應折線圖



隨機效應的結果顯示，受測者作為隨機效果的變異量估計為 0.081（標準差 = 0.016, $Z = 4.988$, $p < .001$ ），95%信賴區間介於[0.055, 0.120]，詳細結果如表 42 所示。這個變異量相較於語義距離的隨機效應明顯較大，且在統計上達到顯著水平，表明在控制了組別和抽象程度等固定效應的影響後，不同受測者之間在流暢性表現上存在顯著的個體差異。

表 42

流暢性之隨機效應表

隨機效應	估計	標準差	Z	顯著性	95 信賴區間	
					下限	上限
受測者	.081	.016	4.988	<.001	.055	.120

4.3 綜合討論

此章節針對研究發現進行探討與詮釋回應研究問題，旨在釐清問題抽象程度如何影響不同創意生成模式（人類、AI 協作、生成式 AI）的創造力表現，並找出各模式的創造力臨界點。

4.3.1 問題抽象程度如何影響三種創意模式的創造力表現與差異

本研究透過分析語義距離、流暢性以及專家評分，揭示了問題抽象程度對不同創意模式創造力表現的顯著影響。


(一) 抽象與具象尺度的創造力差異

本研究透過語義距離、專家評分及流暢性三項核心指標，對生成式 AI、人類創意模式及 AI 協作三種模式在抽象與具象兩種問題尺度下的創造力表現進行剖析，旨在揭示問題抽象度對創意產出的影響，進而推導出其在創造力理論與實務應用上的深層意涵。

首先，在語義距離的結果明確指出抽象題的語義距離顯著高於具象題，如圖 39 所示，這推論出，無論是人類、AI 協作或是生成式 AI，在面對如「Hope」或「Infinity」等抽象概念時，其聯想過程較少受到約束，因而能探索更為遙遠的語義空間。與 Guilford（1950）關於抽象問題能激發更高階認知觀點一致，使個體需動用更高階的認知歷程來重新組合和概念化既有知識。在此之中，生成式 AI 的表現尤為突出，其所產出的聯想整體語義距離最遠。這顯示生成式 AI 能夠運用其龐大的訓練數據庫，發掘並整合語義關聯，展現出較好的語義跳躍能力。相較之下，AI 協作模式與純人類模式的語義距離表現則較為接近。然而，創意模式與問題抽象程度間並無顯著的交互作用，抽象問題促進聯想發散性的這種機制，在人類和 AI 兩種截然不同的創作模式中，展現出一致性，如圖 39 所示。

圖 39


不同創意模式語義距離在兩種抽象程度的變化趨勢圖



其次，在專家評分方面，結果同樣顯示抽象題目的整體得分高於具象題目，如圖 40 所示，這延伸了語義距離的發現，驗證了抽象刺激不僅能促進聯想的原創性與變通性，在專家更全面的創造力品質判斷（涵蓋適切性、原創性、變通性與周全性）中，亦能展現整體優勢。因為抽象問題提供了更大的詮釋空間，使得想法更具創造力，而非僅限於具體應用。在此二種尺度下，創意模式與抽象程度間未呈現顯著的交互作用，由於專家評分採用單盲設計，評分者無法辨識內容來源，且各創意模式在整體專家評分上並無顯著差異，這推論出 AI 所產出的創意在抽象領域的品質，能夠達到與人類創作在專家眼中難以區分的程度，它挑戰了傳統觀念中，人類獨有的情感、意圖或意識是衡量創意品質的唯一或決定性因素，表示 AI 透過其計算能力，已能生成符合甚至超越人類主觀評價標準的創意內容。這一發現與近期 Hubert 等人（2024）在《Scientific Reports》發表的研究結果一致，該研究發現 GPT-4 在發散思考任務上的創意潛力顯著超過人類受試者，特別是在原創性中表現突出。

圖 40

不同創意模式專家評分在兩種抽象程度的變化趨勢圖




然而，在流暢性方面，具象問題的整體回答數量顯著高於抽象問題，如圖 41，這推論出具象概念因其明確的定義，使得受試者能夠快速連結到具體的圖像或情境，進而產生更多回答。此發現與 Paivio (1978) 的雙碼理論相符，該理論指出人類在處理具象概念時能夠同時運用語言性與表象性系統，而面對抽象概念時則更多地依賴語言性系統，因此在理解與記憶上產生差異。具象概念的表象性優勢使得聯想過程更為流暢。從整體組別表現來看，AI 協作組較多，而人類組的產出則相對最少。更為重要的是，流暢性在三種創意模式與抽象度間呈現顯著的交互作用，這揭示了不同創意模式對抽象程度變化所承受認知負荷的差異，像是人類組在面對抽象問題時流暢性下降最為明顯，反映出人類在處理高度抽象、缺乏明確框架的

思維任務時，認知投入與資源耗費顯著增加，導致思維停滯或難以維持連續的發想，從而影響點子的產出數量。與之形成對比的是，AI 協作組在具象題目的回答數量表現上略優於抽象題目，這說明 AI 的輔助能緩解人類在處理抽象問題時的認知困境，透過快速生成初始概念或擴展思維方向，為人類提供一個思維跳板，從而克服創造、發想的阻礙，提升總體產出量。Dell'Acqua 等人（2023）哈佛商學院與波士頓諮詢集團聯合研究的發現，AI 協作可使任務完成率提高 12.2%，完成時間縮短 25.1%，驗證了 AI 協作在提升效率方面的有效性。

圖 41

不同創意模式流暢性在兩種抽象程度的變化趨勢圖



(二) 十種抽象尺度的非線性變化模式


在確立了抽象與具象兩大尺度的普遍趨勢後，接著進一步對十種抽象尺度的創造力表現進行討論。語義距離、流暢性以及專家評分皆展現出非線性複雜的變化。

語義距離其總體曲線呈「高一降一升」波動，如圖 42 所示，儘管在三種創意

模式與十個抽象尺度無交互作用，意即三種模式在十個抽象尺度的語義距離皆維持生成式 AI > AI 協作 ≈ 人類的排序，但其在十個尺度上仍呈現出獨特的軌跡。在特定的抽象度上，出現高峰與低谷，並不是像抽象具象二分法那樣直觀而是更呈現為複雜的趨勢。

圖 42

不同創意模式語義距離在十種抽象程度的變化趨勢圖



從極端對比來看，最抽象的題 1「As」的語義距離高於最具象的題 10「Milk」，在此跨度間，抽象度 5 的「Scare」與抽象度 8 的「Red」分別出現高點與局部谷底，證實了「抽象—具象」維度對語義距離的影響並非線性，可能受詞性或語境等因素綜合影響，導致即便抽象程度相近，聯想廣度仍可能產生顯著差異。本研究在研究限制中提及的詞性控制問題，如 Forthmann 等人(2019)指出，在替代用途測驗中，詞彙的性質會對語義距離計算產生影響，不同詞性可能激發不同的聯想模式與創造力表現。


在專家評分上，三種創意模式與十種抽象尺度之間呈現出顯著的交互作用。如

果僅從抽象與具象的簡單二分法來看，抽象組在專家評分上整體優於具象。此外，三種創作模式對專家評分並未顯現顯著的主效應。這表示即使各創作模式在其他客觀指標（語義距離、流暢性）上有所差異，但在專家評分的情境下，不同創意模式整體的評分仍被評為相近。然而，當分析細化成十種具體的抽象尺度時，可以觀察到這些尺度對專家評分有明確的影響，某些特定的抽象程度，更容易激發人類、AI 協作或生成式 AI 產出被專家認為具有創意和品質的內容，例如，整體的專家評分在抽象度 2、3、4 上的表現最佳，表示中等程度的抽象最能產出具啟發性與適切性的回應；而在抽象度 5、7、8、9、10 的評分普遍偏低，表示這些尺度下的刺激詞聯想空間受限、語意固定，難以激發具新意與意義的內容，因而難獲高分。

進一步來看，不同創意模式在面對不同抽象尺度時，專家評分的表現趨勢並不一致，如圖 43 所示。雖然整體來說，人類創作並未顯著優於 AI，但在某些特定的抽象層級上（如抽象度 1、6、8），人類展現出相對突出的創意表現與品質優勢，這說明即便總體表現上難以區分三種創作模式哪種好，特定語意特徵與抽象程度仍可能觸發不同創作模式的相對優勢。

圖 43

不同創意模式專家評分在十種抽象程度的變化趨勢圖




流暢性的表現模式在細化至十種抽象尺度後，呈現出複雜且非線性特徵，如圖 44 所示。在整體流暢性表現方面，AI 協作組的回答數量顯著高於人類組，AI 的輔助能提升人類在發散性思考任務中的點子產出效率，彌補了純人類模式在產量上的不足，人類組的流暢性最低，反映了個體在獨立思考時，其發想速度和數量可能受限於認知資源。深入觀察流暢性在十種抽象尺度上的變化趨勢，可以發現 AI 協作組與人類組的流暢性曲線，從抽象度 1（最抽象的題目）至抽象度 10（最具象的題目），呈現出近乎線性上升的趨勢，AI 協作與人類組於題 7「Red」達峰後在題 8、9、10「King、Apple、Milk」略為趨緩推測此下降趨勢，後段的趨緩或下降趨

勢，推測可能歸因於實驗疲勞效應，即受試者在持續進行任務的過程中，其認知資源逐漸耗竭，進而影響了後續具象問題的聯想表現。

圖 44

不同創意模式流暢性在十種抽象程度的變化趨勢圖



4.3.2 人類、AI 協作及生成式 AI 模式的創造力臨界點

在前述討論中，已理解抽象程度對創造力的普遍影響，本節將聚焦於三種創意模式在整體創造力表現上的差異與特色，探討各模式的創造力臨界點，所謂「創造力臨界點」，係指特定創意模式在某項創造力指標上展現相對優勢或劣勢的轉折點，以及其在創造力不同面向間的平衡表現。

本研究發現一個關鍵現象，三種創意模式在不同創造力指標上呈現不同表現模式，語義距離方面呈現生成式 AI 組>AI 協作組≈人類組，專家評分則顯示三組間無顯著差異，而流暢性則呈現生成式 AI 組>AI 協作組>人類組的遞減排序，如表 43 所示。

表 43


不同創意模式在各創造力指標上的表現差異總結表

創造力指標	表現差異
語義距離（原創性、變通性）	生成式 AI 組 > AI 協作組 ≈ 人類組
專家評分 （適切性、原創性、變通性、周全性）	三組間無顯著差異
流暢性（產出數量）	生成式 AI 組 > AI 協作組 > 人類組

從語義距離來看，生成式 AI 組顯著優於 AI 協作組和人類組（AI 組>協作組≈人類組），顯示生成式 AI 在產生語義距離較遠（變通性）且更具獨創性的聯想方面（原創性）具有優勢，能突破人類固有的聯想路徑與認知偏見，探索更廣闊的語義空間。然而值得注意的是，仍有少數人類參與者在個別題目，其語義距離甚至高於兩種 AI 模式，突顯人類於極端原創性構想上仍扮演關鍵角色。Koivisto & Grassini (2023) 指出，人類雖然可能因認知偏差或靈感枯竭而產出低品質的點子，但頂尖創作者的創造力較生成式 AI 更具原創性與新穎性，能產生突破框架的創意點子。整體而言，生成式 AI 的強項在於快速且大規模地生成新穎聯想，但這些新穎聯想是否能一致轉化為高品質創意，仍需進一步探討，如圖 45 所示。

圖 45


不同創意模式語義距離分布箱型圖



在流暢性生成式 AI 組同樣表現最佳，其次是 AI 協作組，人類組的流暢性最低 (AI 組 > 協作組 > 人類組)。生成式 AI 結果是預期的能夠在短時間內生成大量的詞彙聯想。值得注意的是，AI 協作模式則展現了融合兩者優勢的潛力，其流暢性介於單純的人類組與生成式 AI 組之間，這表示人類在 AI 的輔助下，確實能有效提升發想的數量，如圖 46 所示。

圖 46

不同創意模式流暢性分布箱型圖




然而專家評分三組之間並無顯著差異。這是一個關鍵發現，如圖 47 所示。儘管生成式 AI 在語義距離（衡量原創性、變通性）和流暢性上表現突出，但專家們對生成式 AI 總體創造力（包含適切性、原創性、變通性、周全性）的評分並未顯著優於人類或 AI 協作組。這不但說明生成式 AI 創造力在「質」的方面與人類、AI 協作並無差異也說明語義距離高不等同於專家眼中高質量的整體創造力生成式 AI 能夠產生語義上遙遠的聯想，帶來高原創性和變通性，但這些聯想的適切性（是否符合任務要求、是否有意義）和周全性（是否足夠完善、有細節）可能不足。如 Dell'Acqua 等人（2023）的研究所揭示的，當任務超出 AI 能力邊界時，過度依賴 AI 反而會導致 13-24 個百分點的性能下降，這進一步說明了 AI 在複雜創意任務中的局限性。人類在聯想數量和語義距離上雖不敵 AI，但其聯想可能更具目的性和內在邏輯，更符合常識或問題情境，因此在總體質量上能與 AI 保持一致，如圖 47

所示。

圖 47

不同創意模式專家評分分布箱型圖



綜合以上分析，抽象概念有助於提升創造力表現；然而，AI 協作組雖在流暢性顯著優於人類組且其語義距離與人類組相近，卻未能在專家評分上取得領先，進一步證實「高品質創意」不能僅以語義距離所代表的原創性與變異性或產量多寡來衡量，而須同時兼顧適切性與周全性——兩者正是人類優勢，也是生成式 AI 的盲點。人類的點子雖較保守，語義距離相對較近，但往往更貼近脈絡、邏輯更嚴謹且結構更完整。AI 協作組恰好印證此觀點：生成式 AI 在流暢性層面補足了「量」，

卻未能在專家評分中穩定「提質」，突顯現行協作機制僅達成增量而未能有效提升品質。關鍵點在於如何設計更佳的協作模式，使 AI 的原創與變異性與人類的適切性與周全性相融合。基於此，本文根據 Kabir (2024) 提出的六階段 co-creation 框架人機互動的迭代循環核心概念建議實務端採用「生成式 AI 抽象發散→人類價值評鑑→AI 協作精煉」之流程，先讓大型語言模型於高抽象概念快速擴散思考，接著由人類篩選並重組構想以確保可行性與價值，最後在協作精煉階段於保留人類創意風格的同時，運用 AI 加速細節擴充與強化可行性，再透過反覆迭代與落地驗證，以實現新穎性與適切性的動態平衡；此流程將抽象概念融入並調整 AI 協作步驟，形塑出一套可操作的模型，得以突破「只增量、不提質」的瓶頸，為後續 AI 協作創造力的深化奠定具體而穩固的實踐基礎。



五、研究結論與建議

本研究透過系統化的實驗設計與量化分析，針對人類獨立創作、AI 協作及生成式 AI 三種創意生成模式，在不同抽象程度問題下的創造力表現進行比較與探討。研究重點聚焦於原創性、適切性與流暢性三項核心指標，以檢驗各模式在不同構面上的優勢與限制。結果驗證了問題抽象度在創意任務中三種模式在特定創造力構面上的互補特性與差異化表現。以下將綜合實驗數據與理論觀察，歸納本研究的主要結論，並提出針對後續應用與研究方向的具體建議。

5.1 研究結論

本研究透過系統性的實驗設計，深入探討了人類、AI 協作與生成式 AI 三種創意模式在不同問題抽象程度下的表現差異。綜合語義距離、專家評分與流暢性三項創造力指標的分析結果，可歸納出以下核心發現與理論貢獻。

5.1.1 問題抽象程度顯著影響創造力表現

問題的抽象程度在創造力活動中扮演關鍵角色，研究發現無論採用何種創意模式，越抽象的問題愈能提升創造力，越具象的問題則有助於快速收斂並提出可操作的想法。抽象—具象形成了「原創性—實用性」的動態張力；團隊可先以高抽象度廣泛發散，激發新意，再逐步下調抽象度，使構想收斂為具體可行方案，從而在不同專案階段平衡創新與實用。

5.1.2 三種創意模式各具獨特優勢

綜觀實驗數據，人類、AI 協作與生成式 AI 三種模式在創造歷程中各司其職、互為完補，生成式 AI 於語義距離指標上顯著優於其他模式，能於短時間內大量擴張概念邊界；在專家評分方面，生成式 AI 已達到與人類創造力相同的品質水準；AI 協作則在流暢性指標顯著提升，顯示協同機制能在保留人類創意風格的同時，加速產出並強化可行性；值得注意的是，語義距離分布的長尾中仍可觀察到少數人

類回答超越生成式 AI 與 AI 協作，證明人類在高原創性構想上仍具不可忽視的潛力。重要的是，儘管生成式 AI 在原創性、變異性與產出量上表現卓越，但其與 AI 協作模式皆未能在專家評分上實現穩定的「提質」效果，此現象驗證了高品質創意必須同時兼顧原創性、適切性與周全性的多維特性。雖然 AI 協作成功地補足了「量」的不足，但在「質」的提升上仍有改進空間。基於上述發現，本研究提出「生成式 AI 抽象發散→人類價值評鑑→AI 協作精煉」的三階段創意流程，以兼顧早期創新與後期實踐，適用於教育、設計與產品開發領域。具體操作要點如下：

(一) 生成式 AI 抽象發散

以高抽象尺度的提示詞驅動大型語言模型，快速蒐集大量、多元且語義跨度遠的原始點子，此階段暫不評估可行性，目標是拓寬概念邊界激發新奇聯想。

(二) 人類價值評鑑

聚焦生成式 AI 較弱的「適切性」與「周全性」，由具領域知識的創作者篩選、合併並重組構想，剔除不相關或不完整的點子，挑選與核心問題最具關聯且具延展潛力者，為後續深化奠定方向。

(三) AI 協作精煉

在人類主導下與 AI 協作，在保留人類創意風格的同時，補充細節、構建情境並驗證可行性，著重提升方案的「周全性」；透過人機反覆迭代，將優質概念發展為完整方案，實現原創性與適切性的動態平衡，突破「只增量、不提質」的限制。

5.1.3 抽象問題創造力測量框架之可複製性

本研究提出一套可重複操作的創造力測量框架。將「問題抽象層級」設定為可操控的自變數，再檢視人類、生成式 AI 與人機協作三種創意策略的表現，最後以語義距離、流暢性與專家評分構成三項創造力指標。

5.2 未來研究建議

雖然本研究已針對抽象與具象尺度問題下的人類、AI 協作及生成式 AI 創意

模式進行了系統性比較，並提出具體的創造力評估與應用框架，但仍存在若干研究範疇與方法上的限制，需在未來予以補足與擴展。以下將依據本研究的發現與不足，提出多方向的後續研究建議，旨在深化理論基礎、拓展應用場景，並驗證框架在跨情境、跨領域與跨文化下的適用性與穩健性。

5.2.1 擴展任務類型

本研究採用字詞聯想測驗（WAT）作為創造力測量工具，該任務屬於相對單純、去脈絡化的發散性思考測驗。呼應研究限制中提及的任務類型限制，未來研究應將本框架延伸至更貼近真實情境的創意任務，例如產品命名、廣告標語發想、具體設計問題解決等多階段創意工作。這些任務通常具備明確的約束條件、特定的目標對象，以及複雜的評估標準，可能會改變人類與 AI 在創造力表現上的相對優勢。

5.2.2 提升 AI 協作流程設計，探索最佳協作模式

本研究僅驗證了單一協作流程（1 分鐘獨立思考+3 分鐘 AI 協作），未來研究應系統性比較不同人機協作模式的效果。建議探索多元協作流程，包括：（a）「AI 先發散→人類收斂」模式；（b）「人類先發散→AI 收斂」模式。同時，實驗中發現 AI 協作組雖在流暢性顯著優於人類組，但仍未完全釋放 AI 協作潛力，推測與受試者須在限時內切換「構思→提示→評估」等繁複操作有關。因此，可嘗試延長協作時間、導入可視化工具協助構思管理，並引入工作負荷指數（NASA Task Load Index）等量表，以客觀評估不同協作流程對受試者認知負荷的影響，據此提升人機交互節奏。

5.2.3 強化刺激詞篩選機制與測量工具

本研究僅依據 MRC 心理語言學資料庫的具象度指標篩選刺激詞，事後分析顯示詞性、語境熟悉度及情緒向量等因素均可能影響創造力表現。未來研究建議採用多維度篩選策略，將 part-of-speech 標籤、valence、imageability、familiarity 等指標納入篩選，以控制潛在混淆變項。此外，建議將語義距離、專家評分與流暢性轉換為標準分數（Z-score），依理論重要性確立權重後加權合成「創造力總分」，既保

留各指標資訊量，又避免單一維度主導詮釋，提升測量的全面性與比較性。

5.2.4 擴大框架適用範圍，驗證跨領域可複製性

本研究建立抽象問題導向創造力評估框架具備良好的可複製性，未來應擴展至多元領域以驗證其普遍適用性。建議將此框架應用於技術創新、藝術創作、教育設計、商業策略等專業領域，深入檢驗問題抽象程度與三種創意模式在各領域中的表現差異與適用條件。此外，應同步進行跨文化比較研究，檢驗本框架在不同文化背景與語言環境下的穩健性，以進一步完善人機協同創意模式的理論基礎。透過這些擴展性研究，可為各專業領域提供更精確且具針對性的 AI 應用策略指引。



六、參考文獻

中文文獻

1. 林建諭. (2018). 兩類型受刑人在字詞聯想測驗之反應. 慈濟大學.
2. 陳天亮, 洪新原, & 梁定澎. (2000). 運用電子腦力激盪以提昇群體生產力及成員滿意之研究：國內實驗室之實驗. 資訊管理學報, 7(1).
<https://doi.org/10.6382/JIM.200007.0019>
3. 蒲怡靜. (2004). 電子腦力激盪術於設計創意值之研究. 碩士, 國立成功大學.
4. 何佳勳 (2012). 建構一以 KJ 法為基礎之創意思考平臺. 臺中科技大學學位論文.

英文文獻

1. Acar, S., & Runco, M. A. (2014). Assessing Associative Distance Among Ideas Elicited by Tests of Divergent Thinking. *Creativity Research Journal*, 26(2), 229–238. <https://doi.org/10.1080/10400419.2014.901095>
2. *AI Benchmarking Dashboard*. (2024, 十一月 27). Epoch AI.
<https://epoch.ai/data/ai-benchmarking-dashboard>
3. Amabile, T. M. (1983). The Social Psychology of Creativity: A Componential Conceptualization.
4. Beaty, R. E., & Johnson, D. R. (2021). Automating creativity assessment with SemDis: An open platform for computing semantic distance. *Behavior Research Methods*, 53(2), 757–780. <https://doi.org/10.3758/s13428-020-01453-w>
5. Berretta, S., Tausch, A., Ontrup, G., Gilles, B., Peifer, C., & Kluge, A. (2023). Defining human-AI teaming the human-centered way: A scoping review and network analysis. *Frontiers in Artificial Intelligence*, 6.

<https://doi.org/10.3389/frai.2023.1250725>

6. Boden, M. A. (1998). Creativity and artificial intelligence. *Artificial Intelligence*, 103(1–2), 347–356. [https://doi.org/10.1016/s0004-3702\(98\)00055-1](https://doi.org/10.1016/s0004-3702(98)00055-1)
7. Carolan, K., Fennelly, L., & Smeaton, A. F. (2024). *A Review of Multi-Modal Large Language and Vision Models* (No. arXiv:2404.01322). arXiv. <https://doi.org/10.48550/arXiv.2404.01322>
8. Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. de O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., ... Zaremba, W. (2021). *Evaluating Large Language Models Trained on Code* (No. arXiv:2107.03374). arXiv. <https://doi.org/10.48550/arXiv.2107.03374>
9. Choudhary, K. (2024). *AtomGPT: Atomistic Generative Pre-trained Transformer for Forward and Inverse Materials Design* (No. arXiv:2405.03680). arXiv. <https://doi.org/10.48550/arXiv.2405.03680>
10. Christophe, C., Raha, T., Maslenkova, S., Salman, M. U., Kanithi, P. K., Pimentel, M. A., & Khan, S. (2024). *Beyond Fine-tuning: Unleashing the Potential of Continuous Pretraining for Clinical LLMs* (No. arXiv:2409.14988). arXiv. <https://doi.org/10.48550/arXiv.2409.14988>
11. Collins, A., & Loftus, E. (1975). A Spreading Activation Theory of Semantic Processing. *Psychological Review*, 82, 407–428. <https://doi.org/10.1037//0033-295X.82.6.407>
12. Coltheart, M. (1981). The MRC Psycholinguistic Database. *The Quarterly Journal of Experimental Psychology Section A*, 33(4), 497–505. <https://doi.org/10.1080/14640748108400805>
13. Guilford, J. P. (1950). Creativity. *American Psychologist*, 5(9), 444–454.

<https://doi.org/10.1037/h0063487>

14. Cseh, G. M., & Jeffries, K. K. (2019). A scattered CAT: A critical evaluation of the consensual assessment technique for creativity research. *Psychology of Aesthetics, Creativity, and the Arts*, 13(2), 159–166. <https://doi.org/10.1037/aca0000220>
15. Dell'Acqua, F., McFowland III, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Kraye, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality* (SSRN Scholarly Paper No. 4573321). Social Science Research Network. <https://doi.org/10.2139/ssrn.4573321>
16. Doshi, A. R., & Hauser, O. P. (2024). Generative AI enhances individual creativity but reduces the collective diversity of novel content. *Science Advances*, 10(28), eadn5290. <https://doi.org/10.1126/sciadv.adn5290>
17. E. Paul Torrance. (1974). *Gifted Child Quarterly*, 18(3), 143–145. <https://doi.org/10.1177/001698627401800302>
18. Forthmann, B., Oyeade, O., Ojo, A., Günther, F., & Holling, H. (2019). Application of Latent Semantic Analysis to Divergent Thinking is Biased by Elaboration. *The Journal of Creative Behavior*, 53(4), 559–575. <https://doi.org/10.1002/jocb.240>
19. Franceschelli, G., & Musolesi, M. (2025). On the Creativity of Large Language Models. *AI & SOCIETY*, 40(5), 3785–3795. <https://doi.org/10.1007/s00146-024-02127-3>
20. Galton, F. (1879). PSYCHOMETRIC EXPERIMENTS. *Brain*, 2(2), 149–162. <https://doi.org/10.1093/brain/2.2.149>
21. Friendly, M., Franklin, P. E., Hoffman, D., & Rubin, D. C. (1982). The Toronto Word Pool: Norms for imagery, concreteness, orthographic variables, and grammatical usage for 1,080 words. *Behavior Research Methods & Instrumentation*,

- 14(4), 375–399. <https://doi.org/10.3758/BF03203275>
22. *Future of Jobs Report 2025: 78 Million New Job Opportunities by 2030 but Urgent Upskilling Needed to Prepare Workforces*. (2025). World Economic Forum. 讀取於 2025 年 6 月 13 日, 從 <https://www.weforum.org/press/2025/01/future-of-jobs-report-2025-78-million-new-job-opportunities-by-2030-but-urgent-upskilling-needed-to-prepare-workforces/>
23. *Gemini 2.5 Pro: Features, Tests, Access, Benchmarks & More*. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://www.datacamp.com/blog/gemini-2-5-pro>
24. Giannuzzo, A. (2023). Creativity, Intentions, and Self-Narratives: Can AI Really Be Creative? 收入 N. Moniz, Z. Vale, J. Cascalho, C. Silva, & R. Sebastião (編輯), *Progress in Artificial Intelligence* (卷 14116, 頁 52–63). Springer Nature Switzerland. https://doi.org/10.1007/978-3-031-49011-8_5
25. Gilhooly, K. J., & Logie, R. H. (1980). Age-of-acquisition, imagery, concreteness, familiarity, and ambiguity measures for 1,944 words. *Behavior Research Methods & Instrumentation*, 12(4), 395–427. <https://doi.org/10.3758/BF03201693>
26. Goldman Sachs report says AI could put 300 million jobs at risk. (2023, 三月 29). *SiliconANGLE*. <https://siliconangle.com/2023/03/29/goldman-sachs-report-says-ai-put-300-million-jobs-risk/>
27. Gough, H. G. (1976). Studying creativity by means of word association tests. *Journal of Applied Psychology*, 61(3), 348–353. <https://doi.org/10.1037/0021-9010.61.3.348>
28. Grok 3 mini Reasoning (high)—Intelligence, Performance & Price Analysis | Artificial Analysis. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://artificialanalysis.ai/models/grok-3-mini-reasoning>
29. Guilford, J. P. (1967). *The nature of human intelligence*. McGraw-Hill.

30. Haase, J., & Hanel, P. H. P. (2023). Artificial muses: Generative artificial intelligence chatbots have risen to human-level creativity. *Journal of Creativity*, 33(3), 100066. <https://doi.org/10.1016/j.yjoc.2023.100066>
31. Hass, R. W. (2017). Tracking the dynamics of divergent thinking via semantic distance: Analytic methods and theoretical implications. *Memory & Cognition*, 45(2), 233–244. <https://doi.org/10.3758/s13421-016-0659-y>
32. Heinen, D. J. P., & Johnson, D. R. (2018). Semantic distance: An automated measure of creativity that is novel and appropriate. *Psychology of Aesthetics, Creativity, and the Arts*, 12(2), 144–156. <https://doi.org/10.1037/aca0000125>
33. Hennessey, B. A., & Amabile, T. M. (2010). Creativity. *Annual Review of Psychology*, 61(Volume 61, 2010), 569–598. <https://doi.org/10.1146/annurev.psych.093008.100416>
34. Hocevar, D., & Bachelor, P. (1989). A Taxonomy and Critique of Measurements Used in the Study of Creativity. 收入 J. A. Glover, R. R. Ronning, & C. R. Reynolds (編輯), *Handbook of Creativity* (頁 53–75). Springer US. https://doi.org/10.1007/978-1-4757-5356-1_3
35. *How to support human-AI collaboration in the Intelligent Age*. (2025, 一月 13). World Economic Forum. <https://www.weforum.org/stories/2025/01/four-ways-to-enhance-human-ai-collaboration-in-the-workplace/>
36. Hubert, K. F., Awa, K. N., & Zabelina, D. L. (2024). The current state of artificial intelligence generative language models is more creative than humans on divergent thinking tasks. *Scientific Reports*, 14(1), 3440. <https://doi.org/10.1038/s41598-024-53303-w>
37. *Intelligence Benchmarking | Artificial Analysis*. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://artificialanalysis.ai/methodology/intelligence-benchmarking>

38. Sternberg, R. J., & Lubart, T. I. (1996). Investing in creativity. *American Psychologist*, 51(7), 677–688. <https://doi.org/10.1037/0003-066x.51.7.677>
39. Jain, N., Han, K., Gu, A., Li, W.-D., Yan, F., Zhang, T., Wang, S., Solar-Lezama, A., Sen, K., & Stoica, I. (2024, 三月 12). *LiveCodeBench: Holistic and Contamination Free Evaluation of Large Language Models for Code*. arXiv.Org. <https://arxiv.org/abs/2403.07974v2>
40. Jauk, E., Benedek, M., & Neubauer, A. C. (2014). The Road to Creative Achievement: A Latent Variable Model of Ability and Personality Predictors. *European Journal of Personality*, 28(1), 95–105. <https://doi.org/10.1002/per.1941>
41. Johnson, D. R., Cuthbert, A. S., & Tynan, M. E. (2021). The neglect of idea diversity in creative idea generation and evaluation. *Psychology of Aesthetics, Creativity, and the Arts*, 15(1), 125–135. <https://doi.org/10.1037/aca0000235>
42. Kabir, M. (2024). Unleashing Human Potential: A Framework for Augmenting Co-Creation with Generative AI. *International Conference on AI Research*, 4(1), Article 1. <https://doi.org/10.34190/icair.4.1.3074>
43. Kenett, Y. N. (2019). What can quantitative measures of semantic distance tell us about creativity? *Current Opinion in Behavioral Sciences*, 27, 11–16. <https://doi.org/10.1016/j.cobeha.2018.08.010>
44. Koivisto, M., & Grassini, S. (2023a). Best humans still outperform artificial intelligence in a creative divergent thinking task. *Scientific Reports*, 13(1), 13601. <https://doi.org/10.1038/s41598-023-40858-3>
45. Koivisto, M., & Grassini, S. (2023b). Best humans still outperform artificial intelligence in a creative divergent thinking task. *Scientific Reports*, 13(1), 13601. <https://doi.org/10.1038/s41598-023-40858-3>
46. Kolbjørnsrud, V. (2023). Designing the Intelligent Organization: Six Principles for

- Human-AI Collaboration. *California Management Review*, 66.
<https://doi.org/10.1177/00081256231211020>
47. Landauer, T. K. (1999). Latent semantic analysis: A theory of the psychology of language and mind. *Discourse Processes*, 27(3), 303–310.
<https://doi.org/10.1080/01638539909545065>
48. *Learning to reason with LLMs*. (2024). 讀取於 2025 年 6 月 13 日, 從 <https://openai.com/index/learning-to-reason-with-llms/>
49. Li, J., Bian, Y., Wang, G., Lei, Y., Cheng, D., Ding, Z., & Jiang, C. (2023). *CFGPT: Chinese Financial Assistant with Large Language Model* (No. arXiv:2309.10654). arXiv. <https://doi.org/10.48550/arXiv.2309.10654>
50. Liu, C., Ren, Z., Zhuang, K., He, L., Yan, T., Zeng, R., & Qiu, J. (2021). Semantic association ability mediates the relationship between brain structure and human creativity. *Neuropsychologia*, 151, 107722.
<https://doi.org/10.1016/j.neuropsychologia.2020.107722>
51. Lu, W., Luu, R. K., & Buehler, M. J. (2024). Fine-tuning large language models for domain adaptation: Exploration of training strategies, scaling, model merging and synergistic capabilities (No. arXiv:2409.03444). arXiv. <https://doi.org/10.48550/arXiv.2409.03444>
52. *McKinsey—Economic potential of generative AI | McKinsey*. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-economic-potential-of-generative-ai-the-next-productivity-frontier>
53. Mednick, S. (1962). The associative basis of the creative process. *Psychological Review*, 69(3), 220–232. <https://doi.org/10.1037/h0048850>
54. Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space* (No. arXiv:1301.3781). arXiv.

<https://doi.org/10.48550/arXiv.1301.3781>

55. Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences 人工智慧之說明：社會科學之洞見. *Artificial Intelligence*, 267, 1–38. <https://doi.org/10.1016/j.artint.2018.07.007>
56. Mitchell, J., & Lapata, M. (2010). Composition in Distributional Models of Semantics. *Cognitive Science*, 34(8), 1388–1429. <https://doi.org/10.1111/j.1551-6709.2010.01106.x>
57. Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality—Working Paper—Faculty & Research—Harvard Business School. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://www.hbs.edu/faculty/Pages/item.aspx?num=64700>
58. O4-Mini: Tests, Features, O3 Comparison, Benchmarks & More. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://www.datacamp.com/blog/o4-mini>
59. OpenAI’s weekly active users surpass 400 million. (2025, 二月 20). *Reuters*. <https://www.reuters.com/technology/artificial-intelligence/openais-weekly-active-users-surpass-400-million-2025-02-20/>
60. Paivio, A. (1978). Comparisons of mental clocks. *Journal of Experimental Psychology: Human Perception and Performance*, 4(1), 61–71. <https://doi.org/10.1037/0096-1523.4.1.61>
61. Pennington, J., Socher, R., & Manning, C. (2014). Glove: Global Vectors for Word Representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar. <https://doi.org/10.3115/v1/d14-1162>
62. Phan, L., Gatti, A., Han, Z., Li, N., Hu, J., Zhang, H., Zhang, C. B. C., Shaaban, M.,

- Ling, J., Shi, S., Choi, M., Agrawal, A., Chopra, A., Khoja, A., Kim, R., Ren, R., Hausenloy, J., Zhang, O., Mazeika, M., ... Hendrycks, D. (2025). *Humanity's Last Exam* (No. arXiv:2501.14249). arXiv. <https://doi.org/10.48550/arXiv.2501.14249>
63. Prabhakaran, R., Green, A. E., & Gray, J. R. (2014). Thin slices of creativity: Using single-word utterances to assess creative cognition. *Behavior Research Methods*, 46(3), 641–659. <https://doi.org/10.3758/s13428-013-0401-7>
64. Prompt Engineering: The Art of Getting What You Need From Generative AI | Ivan Allen College of Liberal Arts. (2024). 讀取於 2025 年 6 月 14 日, 從 <https://iac.gatech.edu/featured-news/2024/02/AI-prompt-engineering-ChatGPT>
65. *Rebalancing AI*-Daron Acemoglu Simon Johnson. (2023). IMF. <https://www.imf.org/en/Publications/fandd/issues/2023/12/Rebalancing-AI-Acemoglu-Johnson>
66. Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., & Bowman, S. R. (2023). *GPQA: A Graduate-Level Google-Proof Q&A Benchmark* (No. arXiv:2311.12022). arXiv. <https://doi.org/10.48550/arXiv.2311.12022>
67. Rhodes, M. (1961). An Analysis of Creativity. *The Phi Delta Kappan*, 42(7), 305–310.
68. Rothenberg, A. (1973). Word Association and Creativity. *Psychological Reports*, 33(1), 3–12. <https://doi.org/10.2466/pr0.1973.33.1.3>
69. Runco, M. A., & Charles, R. E. (1993). Judgments of originality and appropriateness as predictors of creativity. *Personality and Individual Differences*, 15(5), 537–546. [https://doi.org/10.1016/0191-8869\(93\)90337-3](https://doi.org/10.1016/0191-8869(93)90337-3)
70. Runco, M. A., & Jaeger, G. J. (2012). The Standard Definition of Creativity. *Creativity Research Journal*, 24(1), 92–96. <https://doi.org/10.1080/10400419.2012.650092>

71. *Scale AI and CAIS Unveil Results of Humanity's Last Exam | Scale*. (2025). 讀取於 2025 年 6 月 13 日, 從 <https://scale.com/blog/humanitys-last-exam-results>
72. Shneiderman, B. (2022). *Human-centered AI*. Oxford University Press.
73. Silvia, P. J., Winterstein, B. P., Willse, J. T., Barona, C. M., Cram, J. T., Hess, K. I., Martinez, J. L., & Richard, C. A. (2008). Assessing creativity with divergent thinking tasks: Exploring the reliability and validity of new subjective scoring methods. *Psychology of Aesthetics, Creativity, and the Arts*, 2(2), 68–85. <https://doi.org/10.1037/1931-3896.2.2.68>
74. Smith, E., & Kosslyn, S. (2013). *Cognitive Psychology*. Pearson International. <https://elibrary.pearson.de/book/99.150005/9781292035550>
75. Sternberg, R. J., & Lubart, T. I. (1998a). The Concept of Creativity: Prospects and Paradigms. 收入 R. J. Sternberg (編輯), *Handbook of Creativity* (頁 3–15). Cambridge University Press. <https://doi.org/10.1017/CBO9780511807916.003>
76. Sternberg, R. J., & Lubart, T. I. (1998b). The Concept of Creativity: Prospects and Paradigms. 收入 R. J. Sternberg (編輯), *Handbook of Creativity* (1 本, 頁 3–15). Cambridge University Press. <https://doi.org/10.1017/CBO9780511807916.003>
77. Tian, M., Gao, L., Zhang, S. D., Chen, X., Fan, C., Guo, X., Haas, R., Ji, P., Krongchon, K., Li, Y., Liu, S., Luo, D., Ma, Y., Tong, H., Trinh, K., Tian, C., Wang, Z., Wu, B., Xiong, Y., ... Peng, H. (2024). *SciCode: A Research Coding Benchmark Curated by Scientists* (No. arXiv:2407.13168). arXiv. <https://doi.org/10.48550/arXiv.2407.13168>
78. Toglia, M. P. (with Internet Archive). (1978). *Handbook of semantic word norms*. Hillsdale, N.J.: Lawrence Erlbaum Associates; New York: Distributed by the Halsted Press Division of John Wiley. <http://archive.org/details/handbookofsemant0000togl>

79. Valacich, J. S., Dennis, A. R., & Connolly, T. (1994). Idea generation in computer-based groups: A new ending to an old story. *Organizational Behavior and Human Decision Processes*, 57(3), 448–467. <https://doi.org/10.1006/obhd.1994.1024>
80. Wang, Y., Ma, X., Zhang, G., Ni, Y., Chandra, A., Guo, S., Ren, W., Arulraj, A., He, X., Jiang, Z., Li, T., Ku, M., Wang, K., Zhuang, A., Fan, R., Yue, X., & Chen, W. (2024). *MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark* (No. arXiv:2406.01574). arXiv. <https://doi.org/10.48550/arXiv.2406.01574>
81. Wilson, M. (1988). MRC psycholinguistic database: Machine-usable dictionary, version 2.00. *Behavior Research Methods, Instruments, & Computers*, 20(1), 6–10. <https://doi.org/10.3758/BF03202594>
82. Xu, L., Xie, H., Qin, S.-Z. J., Tao, X., & Wang, F. L. (2023). *Parameter-Efficient Fine-Tuning Methods for Pretrained Language Models: A Critical Review and Assessment* (No. arXiv:2312.12148). arXiv. <https://doi.org/10.48550/arXiv.2312.12148>
83. Xue, Q. (2024). Unlocking the potential: A comprehensive exploration of large language models in natural language processing. *Applied and Computational Engineering*, 57(1), 247–252. <https://doi.org/10.54254/2755-2721/57/20241341>
84. Zhou, H., Hu, C., Yuan, Y., Cui, Y., Jin, Y., Chen, C., Wu, H., Yuan, D., Jiang, L., Wu, D., Liu, X., Zhang, C., Wang, X., & Liu, J. (2024). *Large Language Model (LLM) for Telecommunications: A Comprehensive Survey on Principles, Key Techniques, and Opportunities* (No. arXiv:2405.10825). arXiv. <https://doi.org/10.48550/arXiv.2405.10825>